CentraleSupélec

Projet de Machine Learning — CentraleSupélec

Prédiction de la qualité des soudures d'acier à partir de la Cambridge Weld Database

Rapport complet : de l'analyse exploratoire à l'analyse des résultats d'entraînement

Mohamed SALH mohamed.salh@student-cs.fr

Mohamed CHEBLI mohamed.chebli@student-cs.fr

Idriss BEN LETAIFA idriss.benletaifa@student-cs.fr

Équipe n° **[À compléter : numéro d'équipe]**

10 octobre 2026

Données : Cambridge Weld Database (MAP_DATA_WELD), T. Cool et H. K. D. H. Bhadeshia. Code, protocoles et exports reproductibles : notebooks `01` à `07` du dépôt du projet.

Résumé

Ce rapport documente l'ensemble d'un projet d'apprentissage automatique visant à prédire des propriétés mécaniques de soudures d'acier, utilisées ici comme indicateurs mesurables de la « qualité » d'une soudure. Les données proviennent de la *Cambridge Weld Database* : 1 652 dépôts de soudure décrits par 44 champs (composition chimique, paramètres de soudage, traitement thermique après soudage, propriétés mécaniques et microstructure) [1].

L'analyse exploratoire montre une base *hétérogène*, compilée à partir de nombreuses publications : beaucoup de valeurs non rapportées, des valeurs censurées ou annotées, des unités douteuses, des absences qui dépendent du procédé et surtout des *séries expérimentales* dont les observations sont apparentées. Nous traduisons le problème en quatre régressions indépendantes : limite d'élasticité (YS), résistance maximale à la traction (UTS), allongement et, à titre exploratoire, énergie Charpy à température d'essai connue.

La préparation est entièrement traçable : nettoyage déterministe, provenance de 66 080 cellules, déduplication, cohorte principale de 1 555 lignes réparties en 44 séries, puis prétraitement (standardisation, encodage, imputation) *appris uniquement dans les plis d'entraînement*. Cinq familles supervisées — médiane, Ridge, SVR à noyau RBF, forêt aléatoire et k plus proches voisins — sont comparées par validation croisée *imbriquée* selon deux scénarios : un découpage aléatoire des lignes et un découpage par séries, qui teste le transfert à des séries absentes de l'entraînement. La méthode semi-supervisée COREG [2] est ensuite appliquée selon un protocole inductif.

Avec 16 entrées numériques, le procédé et une imputation médiane, la procédure supervisée atteint des R^2 moyens de 0,755 (YS), 0,836 (UTS), 0,660 (allongement) et 0,776 (Charpy) en validation aléatoire, mais seulement 0,337, 0,334, 0,157 et 0,075 lorsque des séries entières sont tenues à l'écart. COREG n'améliore pas cette référence. Les diagnostics attribuent une large part de l'erreur à des décalages de niveau entre séries. La conclusion principale est donc méthodologique : prédire une série déjà représentée est réaliste, prédire une nouvelle étude reste difficile avec les entrées disponibles. Les recommandations portent sur la collecte et l'évaluation des données ; aucun réglage de soudage « optimal » n'est déduit de ces associations.

Mots-clés : soudage, aciers, propriétés mécaniques, régression, données manquantes, validation croisée imbriquée, GroupKFold, forêt aléatoire, SVR, apprentissage semi-supervisé, COREG.

Guide de lecture

Le rapport suit l'ordre chronologique et logique du projet. Chaque section se termine par un encadré « À retenir » qui résume ce qu'il faut garder en tête. Les encadrés « Décision et justification » expliquent chaque choix de conception, et les encadrés « Précaution d'interprétation » signalent ce que les résultats *ne* démontrent *pas*.

Section	Contenu
1	Problématique industrielle et traduction en tâche d'apprentissage
2	Analyse exploratoire (EDA) : structure, absences, distributions, cibles, ACP
3	Choix des variables cibles et stratégie de prédiction
4	Préparation des données et prétraitement appris dans les plis
5	Méthodes supervisées et méthode semi-supervisée (bibliographie, COREG)
6	Protocole de validation croisée imbriquée et métriques
7	Résultats d'entraînement supervisé
8	Diagnostics des performances et explicabilité
9	Résultats semi-supervisés (COREG)
10	Analyse comparative, limites et recommandations
11	Conclusion et perspectives
12	Organisation de l'équipe et diagramme de Gantt
Annexes	Dictionnaire des variables, reproductibilité, tableaux complets, glossaire

Notations et conventions

— **YS** : limite d'élasticité (*yield strength*, MPa) ; **UTS** : résistance maximale à la traction (*ultimate tensile strength*, MPa) ; **Allongement** : allongement à rupture (%, erreurs en points de %) ; **Charpy*** : énergie Charpy (J) à température d'essai connue — l'astérisque rappelle que cette tâche est exploratoire.

— **PWHT** : traitement thermique après soudage (*post-weld heat treatment*), décrit par une température (°C) et une durée (h).

— **Schémas d'entrées** : « 11 », « 13 » et « 16 » désignent le nombre de variables numériques utilisées (tableau 10).

— **Validation aléatoire** : KFold sur les lignes ; **validation groupée** : GroupKFold sur les séries inférées (section 6).

— Les scores sont, sauf mention contraire, des **moyennes non pondérées sur les cinq plis externes**, suivies de leur écart-type (SD) entre plis. Un SD n'est pas un intervalle de confiance.

— Les nombres utilisent la virgule décimale ; les tableaux reprennent les valeurs des exports des notebooks, arrondies à trois décimales.

— Les éléments affichés **[À compléter : ainsi]** doivent être renseignés par l'équipe : ils ne sont pas inventés.

Table des matières

Résumé **1**

1 Problématique et traduction en tâche d'apprentissage **9**
1.1 Contexte industriel . . . 9
1.2 Qu'est-ce que la « qualité » d'une soudure ? . . . 9
1.3 Formulation comme problème d'apprentissage . . . 9
1.4 Démarche suivie . . . 10
1.5 Organisation du dépôt . . . 11

2 Analyse exploratoire des données **12**
2.1 Source et structure de la base . . . 12
2.2 Statut des mesures : absence, censure, intervalles, annotations . . . 13
2.3 Identifiants, répétitions et séries . . . 13
2.4 Distributions et ordres de grandeur . . . 15
2.5 Les absences dépendent du procédé . . . 17
2.6 Cohérence physique et unités douteuses . . . 17
2.7 Propriétés mesurées et relations entre cibles . . . 19
2.8 Analyse en composantes principales descriptive . . . 20
2.9 Bilan de l'analyse exploratoire . . . 22

3 Variables cibles et stratégie de prédiction **23**
3.1 Quelles variables représentent la qualité ? . . . 23
3.2 Pourquoi des régressions séparées ? . . . 23
3.3 Le cas particulier de l'énergie Charpy . . . 24
3.4 Entrées autorisées et entrées exclues . . . 24
3.5 Stratégie d'ensemble . . . 24

4 Préparation des données **26**
4.1 Deux niveaux de traitement . . . 26
4.2 Nettoyage déterministe . . . 26
4.3 Groupes : des séries expérimentales inférées . . . 26
4.4 Cohorte de modélisation . . . 28
4.5 Schémas d'entrées . . . 28
4.6 Normalisation : pourquoi standardiser ? . . . 29
4.7 Imputation des entrées manquantes . . . 30
4.8 Le prétraitement complet dans une pipeline . . . 31

5 Méthodes d'apprentissage **32**
5.1 Méthodes supervisées . . . 32
5.2 Apprentissage semi-supervisé : revue bibliographique . . . 34
5.3 L'algorithme COREG . . . 35

6 Protocole de validation et métriques **37**
6.1 Pourquoi une validation croisée imbriquée ? . . . 37
6.2 Deux scénarios de validation, deux questions . . . 37
6.3 Métriques . . . 38
6.4 Protocole inductif pour le semi-supervisé . . . 39
6.5 Graines et reproductibilité . . . 39

7 Résultats de l'entraînement supervisé **41**
7.1 Premier benchmark : 13 entrées, imputation itérative, validation groupée . . . 41
7.2 Configuration de travail : 16 entrées, imputation médiane . . . 42
7.3 Comparaison des familles de modèles . . . 43
7.4 Familles et hyperparamètres sélectionnés . . . 44
7.5 Prédictions et observations . . . 44
7.6 Modèles réentraînés pour l'inférence . . . 46

8 Diagnostics des performances et explicabilité **48**
8.1 Les modèles apprennent, mais transfèrent mal . . . 48
8.2 Une grande part de l'erreur vient des séries . . . 48
8.3 Domaine des entrées et rôle de l'imputation . . . 50
8.4 Sensibilités : entrées et méthode d'imputation . . . 50
8.5 Effet du mode de découpage . . . 52
8.6 Quantité de données : courbes d'apprentissage . . . 53
8.7 Explicabilité : quelles informations le modèle utilise-t-il ? . . . 53
8.8 Audit des protocoles Charpy . . . 53
8.9 Bilan des diagnostics . . . 55

9 Résultats semi-supervisés : COREG **56**
9.1 Méthodes comparées . . . 56
9.2 Déroulement de la boucle . . . 56
9.3 Performances . . . 56
9.4 Gain apparié et robustesse . . . 56
9.5 Pourquoi COREG n'apporte-t-il pas de gain ici ? . . . 58
9.6 Modèles exportés . . . 58

10 Analyse comparative et discussion **60**
10.1 Vue d'ensemble des approches . . . 60
10.2 Quelle approche est la plus appropriée ? . . . 60
10.3 Limites de l'étude . . . 61
10.4 Recommandations . . . 61

11 Conclusion et perspectives **62**

12 Organisation du projet et diagramme de Gantt **64**
12.1 Méthode de travail . . . 64

12.2 Chronologie et diagramme de Gantt . . . 64
12.3 Répartition des tâches et temps passé . . . 64

Références bibliographiques **66**

A Dictionnaire des variables **68**

B Reproductibilité **69**
B.1 Environnement . . . 69
B.2 Commandes . . . 69
B.3 Notebooks, durées et exports . . . 70
B.4 Contrôles automatiques . . . 70
B.5 Figures de ce rapport . . . 70

C Tableaux complémentaires **70**
C.1 Familles supervisées, configuration 16/médiane . . . 70
C.2 COREG : dispersion et scores OOF . . . 70
C.3 Reconstruction de valeurs Ni/Cr/Mo masquées . . . 70

D Glossaire **74**

Table des figures

1 Enchaînement des étapes du projet. Chaque boîte correspond à un notebook du dossier `notebooks/` ; la référence indique la section du rapport qui le décrit. Le diagnostic (04) a motivé le passage de la configuration initiale 13 entrées/imputation itérative à la configuration 16 entrées/imputation médiane. . . . 10
2 Statut des 1 652 valeurs de chaque variable numérique dans le fichier brut. Les valeurs spéciales (censures, intervalles, annotations) sont de l'information rapportée : elles ne doivent être confondues ni avec une absence ni avec un nombre exact. . . . 14
3 Distributions de compositions, de paramètres de soudage et de propriétés mécaniques (nombres exacts, 1 648 lignes dédupliquées ; n = effectif disponible). Aucune valeur extrême n'est supprimée et aucune unité n'est convertie. . . . 16
4 Part de valeurs non rapportées (%) par procédé, pour les 16 entrées numériques retenues (haut) et les mesures cibles (bas), sur les 1 648 lignes dédupliquées. Cases vides : moins de 0,5 % d'absences. . . . 18
5 Corrélations de Pearson entre propriétés de traction, calculées sur les paires observées (lignes dédupliquées). Bleu : corrélation négative ; rouge : positive. Cette matrice décrit des dépendances par paires ; ce n'est pas une ACP. . . . 19
6 Couples (température d'essai, énergie Charpy) exacts. Les lignes horizontales à 28 J et 100 J concentrent 54 % des points, signature probable de températures de transition plutôt que de mesures à température imposée. . . . 20

7 ACP standardisée des onze entrées complètes (1 339 lignes). (a) Variance expliquée par composante et cumul. (b) Projection sur les deux premiers axes, colorée par procédé. (c) Coefficients des variables sur les deux premiers axes. 21
8 Du fichier brut aux populations de modélisation. Chaque cible utilise les lignes de la cohorte qui la renseignent ; les autres lignes de la cohorte forment son pool non étiqueté (vide pour Charpy, faute de température d'essai connue sans énergie). . . 28
9 Part d'entrées absentes dans la cohorte de 1 555 lignes pour les 16 entrées numériques. Ni, Cr et Mo manquent dans plus de la moitié des lignes. 29
10 Pipeline de prétraitement et de modélisation. Les flèches pleines indiquent les paramètres appris sur le train ; la flèche pointillée, l'application de ces paramètres figés à la validation (ou au pool non étiqueté). 31
11 Principe de COREG. Chaque kNN choisit dans le pool l'exemple dont sa propre prédiction réduit le plus l'erreur locale, puis le transmet à l'autre kNN comme pseudo-label. 35
12 Validation croisée imbriquée : 5 plis externes pour l'évaluation, 3 plis internes dans chaque train externe pour le réglage. Le prétraitement est réappris à chaque ajustement (interne et externe). 37
13 Résultat principal : R^2 moyen ($\pm$ écart-type sur 5 plis) de la procédure supervisée avec sélection interne de la famille, configuration 16/médiane. Bleu : validation aléatoire ; orange : validation groupée. 42
14 R^2 moyen ($\pm$ écart-type) de chaque famille, configuration 16/médiane, validations aléatoire et groupée. La dernière colonne (fond gris) est la procédure de sélection interne de la famille. 43
15 Valeurs observées et prédites hors pli (OOF) par la procédure de sélection interne, configuration 16/médiane. Haut : validation aléatoire ; bas : validation groupée. La diagonale pointillée correspond à une prédiction parfaite. 46
16 Biais moyen (prédit $-$ observé) des six séries qui contribuent le plus à l'erreur quadratique, forêt du benchmark 13/itérative, validation groupée. 49
17 R^2 moyen de la forêt aléatoire en validation groupée selon le nombre d'entrées et l'imputation. Les mentions « $k/5$ » signalent les scénarios où seuls k plis sur 5 ont abouti (non comparables aux scénarios complets). 51
18 Même forêt aléatoire, sans réglage, configuration 16/médiane, sous trois découpages. Séparer des conditions de soudage répétées change peu le score ; séparer des séries entières le fait chuter. 52
19 MAE d'entraînement et de validation groupée de la forêt (benchmark 13/itérative) en fonction de la fraction de groupes d'entraînement utilisée. 53
20 Importance par permutation de blocs d'entrées (forêt du benchmark 13/itérative, validation groupée, dix permutations par pli). Barres : hausse moyenne de MAE ; traits : écart-type entre répétitions et plis. 54
21 Nombre cumulé de pseudo-labels acceptés au fil des tours, pour chacun des cinq plis externes (un trait par pli ; point : arrêt). La croissance est quasi linéaire (deux ajouts par tour) jusqu'à l'absence de gain positif ou au plafond de 100 tours. . . . 57

22 R^2 moyen (± écart-type) de COREG, de son contrôle apparié sans pseudo-labels et de la sélection supervisée de référence. . . . 57
23 Diagramme de Gantt des phases du projet, d'après l'historique Git et les dates des rapports intermédiaires. Les responsables et les heures réelles sont à renseigner dans le tableau 34 ; la date de rendu est indicative. . . . 64

Liste des tableaux

1 Organisation du dépôt du projet. Les données brutes, les données dérivées et les modèles sont produits localement et ne sont pas versionnés. . . . 11
2 Familles de variables de la base et unités documentées. . . . 12
3 Variables les plus concernées par les valeurs spéciales (fichier brut, 1 652 lignes). . . . 13
4 Ordres de grandeur des principales entrées (nombres exacts, lignes dédupliquées). . . . 15
5 Propriétés mécaniques candidates (nombres exacts du fichier brut). . . . 19
6 Cibles retenues et effectifs de labels. « Cohorte » désigne la population de modélisation de 1 555 lignes (section 4.4) ; « Groupes » le nombre de séries inférées portant au moins un label. . . . 23
7 Statistiques des cibles dans la cohorte de modélisation. . . . 23
8 Entrées autorisées et exclues des modèles. . . . 24
9 Règles de nettoyage déterministe et justification. . . . 27
10 Schémas d'entrées numériques ; le procédé catégoriel est ajouté à chacun. . . . 29
11 Étude historique de reconstruction de valeurs masquées (3 plis par séries, graines 42/43). MAE normalisée par l'écart interquartile du train ; plus bas est meilleur. . . . 30
12 Contrôle d'imputation à paramètres fixes, schéma 13, validation groupée (MAE moyenne des cinq plis externes). . . . 31
13 Familles supervisées, rôle dans la comparaison et grilles d'hyperparamètres. . . . 33
14 Grandes familles de méthodes semi-supervisées et adéquation au projet. . . . 34
15 Paramétrage de COREG et écarts à l'article original. . . . 36
16 Les deux scénarios de validation croisée. . . . 38
17 Graines aléatoires utilisées. . . . 40
18 Premier benchmark, schéma 13/itérative, validation groupée : moyenne ± écart-type sur les cinq plis externes. En gras : plus faible MAE par cible. . . . 41
19 Procédure supervisée avec sélection interne, configuration 16/médiane : moyennes ± écart-type sur 5 plis externes, et MAE relative à la médiane de la cible. . . . 42
20 MAE moyenne et R^2 moyen par famille, configuration 16/médiane (A : validation aléatoire ; G : validation groupée). En gras : meilleure famille par colonne. . . . 44
21 Validation aléatoire : famille et hyperparamètres choisis par la MAE interne dans chaque pli externe, et scores externes obtenus. . . . 45
22 Validation groupée : famille et hyperparamètres choisis par la MAE interne dans chaque pli externe, et scores externes obtenus. . . . 45
23 Modèles supervisés réentraînés sur tous les labels, retenus pour l'inférence. . . . 47
24 Écart entre entraînement et validation groupée, forêt aléatoire du benchmark 13/itérative. . . . 48

25 Décomposition de l'erreur de la forêt du benchmark 13/itérative (prédictions OOF réunies). 49
26 MAE de la forêt (benchmark 13/itérative) selon l'appartenance au domaine du train. 50
27 Forêt aléatoire en validation groupée : MAE et R^2 moyens selon le schéma et l'imputation (plis aboutis sur 5 entre parenthèses lorsque incomplets). 50
28 R^2 moyen de la forêt fixe selon le découpage, et structure des séries. 52
29 Correspondance des séries Charpy avec leurs publications originales. 54
30 Déroulement de COREG dans les cinq plis externes (min–max sur les plis). « Pool distinct » : après déduplication et retrait des représentations déjà présentes parmi les vrais labels. 56
31 COREG et contrôles : MAE moyenne et R^2 moyen sur les cinq plis externes. . . . 57
32 Gain de MAE OOF de COREG par rapport au contrôle apparié (même k, sans pseudo-labels) et par rapport à la sélection supervisée. 58
33 Récapitulatif des approches pour YS : R^2 moyen sur cinq plis externes. 60
34 Répartition des tâches. Colonnes « Membre(s) » et « Heures » à compléter par l'équipe à partir de `specs/time_log.csv`. 65
35 Les 44 champs de la Cambridge Weld Database. 68
36 Notebooks, durée de calcul rapportée dans les rapports d'exécution et exports produits (ignorés par Git). 70
37 Validation aléatoire : chaque famille réglée en interne (moyenne ± écart-type sur 5 plis ; RMSE moyenne). 71
38 Validation groupée : chaque famille réglée en interne (moyenne ± écart-type sur 5 plis ; RMSE moyenne). 72
39 COREG : moyenne ± écart-type sur les plis et scores OOF réunis. 72
40 Sensibilité de COREG à la graine de tirage des candidats (k fixé par la sélection interne du calcul principal) : MAE moyenne et R^2 moyen. 73
41 Erreur absolue moyenne (% massique) de reconstruction de 20 % des valeurs observées de Ni, Cr et Mo masquées en validation, imputeur ajusté sur le train ; mêmes cellules pour les deux méthodes. 73

1 Problématique et traduction en tâche d'apprentissage

1.1 Contexte industriel

Le soudage des aciers intervient dans des secteurs dont le poids économique se chiffre en milliards d'euros, par exemple l'assemblage des mâts et pieux d'éoliennes. Une soudure défaillante peut compromettre toute une structure ; il faut donc garantir que le métal déposé possède la résistance et la ténacité attendues. Aujourd'hui, la connaissance sur la qualité des soudures se transmet surtout d'expert à expert, ce qui rend les industriels dépendants de quelques spécialistes. L'énoncé du projet propose d'exploiter les données pour *extraire et homogénéiser* cette connaissance experte, et éventuellement découvrir de nouveaux motifs.

1.2 Qu'est-ce que la « qualité » d'une soudure ?

La qualité n'est pas une grandeur mesurée directement dans la base. Elle se manifeste à travers plusieurs *propriétés mécaniques* mesurées par des essais normalisés :

- la **limite d'élasticité** (YS) : contrainte à partir de laquelle le métal se déforme de façon permanente ;
- la **résistance maximale à la traction** (UTS) : contrainte maximale supportée avant la rupture ;
- l'**allongement** : déformation atteinte à la rupture, qui renseigne sur la ductilité ;
- l'**énergie Charpy** : énergie absorbée lors de la rupture d'une éprouvette entaillée à une température donnée, qui renseigne sur la ténacité.

Ces propriétés décrivent des aspects différents et parfois antagonistes : un métal très résistant est souvent moins ductile (section 2.7). Fusionner ces mesures en un score unique « bon/mauvais » demanderait un cahier des charges (seuils par application, normes visées) que la base ne fournit pas.

Décision et justification

Nous ne créons **aucune classe arbitraire** « bonne soudure / mauvaise soudure ». Chaque propriété mesurée est prédite séparément, dans son unité physique. Ce choix conserve l'information quantitative, évite d'inventer des seuils et permet à un utilisateur d'appliquer ensuite ses propres critères d'acceptation.

1.3 Formulation comme problème d'apprentissage

Pour chaque propriété cible $t \in \{YS, UTS, \text{allongement}, \text{Charpy}\}$, on cherche une fonction f_t qui associe aux *conditions de fabrication* d'une soudure $\boldsymbol{x}$ (composition chimique, paramètres électriques, apport thermique, températures, traitement thermique, procédé) une estimation de la propriété y_t :

$$\hat{y}_t = f_t(\boldsymbol{x}), \qquad \boldsymbol{x} \in \mathbb{R}^p \times \{\text{procédés}\}, \quad y_t \in \mathbb{R}. \tag{1}$$

Il s'agit donc de **régressions supervisées**. Pour l'énergie Charpy, la température d'essai T fait partie des entrées, car l'énergie dépend fortement de la température : on prédit $E(T)$.

La base est **partiellement étiquetée** : une ligne peut renseigner la composition et le procédé sans renseigner la propriété cible. Pour chaque cible, on dispose ainsi d'un ensemble étiqueté $\mathcal{D}_L = \{(\boldsymbol{x}_i, y_i)\}$ et d'un ensemble non étiqueté $\mathcal{D}_U = \{\boldsymbol{x}_j\}$. Cette situation motive l'étude d'une méthode **semi-supervisée**, qui cherche à exploiter $\mathcal{D}_U$ en plus de $\mathcal{D}_L$ (section 5.2).

Intuition

Dans un usage réel, on voudrait estimer les propriétés d'une soudure *avant* de réaliser des essais mécaniques coûteux, à partir de sa recette (composition, réglages, traitement). Les entrées autorisées sont donc uniquement celles connues à ce moment-là : une autre propriété mécanique, la microstructure observée après coup ou l'identifiant de la publication ne peuvent pas servir d'entrée (section 3.4).

1.4 Démarche suivie

Le projet est découpé en sept notebooks autonomes, exécutés dans l'ordre. La figure 1 présente leur enchaînement et la section du rapport qui correspond à chacun.

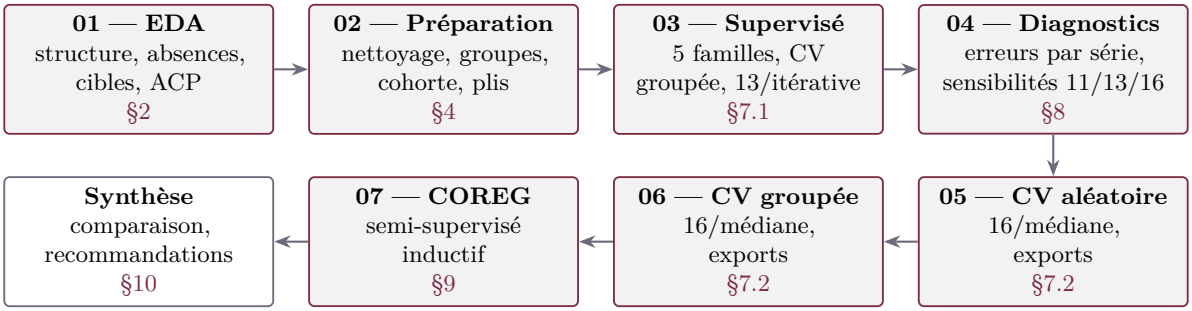


Figure 1. Enchaînement des étapes du projet. Chaque boîte correspond à un notebook du dossier `notebooks/` ; la référence indique la section du rapport qui le décrit. Le diagnostic (04) a motivé le passage de la configuration initiale 13 entrées/imputation itérative à la configuration 16 entrées/imputation médiane.

Trois principes ont guidé toutes les étapes :

1. **Traçabilité** : les fichiers bruts ne sont jamais modifiés ; chaque transformation conserve la valeur d'origine, son statut et sa provenance.
2. **Absence de fuite d'information** : toute transformation apprise (moyennes, médianes, encodage, imputation, choix d'hyperparamètres) est ajustée sur le seul ensemble d'entraînement du pli considéré.
3. **Honnêteté des conclusions** : chaque résultat est rattaché à sa population et à son protocole ; les limites sont explicitées plutôt que masquées.

Tableau 1. Organisation du dépôt du projet. Les données brutes, les données dérivées et les modèles sont produits localement et ne sont pas versionnés.

Élément	Rôle
`sujet.md`	Énoncé original, conservé tel quel
`specs/spec.md`	Décisions scientifiques et justifications (protocole actif)
`scripts/download_data.py`	Téléchargement autonome et vérification SHA-256 de l'archive Cambridge
`notebooks/01…07`	Code d'analyse, de préparation, d'entraînement et d'évaluation
`data/raw/`	Fichiers sources inchangés (`welddb.data`, `.info`, `.tex`)
`data/processed/`	Exports dérivés : table maître, provenance, plis, scores, prédictions
`models/`	188 pipelines complètes sérialisées avec leurs métadonnées
`reports/`	Rapports intermédiaires (01 à 16) et figures historiques
`tests/`	37 tests ciblés hors ligne
`rapport_latex/`	Le présent rapport et le script de génération de ses figures

1.5 Organisation du dépôt

À retenir

La qualité d'une soudure est représentée par quatre propriétés mécaniques mesurées. Le problème devient quatre **régressions supervisées** indépendantes, sur des données **partiellement étiquetées** — ce qui justifie une étude semi-supervisée complémentaire.

2 Analyse exploratoire des données

L'objectif de l'analyse exploratoire (notebook `notebooks/01_eda.ipynb`) est de *maîtriser* la base avant toute modélisation : savoir ce qui est mesuré, dans quelle unité, avec quelle fiabilité, et identifier les tâches de prétraitement nécessaires. Aucune imputation ni transformation apprise n'est appliquée à ce stade.

2.1 Source et structure de la base

La base publique *MAP_DATA_WELD* de l'université de Cambridge rassemble des dépôts de métal fondu de soudures d'acier issus de nombreuses publications [1, 3]. L'archive téléchargée par `scripts/download_data.py` est vérifiée par somme de contrôle SHA-256 ; le fichier de données `welddb.data` (empreinte `eb46df81…676ac1`) contient **1 652 lignes et 44 colonnes** séparées par des espaces, sans en-tête. La documentation source définit l'ordre et les unités des colonnes, résumés au tableau 2 (dictionnaire complet en annexe A).

Tableau 2. Familles de variables de la base et unités documentées.

Famille	Colonnes	Variables	Unité
Composition principale	12	C, Si, Mn, S, P, Ni, Cr, Mo, V, Cu, Co, W	% massique
Éléments traces	9	O, Ti, N, Al, B, Nb, Sn, As, Sb	ppm massiques
Paramètres de soudage	7	courant, tension, type de courant, polarité, apport thermique, température entre passes, procédé	A, V, –, –, kJ/mm, °C, –
Traitement thermique (PWHT)	2	température, durée	°C, h
Propriétés mécaniques	8	YS, UTS, allongement, réduction de section, température et énergie Charpy, dureté, FATT50	MPa, MPa, %, %, °C, J, kg/mm^2, ?
Microstructure	5	ferrite primaire, ferrite à seconde phase, ferrite aciculaire, martensite, agrégat ferrite-carbure	%
Identifiant	1	`weld_id` (référence de la source)	–

Les unités sont très hétérogènes : pourcentages massiques, ppm, ampères, volts, kJ/mm, degrés Celsius, heures, MPa, joules. Cette hétérogénéité impose une **standardisation** avant toute méthode sensible aux distances ou aux échelles (ACP, kNN, SVR, Ridge), comme nous le verrons en

section 4.6.

2.2 Statut des mesures : absence, censure, intervalles, annotations

La documentation précise que le symbole `N` signifie « valeur non rapportée » et **jamais zéro** [1]. En lisant toutes les colonnes comme du texte, nous avons distingué cinq statuts :

1. **nombre exact** : valeur numérique sans annotation (ce qui ne veut pas dire sans incertitude expérimentale) ;
2. **non rapporté** : symbole `N` ;
3. **censuré** : `<L`, valeur inférieure à une limite de détection L ;
4. **intervalle** : par exemple `150-200` pour une température entre passes ;
5. **annoté** : par exemple `67tot33res` pour l'azote (total/résiduel) ou `Hv10` pour un protocole de dureté Vickers.

La figure 2 montre trois situations très différentes. Le carbone, le silicium, le manganèse, l'apport thermique et le procédé sont renseignés sur toutes les lignes. À l'inverse, la microstructure, la dureté et FATT50 sont presque toujours absentes. Entre les deux, Ni, Cr, Mo, O, N, le courant et la tension sont partiellement renseignés. **Aucune ligne n'est complète sur les 44 colonnes** : supprimer les lignes incomplètes supprimerait toute la base. Le tableau 3 détaille les variables les plus concernées par la censure ou les annotations.

Tableau 3. Variables les plus concernées par les valeurs spéciales (fichier brut, 1 652 lignes).

Variable	Nombres exacts	Censurées	Intervalles/annotations	Non rapportées
Aluminium	502	403	0	747
Vanadium	620	308	0	724
Bore	85	419	0	1 148
Niobium	453	299	0	900
Azote	1 183	0	59	410
Température entre passes	1 614	0	38	0
Dureté	80	0	58	1 514
FATT50	31	0	0	1 621

Pour l'aluminium, 44,5 % des valeurs rapportées sont censurées ; pour le bore, 83,1 %. Un histogramme calculé sur les seuls nombres exacts décrirait donc un sous-ensemble sélectionné. Les annotations de dureté (`Hv5`, `Hv10`, `Hv30`) renvoient à des protocoles Vickers différents : les nombres annotés vont de 143 à 467, alors que les valeurs non annotées s'arrêtent à 265.

2.3 Identifiants, répétitions et séries

Les 1 652 lignes portent **1 490 identifiants distincts** ; 91 identifiants apparaissent plusieurs fois et concernent 253 lignes (par exemple un même dépôt testé en Charpy à plusieurs températures). Aucune ligne n'est un doublon exact sur les 44 colonnes, mais **quatre lignes répètent exactement une autre ligne lorsqu'on ignore l'identifiant** (indices bruts 393, 423, 425 et 1 434, qui dupliquent 333, 363, 365 et 1 418).

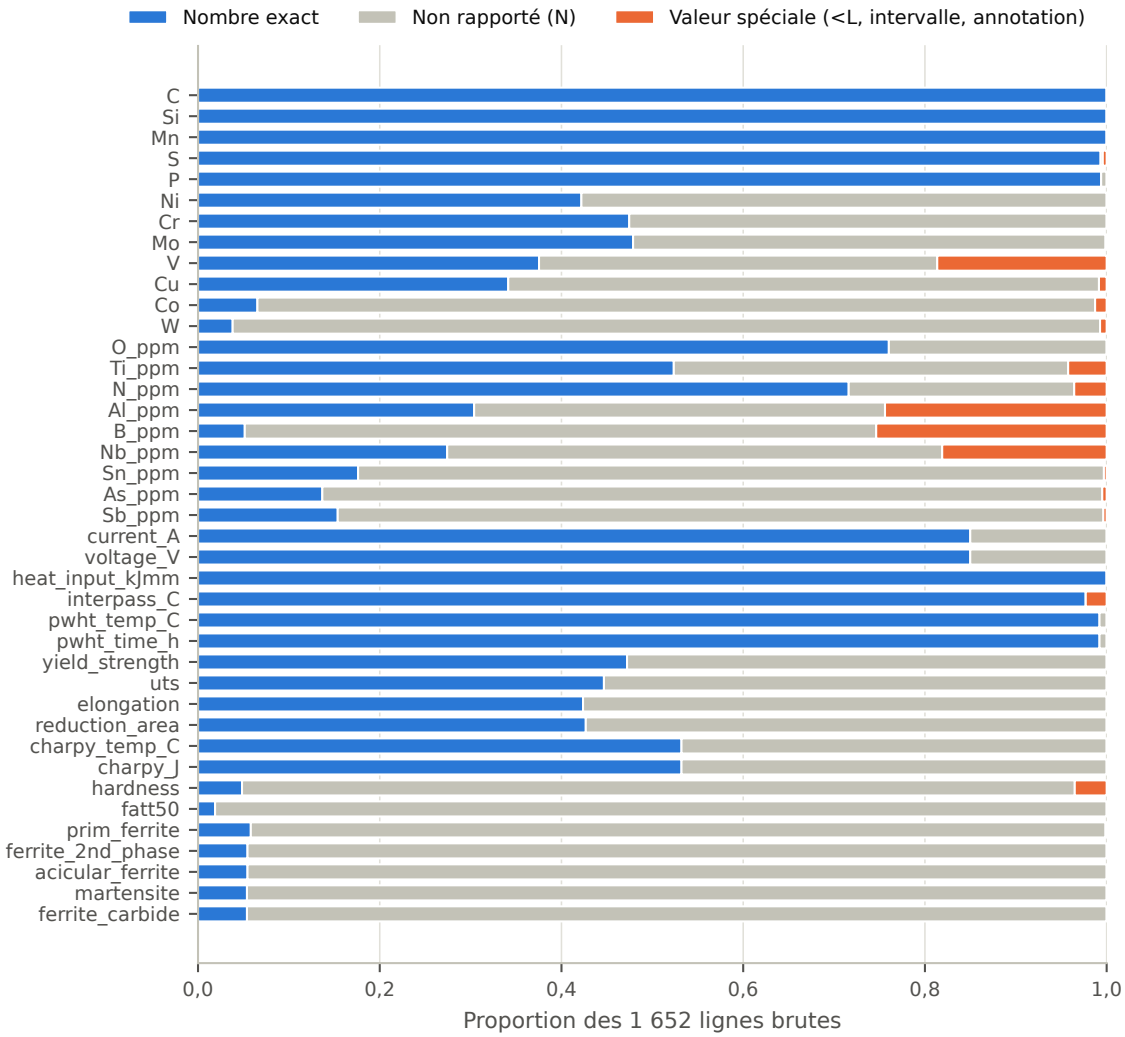


Figure 2. Statut des 1 652 valeurs de chaque variable numérique dans le fichier brut. Les valeurs spéciales (censures, intervalles, annotations) sont de l'information rapportée : elles ne doivent être confondues ni avec une absence ni avec un nombre exact.

Surtout, les identifiants révèlent des **séries expérimentales** : par exemple `Evans-Ni/CMn-1990/1991-0Aaw` et `Evans-Ni/CMn-1990/1991-0Aawch` appartiennent à la même étude, qui fait varier un seul élément d'alliage à procédé et protocole constants. Les observations d'une même série partagent la composition de base, le matériel, les opérateurs et le laboratoire d'essai.

Précaution d'interprétation

Si l'on mélange aléatoirement les lignes, une soudure de la validation a presque toujours une « sœur » de la même série dans l'entraînement. Le score obtenu mesure alors la capacité à *interpoler à l'intérieur de séries connues*, et non à prédire une nouvelle étude. Cette observation motive la validation par groupes décrite en section 6.

2.4 Distributions et ordres de grandeur

La figure 3 présente les distributions de neuf variables après retrait des quatre doublons, sur les seuls nombres exacts ; le tableau 4 donne les ordres de grandeur correspondants.

Tableau 4. Ordres de grandeur des principales entrées (nombres exacts, lignes dédupliquées).

Variable	Unité	Effectif	Minimum	Médiane	Maximum
Carbone	% mass.	1 648	0,029	0,074	0,18
Silicium	% mass.	1 648	0,04	0,32	1,14
Manganèse	% mass.	1 648	0,27	1,27	2,25
Nickel	% mass.	696	0	0,0675	3,5
Chrome	% mass.	783	0	0,53	10,2
Molybdène	% mass.	790	0	0,34	1,5
Oxygène	ppm	1 253	132	423	1 650
Azote (non annoté)	ppm	1 180	21	83	552
Courant	A	1 400	115	170	900
Tension	V	1 400	11,5	21	75,36
Apport thermique	kJ/mm	1 648	0,6	1	7,9
Température entre passes	°C	1 610	20	200	300
Température PWHT	°C	1 635	0	250	760
Durée PWHT	h	1 635	0	2	24
Température d'essai Charpy	°C	877	−114	−40	188

Plusieurs observations orientent le prétraitement :

— **Distributions multimodales.** Le manganèse présente plusieurs pics ; le chrome forme des groupes autour de faibles teneurs, de 2 % et de 9 %. Ces structures traduisent un *mélange de familles d'aciers et de séries expérimentales* plutôt qu'une loi unique.

— **Régimes de procédé.** Les 30 lignes entre 850 et 900 A appartiennent toutes au procédé sous flux `SA`, alors que le courant médian est de 170 A. Ces valeurs sont cohérentes avec le procédé et ne sont pas des anomalies.

— **Réglages répétés.** Les pics d'apport thermique (1 kJ/mm), de température entre passes (200 °C) et de PWHT correspondent à des réglages standard répétés.

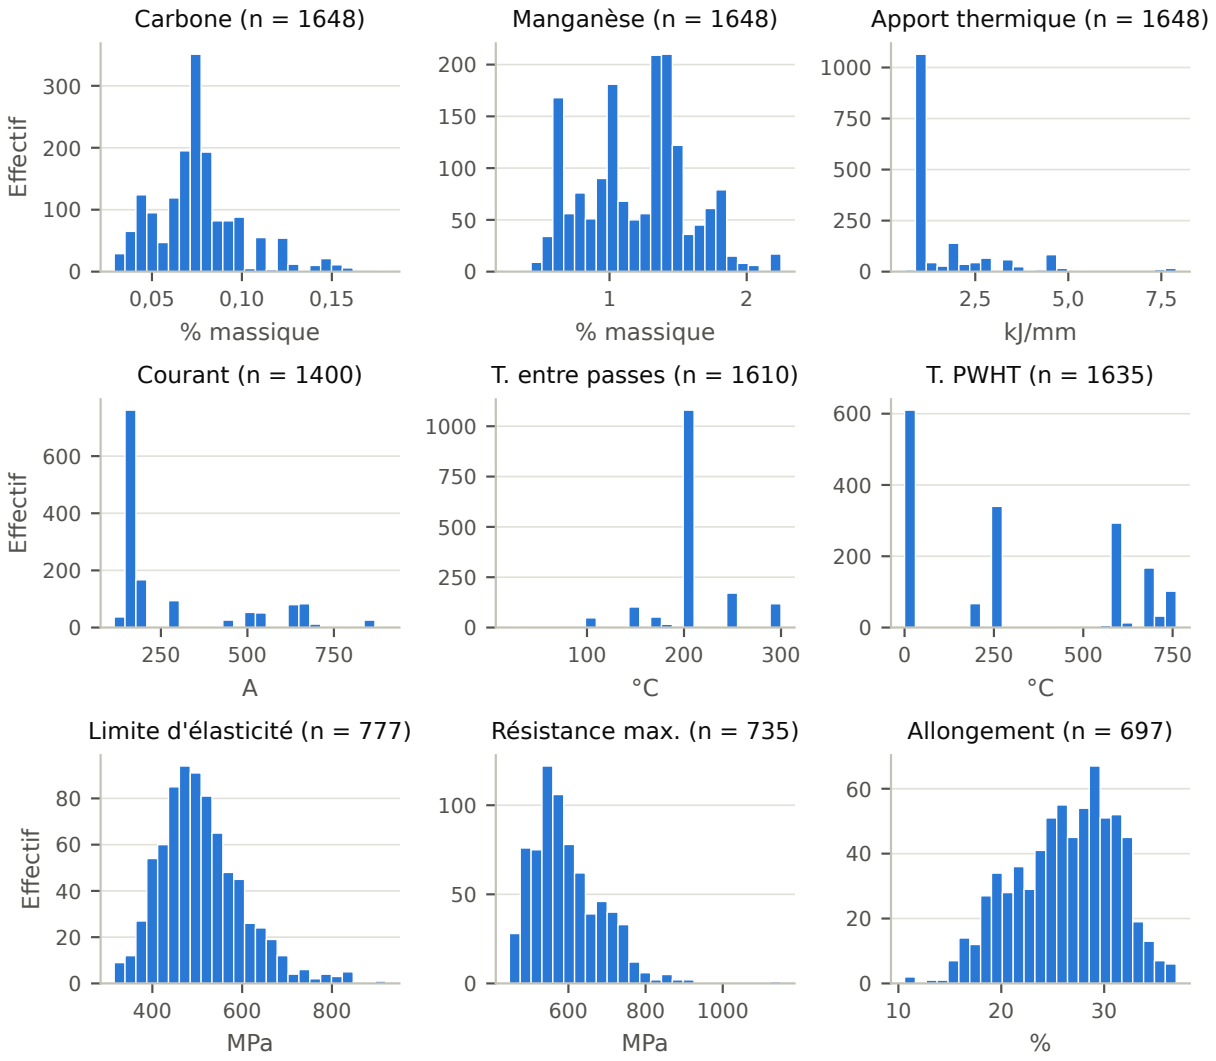


Figure 3. Distributions de compositions, de paramètres de soudage et de propriétés mécaniques (nombres exacts, 1 648 lignes dédupliquées ; n = effectif disponible). Aucune valeur extrême n'est supprimée et aucune unité n'est convertie.

— **Zéros PWHT.** 610 lignes ont le couple (0 °C, 0 h), qui code vraisemblablement un état brut de soudage. Ces zéros mesurés sont conservés tels quels.

— **Valeurs élevées regroupées.** Les plus fortes teneurs en soufre (0,14 %) et phosphore (0,25 %) apparaissent ensemble dans dix lignes d'une même série (`Mart-G…`) : cela justifie un examen de provenance, pas une suppression automatique.

— **Cibles.** La limite d'élasticité et la résistance maximale sont unimodales avec une queue vers les fortes valeurs ; l'allongement est concentré entre 25 et 30 %.

Décision et justification

Les valeurs extrêmes sont **conservées** : leur amplitude seule ne démontre pas une erreur, et elles appartiennent souvent à un procédé ou à une série identifiable. Supprimer ces points réduirait artificiellement la diversité des conditions que le modèle doit apprendre.

2.5 Les absences dépendent du procédé

Les absences ne sont pas réparties au hasard. La figure 4 croise le taux de valeurs non rapportées avec le procédé de soudage (après regroupement des seuls synonymes documentés `ShMA`→`MMA` et `SMA`→`SA`).

On y lit par exemple que l'oxygène n'est jamais rapporté pour les procédés `SAA`, `GTAA` et `GMAA`, que l'azote manque toujours pour `NGSAW` et `NGGMA`, que Ni et Cr manquent dans 91 % des lignes `TSA`, ou que l'énergie Charpy manque dans 77 % des lignes `SA`. En statistique des données manquantes, ces absences ne sont donc pas « complètement aléatoires » (MCAR) [4] : elles dépendent au moins du procédé et de la source.

Précaution d'interprétation

Une valeur imputée n'est pas une mesure. Quand l'absence dépend de la source, l'imputation peut confondre une composition réelle avec la composition « typique » des autres séries. C'est pourquoi l'imputation sera ajustée dans chaque pli d'entraînement, comparée entre plusieurs méthodes, et ses limites explicitement testées (section 8.4).

2.6 Cohérence physique et unités douteuses

Les bornes physiques élémentaires sont respectées : concentrations positives, fractions entre 0 et 100 %, températures au-dessus du zéro absolu. Sur les 714 lignes où les deux résistances sont présentes, **aucune limite d'élasticité ne dépasse la résistance maximale**. Ce contrôle ne démontre cependant pas l'homogénéité des unités. Plusieurs indices demandent un retour aux sources :

— **Aluminium** : dix lignes de la famille `EPRI-TR-101394s` contiennent 0,004 à 0,014 dans une colonne annoncée en ppm ; en % massique, cela correspondrait à 40–140 ppm.

— **Étain, arsenic, antimoine** : les mêmes 90 lignes ont simultanément des valeurs positives inférieures à 1 ppm, motif typique d'une saisie en % massique.

— **Titane et vanadium** : une valeur de 0,5 ppm de titane, des limites `<0.01` pour Ti/Al (famille `PantK-1990`) et `<5` pour V dans une colonne en % massique.

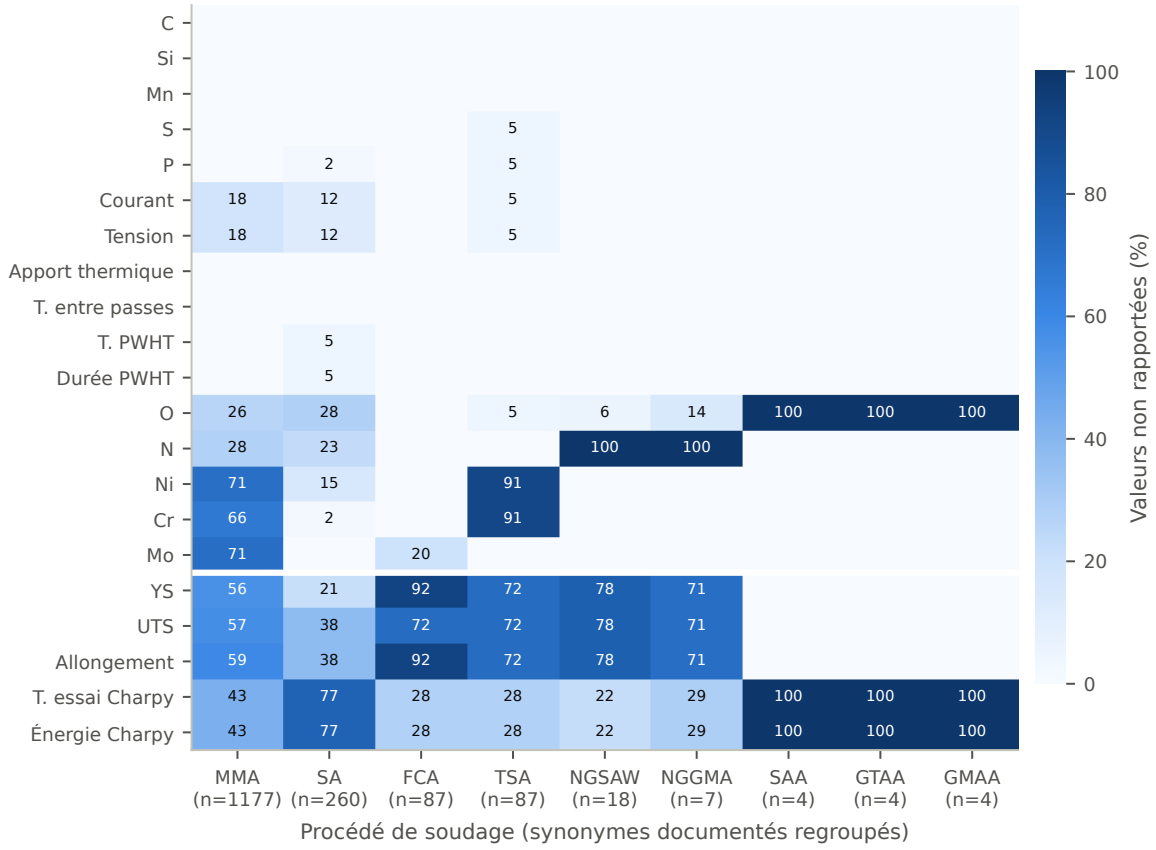


Figure 4. Part de valeurs non rapportées (%) par procédé, pour les 16 entrées numériques retenues (haut) et les mesures cibles (bas), sur les 1 648 lignes dédupliquées. Cases vides : moins de 0,5 % d'absences.

Rappelons que 1 % massique = 10 000 ppm : multiplier toutes les petites valeurs par 10 000 serait une hypothèse non vérifiée. Une normalisation statistique ne corrigerait pas non plus une erreur d'unité. Ces cellules sont donc mises en quarantaine (section 4.2). L'audit des publications (section 8.8) a d'ailleurs confirmé qu'au moins une source (Svensson–Gretoft) exprime Ti/Al/Sn/As/Sb en % massique.

2.7 Propriétés mesurées et relations entre cibles

Le tableau 5 recense les propriétés mécaniques candidates. Toutes sont partiellement renseignées : chaque cible n'est disponible que pour 42 à 53 % des lignes.

Tableau 5. Propriétés mécaniques candidates (nombres exacts du fichier brut).

Propriété	Mesures	Minimum	Médiane	Maximum
Limite d'élasticité (MPa)	780	315	495	920
Résistance maximale (MPa)	738	447	575,5	1 151
Allongement (%)	700	10,6	26,8	37
Réduction de section (%)	705	17	75	83
Énergie Charpy (J)	879	3	100	270
Dureté non annotée (kg/mm^2)	80	–	–	265
FATT50 (unité non précisée)	31	–	–	–

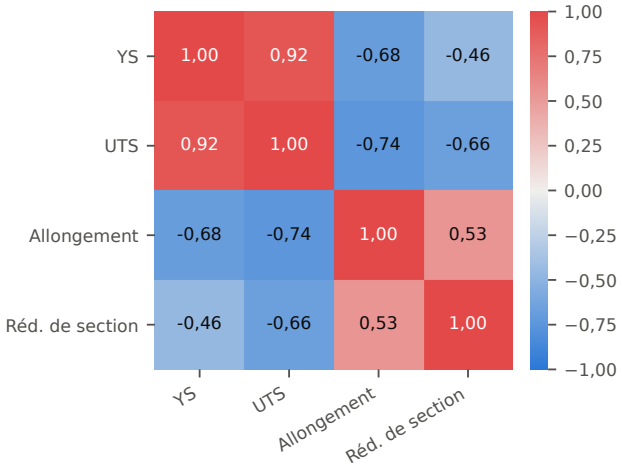


Figure 5. Corrélations de Pearson entre propriétés de traction, calculées sur les paires observées (lignes dédupliquées). Bleu : corrélation négative ; rouge : positive. Cette matrice décrit des dépendances par paires ; ce n'est pas une ACP.

La figure 5 montre que YS et UTS sont très corrélées ($r = 0{,}915$), tandis que l'allongement leur est opposé ($r = -0{,}680$ avec YS, $-0{,}738$ avec UTS) : un métal plus résistant est en moyenne moins ductile. Ces corrélations n'autorisent pas à remplacer une cible par une autre : 0,915 laisse une part substantielle de variation propre à chacune, et résistance et ductilité sont des informations complémentaires.

L'énergie Charpy doit toujours être lue avec sa température d'essai (figure 6). Sur 877 couples exacts dédupliqués, **355 énergies valent exactement 100 J et 118 valent 28 J**. Ces valeurs correspondent à des critères classiques de transition ductile-fragile : certaines publications rapportent la *température* à laquelle l'énergie atteint 100 J ou 28 J, plutôt qu'une énergie mesurée à

une température choisie [5]. Les deux protocoles produisent des points d'apparence identique dans la base.

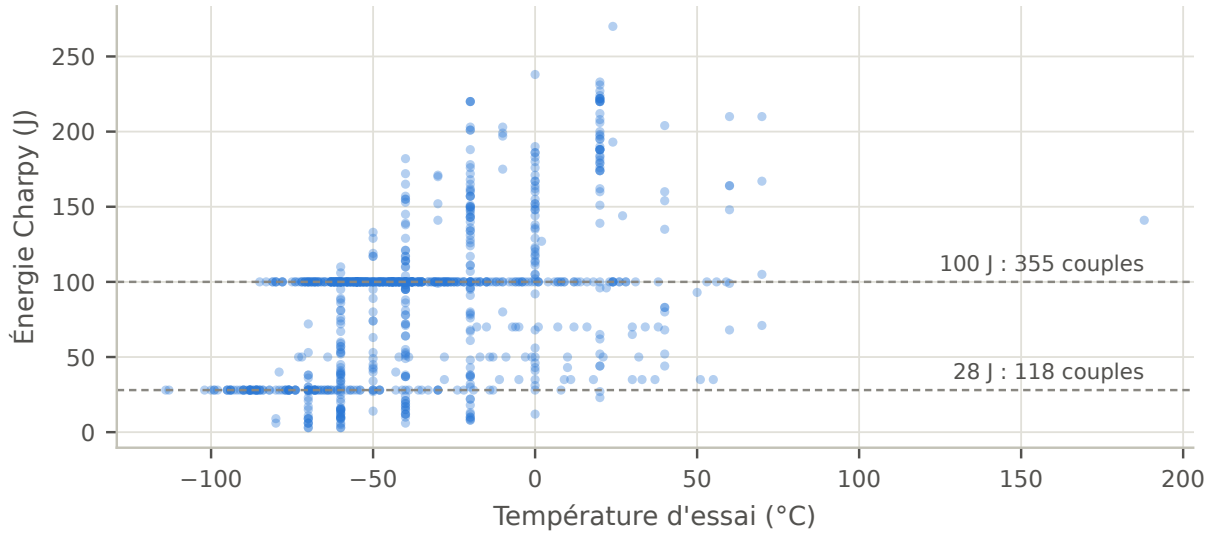


Figure 6. Couples (température d'essai, énergie Charpy) exacts. Les lignes horizontales à 28 J et 100 J concentrent 54 % des points, signature probable de températures de transition plutôt que de mesures à température imposée.

2.8 Analyse en composantes principales descriptive

L'énoncé demande d'appliquer une ACP pour développer une intuition sur le problème. L'ACP cherche les directions orthogonales de l'espace des entrées qui expliquent le plus de variance [6]. Comme les unités sont différentes, chaque variable est d'abord **standardisée** (moyenne nulle, écart-type unité) ; sinon le courant (centaines d'ampères) écraserait le carbone (centièmes de pourcent).

Décision et justification

L'ACP porte sur les **1 339 lignes dédupliquées dont les onze entrées de base sont des nombres exacts complets** (C, Si, Mn, S, P, courant, tension, apport thermique, température entre passes, température et durée PWHT), **sans imputation**. Ainsi, la structure observée n'est pas fabriquée par des valeurs reconstruites. En contrepartie, cette sous-population peut différer de la base entière, et l'ACP reste descriptive : elle n'est réutilisée ni pour entraîner ni pour évaluer les modèles.

Les deux premiers axes expliquent **27,02 %** et **19,03 %** de la variance, soit 46,05 % cumulés ; trois axes en expliquent 61,26 % et il faut huit axes pour dépasser 95 % (figure 7a). L'information est donc *répartie* sur de nombreuses directions. L'interprétation des axes (figure 7c) est néanmoins éclairante :

— **PC1 — « énergie du procédé ».** Les coefficients les plus forts sont l'apport thermique (0,52), le courant (0,52) et la tension (0,46). Cet axe sépare nettement le soudage manuel `MMA`, à faible courant, du soudage sous flux `SA`, à fort courant (figure 7b).

— **PC2 — « impuretés et traitement thermique ».** Le phosphore (0,47), le soufre (0,45),

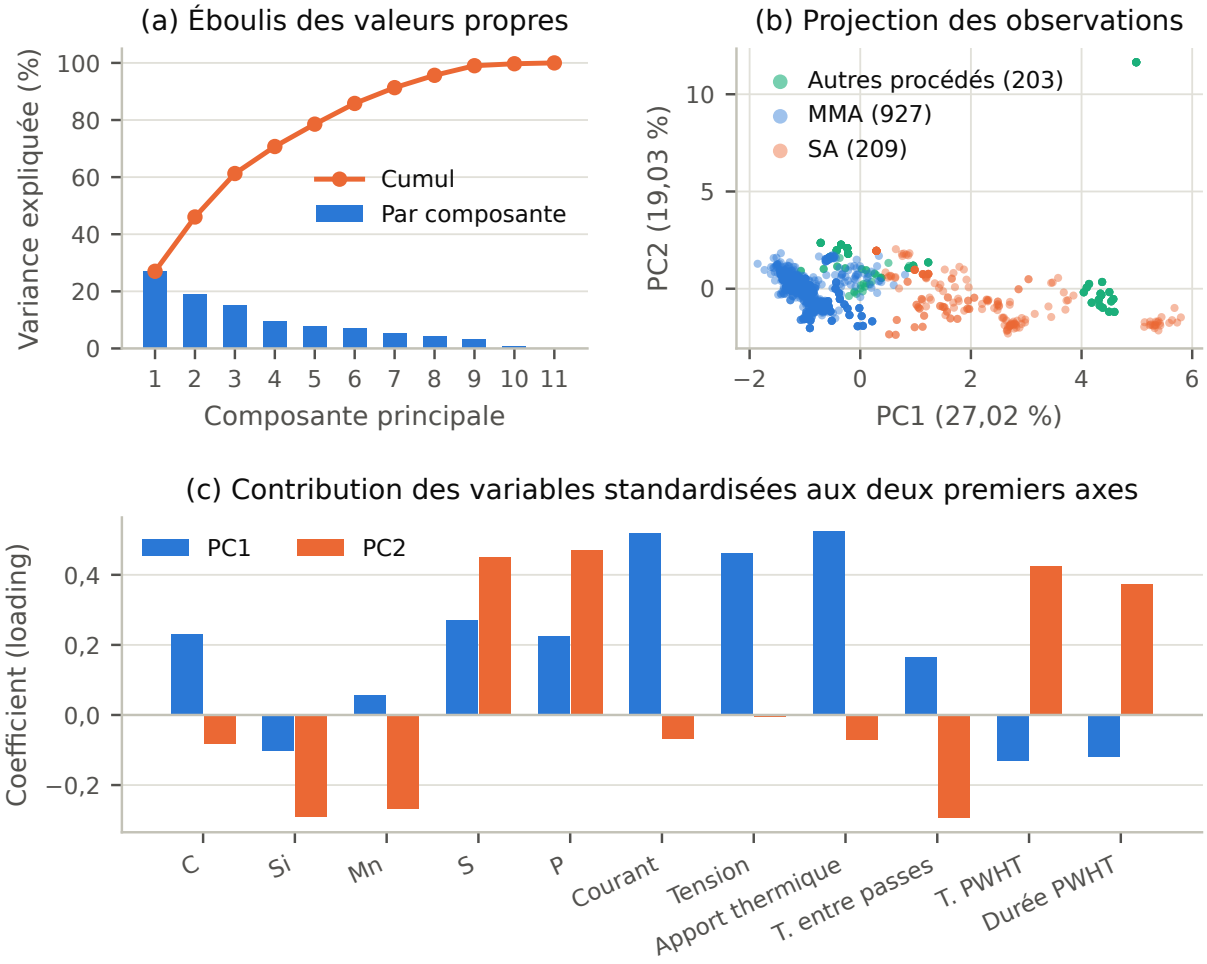


Figure 7. ACP standardisée des onze entrées complètes (1 339 lignes). (a) Variance expliquée par composante et cumul. (b) Projection sur les deux premiers axes, colorée par procédé. (c) Coefficients des variables sur les deux premiers axes.

la température (0,43) et la durée (0,37) du PWHT s'opposent au silicium (−0,29), à la température entre passes (−0,29) et au manganèse (−0,27).

La projection montre des amas compacts correspondant à des séries et des procédés, plutôt qu'un nuage continu. L'ACP confirme ainsi, du point de vue des entrées, la structure en séries identifiée par les identifiants.

Décision et justification

Aucune ACP n'est incluse dans les pipelines prédictives : les deux premiers axes ne résument que 46 % de la variance, les forêts aléatoires n'en ont pas besoin, et une réduction de dimension aurait dû être réapprise dans chaque pli. Une ACP ajustée sur toute la base puis réutilisée en validation constituerait une fuite d'information.

2.9 Bilan de l'analyse exploratoire

À retenir

- La base est une **compilation de séries expérimentales** : observations apparentées, compositions multimodales, procédés déséquilibrés (`MMA` majoritaire).
- `N` signifie **non rapporté** ; censures, intervalles et annotations sont des informations à conserver, pas à confondre avec des nombres exacts.
- Les absences **dépendent du procédé et de la source** ; aucune ligne n'est complète.
- Quelques cellules ont une **unité douteuse** ; elles doivent être isolées sans conversion conjecturale.
- Les cibles sont partiellement renseignées et corrélées sans être interchangeables ; l'énergie Charpy mélange probablement plusieurs protocoles.
- L'ACP met en évidence un axe « énergie du procédé » et un axe « impuretés/PWHT », et confirme une structure en amas liée aux séries.

3 Variables cibles et stratégie de prédiction

3.1 Quelles variables représentent la qualité ?

À partir de l'EDA, nous retenons comme **cibles principales** les trois propriétés de traction — YS, UTS et allongement — et comme **cible exploratoire** l'énergie Charpy à température d'essai connue. Le tableau 6 justifie ce choix et donne les effectifs à chaque étape du filtrage décrit en section 4.

Tableau 6. Cibles retenues et effectifs de labels. « Cohorte » désigne la population de modélisation de 1 555 lignes (section 4.4) ; « Groupes » le nombre de séries inférées portant au moins un label.

Cible	Unité	Brut	Dédupl.	Cohorte	Groupes	Rôle et justification
YS	MPa	780	777	706	40	Principale : propriété de dimensionnement, bonne couverture
UTS	MPa	738	735	677	39	Principale : résistance, complémentaire de YS
Allongement	%	700	697	631	34	Principale : ductilité, opposée à la résistance
Énergie Charpy*	J	879	877	861	24	Exploratoire : protocoles hétérogènes (section 3.3)
Réduction de section	%	705	702	635	–	Complémentaire, non entraînée
Dureté	kg/mm^2	138	–	–	–	Écartée : 80 valeurs exactes, protocoles Vickers mélangés
FATT50	?	31	–	–	–	Écartée : 31 valeurs, unité non documentée

Les distributions des cibles dans la cohorte sont résumées au tableau 7.

Tableau 7. Statistiques des cibles dans la cohorte de modélisation.

Cible	Labels	Médiane	Minimum	Maximum
YS (MPa)	706	496,0	315,0	920,0
UTS (MPa)	677	576,0	447,0	1 151,0
Allongement (%)	631	26,6	10,6	36,4
Énergie Charpy* (J)	861	100,0	3,0	270,0

3.2 Pourquoi des régressions séparées ?

Dans la cohorte, seules **609 lignes** renseignent simultanément les trois propriétés de traction et **141** les quatre cibles. Un modèle multi-sorties exigeant les trois propriétés de traction perdrait 14 % des labels de YS ; exiger les quatre cibles ne conserverait que 16 à 22 % des labels selon la cible. Il faudrait sinon imputer des cibles, ce qui reviendrait à entraîner sur des valeurs inventées.

Décision et justification

Chaque cible dispose de **son propre modèle et de ses propres lignes d'entraînement** : on apprend la cible t sur toutes les lignes qui renseignent t, sans exiger les autres. Une cible absente reste inconnue et **n'est jamais imputée**. Aucune propriété mécanique n'est utilisée comme entrée pour en prédire une autre, car elle ne serait pas disponible au moment d'estimer une soudure non encore testée.

3.3 Le cas particulier de l'énergie Charpy

Deux formulations sont possibles pour la ténacité : prédire l'énergie E à une température T donnée, ou prédire la température $T_{100\,\mathrm{J}}$ (ou $T_{28\,\mathrm{J}}$) à laquelle l'énergie atteint un seuil. Nous retenons la première, $E(T)$ **avec la température d'essai en entrée**, formulation utilisée par des travaux de référence sur cette famille de données [3, 7]. La température n'est jamais reconstruite : seules les 861 lignes de la cohorte où elle est connue sont utilisées.

Précaution d'interprétation

La documentation définit bien deux colonnes distinctes (température en °C, énergie en J), mais pas le protocole de chaque ligne. Une partie des couples correspond probablement à des températures de transition à 28 ou 100 J (figure 6), une autre à des courbes $E(T)$ complètes. Aucun seuil 28/100 J ne sert à exclure automatiquement des lignes : cette tâche est traitée comme **exploratoire** et les sources ont été auditées a posteriori (section 8.8).

3.4 Entrées autorisées et entrées exclues

Une variable n'est utilisée en entrée que si elle serait connue *avant* l'essai mécanique, dans un usage réaliste du modèle. Le tableau 8 résume cette règle.

Tableau 8. Entrées autorisées et exclues des modèles.

Statut	Variables et raison
Autorisées	Composition (C, Si, Mn, S, P, Ni, Cr, Mo, O, N), courant, tension, apport thermique, température entre passes, température et durée PWHT, procédé ; pour Charpy uniquement : température d'essai.
Exclues (fuite)	Autres propriétés mécaniques, dureté, FATT50 : mesurées après l'essai, indisponibles pour une soudure nouvelle.
Exclues (fuite)	Identifiant, série, groupe, numéro de pli, drapeaux d'éligibilité : ils renseigneraient sur la source et non sur la soudure.
Exclues (disponibilité)	Microstructure : observée après soudage, 89 à 98 valeurs par colonne seulement.
Exclues (fiabilité)	V, Cu, Co, W, Ti, Al, B, Nb, Sn, As, Sb : couverture faible, censures nombreuses ou unités douteuses. Cette exclusion ne signifie pas que ces éléments n'ont pas d'effet métallurgique.
Non utilisées	Type de courant et polarité : conservés dans la table maître (modalité `missing` si non rapportés), non retenus dans les schémas d'entrées.

3.5 Stratégie d'ensemble

La stratégie de prédiction se déroule en cinq temps :

1. **Construire une population fiable** : nettoyage déterministe, déduplication, groupes de séries et cohorte avec peu d'entrées manquantes (section 4).
2. **Fixer une référence minimale** : prédire la médiane de y du train, sans utiliser $\boldsymbol{x}$. Tout modèle doit faire mieux.
3. **Comparer des familles de modèles vues en cours**, du linéaire régularisé (Ridge) aux méthodes non linéaires (SVR, forêt aléatoire, kNN), avec réglage des hyperparamètres par validation croisée **imbriquée** (sections 5 et 6).
4. **Évaluer selon deux usages** : interpolation dans des séries connues (découpage aléatoire) et transfert à de nouvelles séries (découpage groupé).
5. **Exploiter les lignes non étiquetées** avec une méthode semi-supervisée (COREG), comparée à son exact pendant supervisé.

Les lignes de la cohorte sans la cible forment le **pool non étiqueté** de cette cible : 849 lignes pour YS, 878 pour UTS et 924 pour l'allongement. Pour Charpy, **aucune** ligne de la cohorte n'a une température d'essai connue sans énergie : le pool naturel est vide, et aucune température n'est fabriquée pour en créer un.

À retenir

Quatre régressions indépendantes : YS, UTS, allongement (principales) et énergie Charpy $E(T)$ (exploratoire). Les entrées sont limitées à ce qui est connu avant l'essai ; aucune cible n'est imputée ni utilisée comme entrée. Les lignes sans cible alimentent l'étude semi-supervisée pour les trois cibles de traction.

4 Préparation des données

La préparation (notebook `notebooks/02_data_preparation.ipynb`) transforme le fichier brut en une table maître traçable, définit les groupes, la cohorte et les plis, puis fournit le prétraitement qui sera appris *à l'intérieur* de chaque entraînement. Elle a d'abord été prototypée, auditée à deux reprises (rapports 06 et 07 du dépôt), puis migrée dans ce notebook autonome ; les huit exports migrés reproduisent exactement les exports audités.

4.1 Deux niveaux de traitement

Il est essentiel de distinguer deux types d'opérations :

Nettoyage déterministe (global)
règles fixées *a priori*, qui ne dépendent d'aucune statistique apprise : interpréter `N`, remplacer une censure par une valeur conventionnelle, isoler une unité douteuse. Elles peuvent être appliquées à toute la base sans fuite d'information.

Prétraitement appris (dans les plis)
opérations qui estiment des paramètres sur les données : moyennes et écarts-types, médianes, catégories connues, modèles d'imputation. Elles sont **réajustées sur chaque ensemble d'entraînement**, puis appliquées telles quelles à la validation correspondante.

Intuition

Si l'on calculait la médiane d'imputation ou la moyenne de standardisation sur toute la base, la validation « verrait » indirectement ses propres valeurs à travers ces statistiques : le score serait légèrement optimiste. Ajuster ces statistiques dans le train seulement reproduit la situation réelle, où une nouvelle soudure arrive après l'entraînement.

4.2 Nettoyage déterministe

Le tableau 9 récapitule chaque règle et sa justification. Le résultat est une **table maître de 1 652 lignes** (dont quatre alias marqués) et un fichier de **provenance de 66 080 cellules numériques** (1 652 lignes × 40 colonnes numériques) qui conserve, pour chaque cellule, le jeton brut, son statut, ses bornes, l'opérateur de censure, l'annotation éventuelle, le drapeau de revue et la valeur retenue. Aucune cible observée n'est modifiée.

Précaution d'interprétation

Les choix $L/2$ et milieu d'intervalle sont des *approximations déterministes*, pas des mesures. Ils concernent surtout des éléments absents des schémas d'entrées retenus (Al, B, Nb, V). Pour les 16 entrées retenues, seules 47 cellules du fichier brut sont concernées : 38 intervalles de température entre passes, 7 censures de soufre et 2 de molybdène (les 59 azotes annotés étant indisponibles). Le statut d'origine reste disponible pour toute analyse de sensibilité.

4.3 Groupes : des séries expérimentales inférées

Pour évaluer le transfert à de nouvelles séries, il faut d'abord les définir. La base ne fournit pas de numéro de publication ; les groupes sont donc **inférés des identifiants**, de manière conservatrice :

Tableau 9. Règles de nettoyage déterministe et justification.

Situation	Règle appliquée	Justification
Lecture	44 champs lus comme texte ; identifiant brut `raw_row_id` stable (0 à 1 651)	Ne rien perdre avant d'avoir classé chaque jeton
`N` (non rapporté)	Valeur manquante (NaN), jamais zéro	Définition de la documentation source
Nombres exacts, zéros, extrêmes	Conservés	Une valeur extrême n'est pas une erreur démontrée
Censure `<L` sans doute d'unité	$L/2$, avec statut, opérateur et borne conservés	Approximation conventionnelle, explicitement signalée comme telle
Intervalle `a-b`	Milieu $(a+b)/2$, bornes conservées	38 températures entre passes `150-200` $\rightarrow$ 175 °C
Unité douteuse	NaN, sans conversion ; 322 cellules : Al 26, Ti 17, V 9, Sn/As/Sb 90 chacun	Seule la source peut confirmer l'unité (section 2.6)
Azote annoté (`tot`/`res`)	59 annotations hors de N principal, extraction lexicale conservée	Sens total/résiduel non comparable aux autres valeurs
Dureté	Valeur et protocole Vickers séparés	Protocoles non regroupés automatiquement
Procédé	Seuls `ShMA`$\rightarrow$`MMA` et `SMA`$\rightarrow$`SA`	Synonymes documentés ; les autres procédés restent distincts
Courant et polarité	`N` $\rightarrow$ modalité `missing` ; aucune déduction DC/AC	Ne pas inventer une catégorie
Doublons hors identifiant	4 occurrences excédentaires exclues de la cohorte et des plis ; alias conservés	Éviter qu'une même observation soit en train et en validation
PWHT	13 lignes PWHT manquant conservées ; couples (0, 0) conservés	Le sens métallurgique exact du zéro n'est pas affirmé

1. préfixe de l'identifiant jusqu'à l'année (`Evans-Ni/CMn-1990/1991-0Aaw` → `Evans-Ni/CMn-1990`) ;
2. familles explicites de rapports ou de lettres (par exemple `EvansLetter`) ;
3. préfixe non daté, ou identifiant exact en dernier recours ;
4. les doublons bruts relient leurs séries respectives.

On obtient **47 groupes** sur les 1 648 lignes dédupliquées. Les variantes orthographiques d'auteurs (`Ga&K`/`Gar&K`, `Kocak`) ne sont pas fusionnées dans le protocole actif. Ces groupes sont des *séries inférées*, pas des publications vérifiées : une série peut regrouper plusieurs conditions de soudage (section 8.5).

4.4 Cohorte de modélisation

Ni, Cr et Mo sont absents dans plus de la moitié des lignes ; d'autres entrées le sont plus rarement. Nous définissons une cohorte qui limite le nombre d'entrées à reconstruire tout en conservant un maximum de séries :

Décision et justification

Cohorte principale : lignes non dupliquées ayant **au plus deux entrées numériques indisponibles parmi les 13 entrées du schéma A1_13** (tableau 10). Elle compte **1 555 lignes réparties en 44 groupes** ; trois séries (`Cunh-1982`, `EvHtIp1979`, `Natsume-1990`) sortent entièrement. Les seuils alternatifs ≤ 1 et ≤ 3 donneraient 1 087 et 1 603 lignes, 34 et 46 groupes, 501 et 748 labels de YS : le seuil 2 est un compromis d'ingénierie entre couverture et quantité d'imputation, pas une garantie de fiabilité.

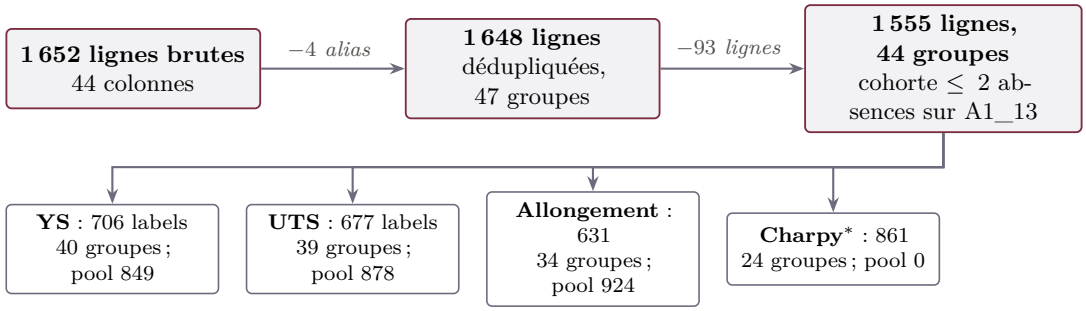


Figure 8. Du fichier brut aux populations de modélisation. Chaque cible utilise les lignes de la cohorte qui la renseignent ; les autres lignes de la cohorte forment son pool non étiqueté (vide pour Charpy, faute de température d'essai connue sans énergie).

Dans la cohorte, **607 lignes** ont au moins une entrée absente parmi les 13, soit **1 075 cellules**. La table maître conserve ces NaN : aucune table globalement imputée n'est utilisée par les modèles. Parmi les lignes dédupliquées, 105 n'ont aucune des cinq sorties traction/Charpy (99 dans la cohorte) ; elles sont conservées comme exemples non étiquetés.

4.5 Schémas d'entrées

Trois schémas emboîtés ont été définis et comparés (tableau 10). Le schéma de départ A1_13 privilégiait des entrées bien renseignées ; l'extension A1b_16 ajoute Ni, Cr et Mo, éléments d'alliage

métallurgiquement importants mais souvent absents (figure 9). Passer de 13 à 16 entrées **ajoute des colonnes, pas des lignes** : la cohorte n'est pas refiltrée.

Tableau 10. Schémas d'entrées numériques ; le procédé catégoriel est ajouté à chacun.

Schéma	Entrées	Variables
A0_11	11	C, Si, Mn, S, P, courant, tension, apport thermique, température entre passes, température et durée PWHT
A1_13	13	A0_11 + oxygène et azote
A1b_16	16	A1_13 + nickel, chrome et molybdène

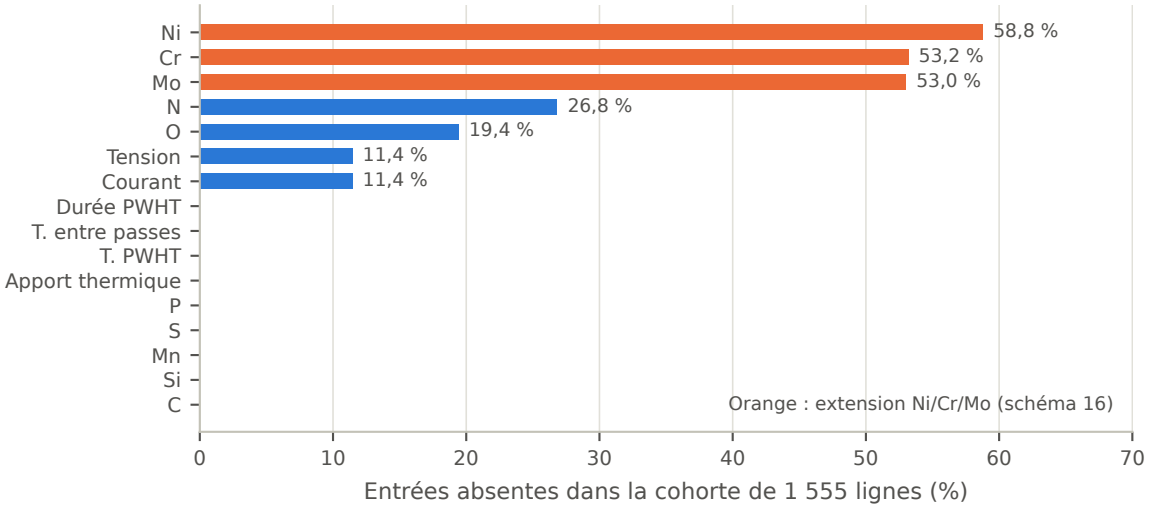


Figure 9. Part d'entrées absentes dans la cohorte de 1 555 lignes pour les 16 entrées numériques. Ni, Cr et Mo manquent dans plus de la moitié des lignes.

4.6 Normalisation : pourquoi standardiser ?

Chaque entrée numérique est standardisée avec la moyenne μ_j et l'écart-type σ_j calculés sur les valeurs *observées* du train :

$$z_{ij} = \frac{x_{ij} - \mu_j^{\text{train}}}{\sigma_j^{\text{train}}}. \tag{2}$$

Cette étape est indispensable pour les méthodes fondées sur des distances ou des normes : le kNN, la SVR à noyau RBF (dont le noyau $\exp(-\gamma\|\boldsymbol{x}-\boldsymbol{x}'\|^2)$ dépend des échelles) et la régression Ridge (dont la pénalité $\lambda\|\boldsymbol{\beta}\|^2$ traite tous les coefficients de la même manière). Elle est sans effet sur les partitions d'une forêt aléatoire, mais elle est conservée pour que toutes les familles partagent exactement la même représentation. Le procédé est encodé en *one-hot* sur les catégories vues dans le train ; une catégorie inconnue devient un vecteur nul. Pour la SVR uniquement, la cible y est aussi standardisée dans le train, puis les prédictions sont remises dans leur unité physique.

4.7 Imputation des entrées manquantes

Deux méthodes d'imputation ont été mises en œuvre, toutes deux **ajustées dans chaque train** et appliquées aux seules *entrées* :

Médiane
chaque valeur manquante reçoit la médiane de la colonne dans le train. Simple et stable, elle ignore les relations entre variables.

Itérative
(*chained equations*) [8] chaque colonne incomplète est régressée sur les autres par une régression bayésienne ridge (`IterativeImputer` + `BayesianRidge`), en alternant jusqu'à convergence : initialisation médiane, ordre ascendant, au plus 100 itérations, tolérance 10^{-3}, graine 42, bornes non négatives.

Après imputation, un PWHT reconstruit est projeté sur un couple (température, durée) *réellement observé* dans le train, au plus proche en distance standardisée et compatible avec une composante observée. Toute situation anormale — colonne entièrement absente du train, absence de couple compatible, non-convergence de l'imputation itérative — déclenche une **erreur explicite**, sans repli silencieux. Les cibles ne sont jamais transmises à l'imputeur.

Pourquoi l'itérative au départ ? Une étude historique de reconstruction (5 octobre) masquait artificiellement 10, 20 ou 40 % de valeurs exactes et comparait les méthodes sur des plis par séries (tableau 11). Sur 11 entrées, l'itérative reconstruisait le mieux ; sur une extension à 22 entrées, elle ne convergeait dans aucun pli.

Tableau 11. Étude historique de reconstruction de valeurs masquées (3 plis par séries, graines 42/43). MAE normalisée par l'écart interquartile du train ; plus bas est meilleur.

Entrées	Méthode	MAE normalisée	Δ corrélations	Plis convergés
11 (noyau)	Médiane	1,697	0,084	3/3
11 (noyau)	Médiane par procédé	1,254	0,069	3/3
11 (noyau)	Itérative	**0,853**	**0,066**	3/3
22 (étendu)	Médiane	2,253	0,106	3/3
22 (étendu)	Médiane par procédé	2,060	0,106	3/3
22 (étendu)	Itérative	2,009	0,159	0/3

Un contrôle à paramètres fixes, sur le schéma A1_13 et les plis groupés, a ensuite comparé les deux imputations sous une forêt aléatoire (300 arbres, feuille minimale 2, graine 42). Les 15 ajustements itératifs convergeaient en 4 à 7 itérations, et l'itérative n'était pas uniformément meilleure (tableau 12).

Décision et justification

Le premier benchmark supervisé utilise **A1_13 avec imputation itérative**, justifiée par l'étude de reconstruction. Les diagnostics (section 8.4) montreront ensuite que l'itérative **ne converge pas** dans 11 contextes sur 16 entrées, alors que la médiane reste stable et que l'ajout de Ni/Cr/Mo améliore

Tableau 12. Contrôle d'imputation à paramètres fixes, schéma 13, validation groupée (MAE moyenne des cinq plis externes).

Cible	Baseline médiane	RF / médiane	RF / itérative	R^2 RF / itérative
YS (MPa)	70,45	**65,39**	66,13	0,077
UTS (MPa)	72,66	58,10	**56,71**	0,190
Allongement (points de %)	4,09	3,70	**3,55**	0,114

nettement YS et UTS. La configuration de travail devient alors **A1b_16 avec imputation médiane**. Ce choix est rétrospectif : il a été fait après observation des scores sur ces mêmes données.

4.8 Le prétraitement complet dans une pipeline

Toutes les étapes apprises sont encapsulées dans une `Pipeline` de scikit-learn [9] : la classe `FoldPreprocessor`, définie dans le notebook 02, est suivie de l'estimateur. La figure 10 illustre son fonctionnement : la même pipeline est ajustée sur le train, puis appliquée sans réajustement à la validation et, pour COREG, au pool non étiqueté.

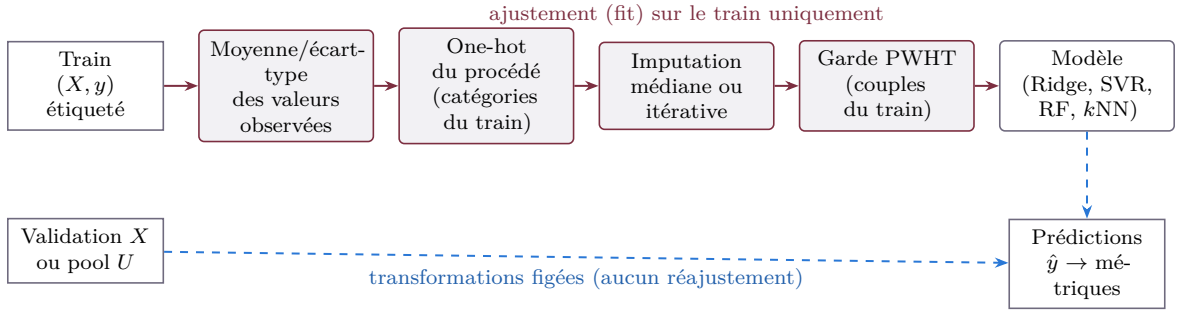


Figure 10. Pipeline de prétraitement et de modélisation. Les flèches pleines indiquent les paramètres appris sur le train ; la flèche pointillée, l'application de ces paramètres figés à la validation (ou au pool non étiqueté).

À retenir

- Nettoyage **déterministe et traçable** (66 080 cellules documentées) ; brut inchangé ; aucune cible modifiée ou imputée.
- **47 groupes** de séries inférées ; cohorte de **1 555 lignes / 44 groupes** avec au plus deux entrées manquantes sur 13.
- Standardisation, encodage et imputation sont **appris dans chaque train** via une pipeline unique.
- Configuration initiale 13/itérative, puis configuration de travail **16/médiane** après diagnostic.

5 Méthodes d'apprentissage

Nous comparons cinq familles supervisées vues en cours, choisies pour couvrir des hypothèses différentes sur la forme de la relation entre conditions de soudage et propriétés, puis une méthode semi-supervisée. Toutes sont implémentées avec scikit-learn [9] dans les notebooks 03 à 07. Dans la suite, $\{(\boldsymbol{x}_i, y_i)\}_{i=1}^{n}$ désigne l'ensemble d'entraînement d'un pli, après prétraitement.

5.1 Méthodes supervisées

5.1.1 Référence : médiane de la cible

Le modèle constant $\hat{y} = \text{médiane}(y_1, \ldots, y_n)$ ignore complètement $\boldsymbol{x}$. Il fixe le **gain minimal** à dépasser : un modèle qui ne fait pas mieux n'apprend rien d'utile des conditions de soudage. La médiane minimise l'erreur absolue moyenne parmi les prédicteurs constants, ce qui en fait la référence naturelle pour la MAE.

5.1.2 Régression Ridge

La régression Ridge [10] est une régression linéaire pénalisée :

$$\hat{\boldsymbol{\beta}} = \arg\min_{\boldsymbol{\beta}} \sum_{i=1}^{n} \big(y_i - \beta_0 - \boldsymbol{x}_i^{\top}\boldsymbol{\beta}\big)^2 + \alpha \,\|\boldsymbol{\beta}\|_2^2. \tag{3}$$

La pénalité α réduit l'amplitude des coefficients et stabilise l'estimation lorsque des entrées sont corrélées (courant, tension et apport thermique, par exemple). Ridge sert de **contrôle linéaire** : si un modèle non linéaire fait beaucoup mieux, la relation contient des non-linéarités ou des interactions.

5.1.3 Régression à vecteurs de support (SVR) à noyau RBF

La SVR [11] cherche une fonction $f(\boldsymbol{x}) = \langle \boldsymbol{w}, \phi(\boldsymbol{x}) \rangle + b$ aussi « plate » que possible, en ignorant les erreurs inférieures à ε (perte ε-insensible) :

$$\min_{\boldsymbol{w}, b} \; \tfrac{1}{2}\|\boldsymbol{w}\|^2 + C \sum_{i=1}^{n} \max\big(0, |y_i - f(\boldsymbol{x}_i)| - \varepsilon\big), \tag{4}$$

$$k(\boldsymbol{x}, \boldsymbol{x}') = \langle \phi(\boldsymbol{x}), \phi(\boldsymbol{x}') \rangle = \exp\big(-\gamma \|\boldsymbol{x} - \boldsymbol{x}'\|^2\big). \tag{5}$$

Le noyau gaussien (RBF) permet des relations non linéaires lisses. C règle le compromis entre régularité et ajustement, γ la portée du noyau et ε la largeur du tube de tolérance. Comme ε s'exprime dans l'unité de y, la cible est standardisée dans le train (`TransformedTargetRegressor`) puis les prédictions sont reconverties.

5.1.4 Forêt aléatoire

Une forêt aléatoire [12] moyenne B arbres de régression, chacun appris sur un échantillon bootstrap et choisissant ses coupures parmi un sous-ensemble aléatoire de variables :

$$\hat{y}(\boldsymbol{x}) = \frac{1}{B}\sum_{b=1}^{B} T_b(\boldsymbol{x}). \tag{6}$$

Les arbres capturent les interactions et les effets de seuil (par exemple un traitement thermique au-delà d'une certaine température) ; la moyenne réduit la variance. La méthode est insensible aux transformations monotones des entrées et robuste à des entrées peu informatives. Nous fixons $B = 300$ arbres et la graine 42, et réglons la taille minimale des feuilles, la profondeur maximale et la fraction de variables candidates à chaque coupure.

5.1.5 k plus proches voisins

Le kNN [13] prédit la moyenne des cibles des k voisins les plus proches dans l'espace standardisé :

$$\hat{y}(\boldsymbol{x}) = \frac{1}{k}\sum_{i\in\mathcal{N}_k(\boldsymbol{x})} y_i, \tag{7}$$

$$d_p(\boldsymbol{x},\boldsymbol{x}') = \Big(\sum_j |x_j - x'_j|^p\Big)^{1/p}, \quad p = 1 \text{ (L1, Manhattan) ou } p = 2 \text{ (L2, euclidienne).} \tag{8}$$

C'est une méthode locale et sans hypothèse de forme. Elle est aussi le **pendant supervisé de COREG**, qui repose sur deux kNN : la comparer directement permet d'isoler l'effet des pseudo-labels.

5.1.6 Grilles d'hyperparamètres

Le tableau 13 donne les grilles explorées. Elles ont été fixées *avant* les entraînements comme budgets raisonnables, et non optimisées a posteriori. Au total, **39 configurations** sont évaluées par cible et par pli externe.

Tableau 13. Familles supervisées, rôle dans la comparaison et grilles d'hyperparamètres.

Famille	Rôle	Grille	Config.
Médiane de y	Gain minimal à dépasser	aucune	1
Ridge	Contrôle linéaire régularisé	$\alpha \in \{0{,}01;\ 0{,}1;\ 1;\ 10;\ 100;\ 1\,000\}$	6
SVR RBF	Non-linéarité lisse à noyau	$C \in \{1{,}10{,}100\}$, $\gamma \in \{\text{scale}, 0{,}05\}$, $\varepsilon \in \{0{,}05;\ 0{,}2\}$	12
Forêt aléatoire	Interactions et seuils	300 arbres ; feuille $\in \{1{,}2{,}5\}$, profondeur $\in \{\text{libre}, 10\}$, `max_features` $\in \{0{,}5;\ 1\}$	12
kNN	Méthode locale, contrôle de COREG	$k \in \{3{,}5{,}9{,}15\}$, $p \in \{1{,}2\}$, poids uniformes	8
Total par cible et par pli externe			39

Décision et justification

Le critère de réglage est la **MAE interne moyenne** (section 6.3). Elle s'exprime dans l'unité de la cible et est moins dominée que la RMSE par quelques séries très mal prédites. La famille elle-même peut être choisie dans la boucle interne : on parle alors de « sélection interne », procédure dont le score externe est une estimation honnête (section 6).

5.2 Apprentissage semi-supervisé : revue bibliographique

L'apprentissage semi-supervisé cherche à améliorer un prédicteur en utilisant, en plus des exemples étiquetés $\mathcal{D}_L$, des exemples non étiquetés $\mathcal{D}_U$ [14, 15]. Il n'aide que si la distribution des entrées renseigne sur la fonction à apprendre, ce qui suppose l'une des hypothèses suivantes :

— **régularité** : deux entrées proches ont des sorties proches ;
— **amas** : les points d'un même amas partagent une sortie similaire ;
— **variété** : les données vivent près d'une variété de faible dimension.

Les principales familles de méthodes sont résumées au tableau 14.

Tableau 14. Grandes familles de méthodes semi-supervisées et adéquation au projet.

Famille	Principe	Adéquation à notre problème
Auto-apprentissage (*self-training*) [16]	Un modèle étiquette ses prédictions les plus sûres et se réentraîne dessus	Simple, mais risque de renforcer ses propres erreurs ; la « confiance » est mal définie en régression
Co-apprentissage (*co-training*) [17]	Deux modèles sur deux vues indépendantes s'étiquettent mutuellement	Conçu pour la classification et pour deux vues naturelles, absentes ici
Méthodes à graphe (propagation de labels) [18]	Les labels diffusent le long d'un graphe de similarité	Essentiellement transductives ; graphe sensible aux absences et aux échelles
Modèles génératifs, SVM transductives [14]	Modéliser $p(\boldsymbol{x}, y)$ ou placer la frontière dans les zones peu denses	Pensés surtout pour la classification
Régularisation par cohérence (réseaux profonds) [15]	Prédictions stables sous perturbation	Exigent de grands volumes de données
COREG [2]	Co-apprentissage pour la **régression**, deux kNN, confiance par réduction locale d'erreur	**Retenu** : conçu pour la régression, inductif, peu coûteux

Décision et justification

Nous retenons **COREG** (*CO-training REGressors*) de Zhou et Li [2], pour cinq raisons :

1. il est **conçu pour la régression**, alors que la plupart des méthodes le sont pour la classification ;
2. il définit une **confiance mesurable** pour une prédiction numérique : la baisse d'erreur locale qu'elle provoque ;
3. il n'exige pas deux vues naturelles indépendantes : la diversité provient de **deux métriques de**

distance ;

4. il repose sur le kNN, méthode vue en cours, ce qui permet un **contrôle supervisé exact** (mêmes kNN, mêmes labels, sans pseudo-labels) ;
5. il est **inductif** : le modèle final prédit de nouvelles soudures sans réapprentissage, ce qui correspond à l'usage visé.

5.3 L'algorithme COREG

COREG entraîne deux régresseurs kNN, h_1 (distance L1) et h_2 (distance L2), sur les mêmes labels. À chaque tour, chaque régresseur examine des candidats du pool U et estime leur **confiance** : pour un candidat $\boldsymbol{x}_u$, on calcule sa prédiction $\hat{y}_u = h_j(\boldsymbol{x}_u)$, on ajoute temporairement $(\boldsymbol{x}_u, \hat{y}_u)$ au jeu de h_j pour obtenir h'_j, puis on mesure la réduction d'erreur quadratique sur les k voisins étiquetés Ω_u de $\boldsymbol{x}_u$:

$$\Delta_u = \sum_{\boldsymbol{x}_i \in \Omega_u} \Big[\big(y_i - h_j(\boldsymbol{x}_i)\big)^2 - \big(y_i - h'_j(\boldsymbol{x}_i)\big)^2 \Big]. \tag{9}$$

Le candidat de plus grand gain positif est **transmis à l'autre régresseur**, qui l'ajoute à ses données comme pseudo-label. La prédiction finale est la moyenne $\hat{y} = \frac{1}{2}\big(h_1(\boldsymbol{x}) + h_2(\boldsymbol{x})\big)$. La figure 11 et l'algorithme 1 résument la procédure.

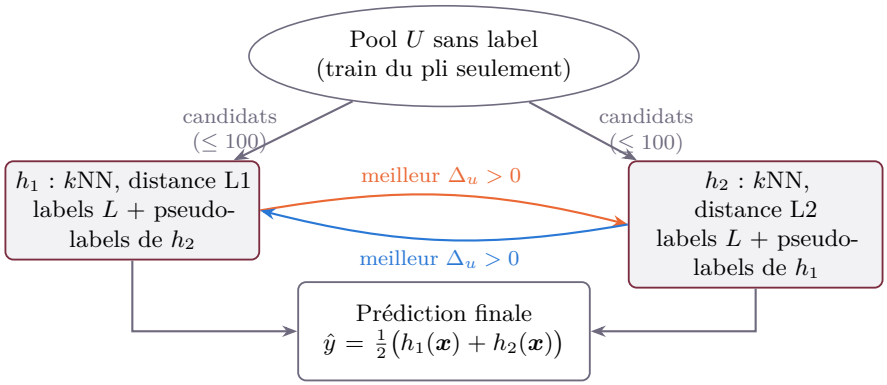


Figure 11. Principe de COREG. Chaque kNN choisit dans le pool l'exemple dont sa propre prédiction réduit le plus l'erreur locale, puis le transmet à l'autre kNN comme pseudo-label.

Le tableau 15 distingue ce qui vient de l'article original et ce qui relève de nos choix d'implémentation, tous fixés *avant* le calcul.

Précaution d'interprétation

Un pseudo-label est une *estimation*, pas une mesure mécanique. Le gain local Δ_u mesure la cohérence d'une prédiction avec ses voisins étiquetés ; il ne garantit pas qu'elle soit exacte, et deux kNN qui partagent les mêmes entrées peuvent propager une même erreur.

À retenir

Cinq familles supervisées couvrent le constant, le linéaire, le non-linéaire lisse, les arbres et le local ; 39 configurations sont réglées par MAE interne. COREG est retenu comme méthode semi-supervisée parce qu'il est conçu pour la régression, inductif et directement comparable à un contrôle kNN supervisé.

Algorithme 1 COREG tel qu'implémenté dans le notebook 07 (un pli, une cible)

Entrées : labels du train L (prétraités), pool U du train, k, $T_{\max} = 100$, $N_{\text{cand}} = 100$
Ajuster le prétraitement sur L ; le figer ; transformer U
Dédupliquer U par représentation exacte ; retirer les $\boldsymbol{x}$ déjà présents dans L
$L_1 \leftarrow L$, $L_2 \leftarrow L$; $h_1 \leftarrow k\text{NN}_{L1}(L_1)$, $h_2 \leftarrow k\text{NN}_{L2}(L_2)$
pour $t = 1, \ldots, T_{\max}$ **faire**
    Tirer (graine dérivée du pli) au plus N_{cand} candidats actifs $U' \subseteq U$
    pour $j \in \{1, 2\}$ **faire**
        Pour chaque $\boldsymbol{x}_u \in U'$: $\hat{y}_u \leftarrow h_j(\boldsymbol{x}_u)$ et calculer Δ_u (équation (9))
        $u_j^\star \leftarrow \arg\max_u \Delta_u$; retenir si $\Delta_{u_j^\star} > \tau = 10^{-12} \max(1, \text{var}(y))\, k$
        Retirer $\boldsymbol{x}_{u_j^\star}$ de U' et de U
    fin pour
    $L_2 \leftarrow L_2 \cup \{(\boldsymbol{x}_{u_1^\star}, \hat{y}_{u_1^\star})\}$, $L_1 \leftarrow L_1 \cup \{(\boldsymbol{x}_{u_2^\star}, \hat{y}_{u_2^\star})\}$; mettre à jour h_1, h_2
    si aucun ajout accepté **ou** U épuisé **alors**
        arrêter
    fin si
fin pour
retourner $\hat{y}(\boldsymbol{x}) = \frac{1}{2}\big(h_1(\boldsymbol{x}) + h_2(\boldsymbol{x})\big)$

Tableau 15. Paramétrage de COREG et écarts à l'article original.

Élément	Choix du projet
Régresseurs	Deux kNN uniformes sur les mêmes 16 entrées + procédé ; distances L1 et L2 (l'article utilise des distances de Minkowski d'ordres 2 et 5)
Nombre de voisins	Même k pour les deux, choisi dans $\{3, 5, 9, 15\}$ par MAE interne
Prétraitement	Appris sur les vrais labels du train, figé pendant toute la boucle
Confiance	équation (9) ; voisinage dans le jeu courant, pseudo-labels précédents inclus ; mise à jour exacte vérifiée contre un réapprentissage explicite
Candidats et tours	Au plus 100 candidats actifs par tour, au plus 100 tours, un ajout par régresseur et par tour, aucun identifiant ajouté deux fois
Pool	Déduplication des représentations identiques (plus petit identifiant conservé) ; retrait des $\boldsymbol{x}$ déjà présents dans les vrais labels
Arrêt	Pool épuisé, aucun gain positif dans le pool actif, ou 100 tours ; jamais sur un label de validation
Égalités	Ordre stable : vrais labels triés par identifiant, puis représentants du pool

6 Protocole de validation et métriques

6.1 Pourquoi une validation croisée imbriquée ?

Un modèle doit être jugé sur des données qu'il n'a pas vues ; c'est le rôle de la validation croisée [19]. Mais lorsqu'on *choisit* aussi des hyperparamètres, voire une famille de modèles, en regardant des scores de validation, ces scores deviennent optimistes : on a sélectionné le meilleur résultat parmi beaucoup d'essais [20, 21].

La validation croisée **imbriquée** sépare les deux rôles :

— une **boucle interne** (3 plis) choisit les hyperparamètres — et, pour la « sélection interne », la famille — en n'utilisant que le train externe ;
— une **boucle externe** (5 plis) évalue *une seule fois* la configuration choisie sur des données jamais utilisées pour la choisir.

Le score externe estime donc la performance de *toute la procédure* de réglage, et non celle d'une configuration choisie après coup.

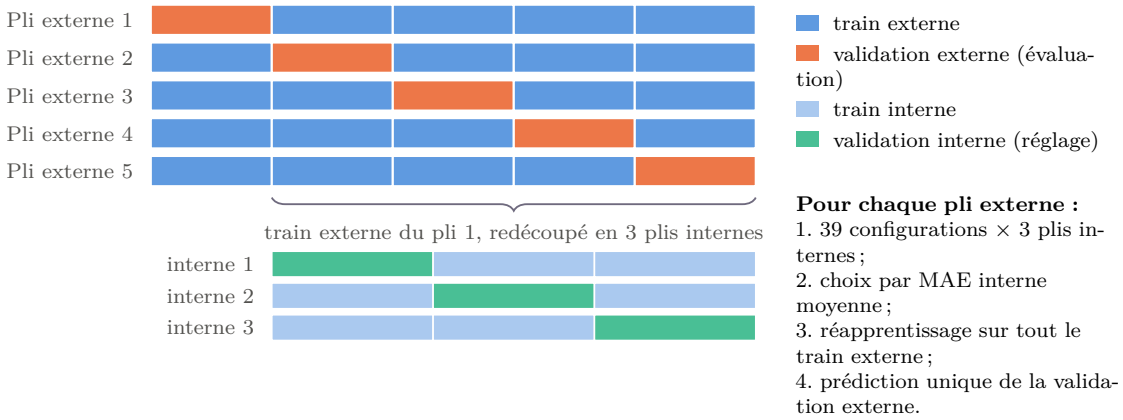


Figure 12. Validation croisée imbriquée : 5 plis externes pour l'évaluation, 3 plis internes dans chaque train externe pour le réglage. Le prétraitement est réappris à chaque ajustement (interne et externe).

Pour chaque cible et chaque pli externe, cela représente 39 configurations × 3 validations internes, plus un réapprentissage par famille : dans le benchmark du notebook 03, **2 340 ajustements internes et 100 réapprentissages externes**, soit 2 440 ajustements d'estimateurs. Tout échec d'ajustement lève une erreur (`error_score='raise'`) plutôt que d'être masqué.

6.2 Deux scénarios de validation, deux questions

La manière de former les plis détermine la question à laquelle répond le score. Nous utilisons deux scénarios, avec les mêmes labels et les mêmes familles (tableau 16).

Intuition

Imaginons une étude qui fait varier la teneur en nickel de cinq soudures fabriquées avec le même procédé, dans le même laboratoire. En validation aléatoire, quatre d'entre elles peuvent être dans le train : le modèle « connaît » déjà le niveau de cette étude et n'a qu'à interpoler. En validation groupée, les cinq

Tableau 16. Les deux scénarios de validation croisée.

	Validation aléatoire	**Validation groupée**
Découpage externe	KFold(5) mélangé, graine 42, par cible	GroupKFold(5) sur les séries inférées, sans mélange
Découpage interne	KFold(3) mélangé, graine 43 + pli	GroupKFold(3) dans chaque train externe
Ce qui est séparé	Des lignes	Des séries entières
Question posée	Prédire une nouvelle soudure d'une série *déjà représentée*	Prédire les soudures d'une *nouvelle étude*
Partage observé	99 à 100 % des lignes de validation ont une série présente dans le train	Aucune série partagée
Risque	Optimisme si l'usage visé concerne de nouvelles séries	Pessimisme si les séries sont très hétérogènes ou mal définies

sont absentes : le modèle doit deviner le niveau d'une étude qu'il n'a jamais vue. Les données structurées en groupes appellent une validation qui respecte cette structure [22].

En validation groupée, chaque pli externe contient 8 à 10 groupes ; les validations des trois cibles de traction comportent 103 à 166 labels selon le pli. Le nombre de lignes ne garantit pas le nombre d'observations réellement indépendantes.

Décision et justification

Les deux scénarios sont conservés et rapportés côte à côte. Le choix du protocole « principal » dépend de l'usage : la validation aléatoire décrit l'interpolation dans la population couverte par la base, la validation groupée est un test de transfert à de nouvelles études. On ne choisit pas le protocole qui affiche le meilleur score.

6.3 Métriques

Pour n labels de validation y_i, de prédictions $\hat{y}_i$ et de moyenne $\bar{y}$:

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n} |y_i - \hat{y}_i|, \tag{10}$$

$$\mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n} (y_i - \hat{y}_i)^2}, \tag{11}$$

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}. \tag{12}$$

— La **MAE** est l'erreur typique, dans l'unité de la cible (MPa, points de %, J). Elle sert de **critère de réglage**.

— La **RMSE** pénalise davantage les grandes erreurs ; l'écart entre RMSE et MAE renseigne sur la présence d'erreurs très fortes.

— Le R^2 est sans unité : c'est la part de la variance de la validation expliquée par le modèle. $R^2 = 0$ correspond à prédire la moyenne *de la validation* ; $R^2 < 0$ signifie faire pire. Il permet de comparer des cibles d'unités différentes, mais dépend de la variance de la population évaluée.

Deux agrégations coexistent. La **moyenne des plis** calcule la métrique dans chaque pli externe puis en fait la moyenne non pondérée (avec l'écart-type SD) ; le score **OOF** (*out-of-fold*) réunit toutes les prédictions externes puis calcule une seule métrique. Les deux diffèrent, surtout pour le R^2, car chaque pli a sa propre variance. Sauf mention contraire, les tableaux donnent la moyenne des plis. Pour comparer deux méthodes sur les mêmes observations, nous utilisons un **gain apparié** de MAE OOF accompagné d'un intervalle **bootstrap par groupes** (2 000 rééchantillonnages des séries) [23], plus honnête qu'un bootstrap par lignes lorsque les lignes d'une série sont dépendantes.

Précaution d'interprétation

Les écarts-types entre plis et les intervalles bootstrap sont descriptifs : ils sont conditionnels aux plis et aux modèles entraînés, et ne constituent pas des intervalles de confiance sur de nouvelles publications. Un R^2 de 0,5 n'est pas un seuil garanti par le choix d'un algorithme.

6.4 Protocole inductif pour le semi-supervisé

Un protocole semi-supervisé est *transductif* s'il exploite les entrées de validation (sans leurs labels) pendant l'apprentissage, et *inductif* s'il ne les voit jamais. Nous adoptons un protocole **strictement inductif** :

— le pool non étiqueté d'un pli ne contient que des lignes sans la cible *affectées au train courant* — interne comme externe ;

— en validation aléatoire, les lignes sans label sont réparties en cinq blocs équilibrés (graine 142), puis en trois blocs internes (graine 1042 + pli) ; aucune ligne de validation n'entre dans le pool ;

— en validation groupée, le pool exclut en plus *toutes les séries* de validation ;

— ni les entrées ni les labels de validation ne servent au calcul de confiance, à l'arrêt ou au prétraitement ;

— les modèles réentraînés sur tous les labels ne servent jamais à scorer les plis.

6.5 Graines et reproductibilité

Toutes les sources d'aléa sont fixées et enregistrées dans les manifestes d'expérience (tableau 17). Les partitions sont exportées par identifiant brut ; les versions des bibliothèques et les empreintes SHA-256 des données, du code et des exports sont consignées (annexe B).

À retenir

Validation croisée **imbriquée** 5×3, prétraitement réappris dans chaque train, sélection par MAE interne. Deux scénarios complémentaires : **aléatoire** (interpolation dans des séries connues) et **groupé** (transfert à de nouvelles séries). Métriques MAE, RMSE, R^2 ; semi-supervisé évalué selon un protocole **inductif**.

Tableau 17. Graines aléatoires utilisées.

Graine	Usage
42	Estimateurs stochastiques (forêts), imputation itérative, plis externes aléatoires, base des graines de COREG, bootstrap des gains COREG (2 000 tirages), test de permutation série/cible (999)
43 + pli	Plis internes de la validation aléatoire
142	Répartition des lignes sans label en cinq blocs (validation aléatoire)
1042 + pli	Blocs internes des lignes sans label
1042	CV5 aléatoire de sélection des modèles réentraînés sur tous les labels
1142	Affectation des lignes sans label lors des réapprentissages complets de COREG
43, 44	Sensibilité de COREG à la graine (à k fixé)

7 Résultats de l'entraînement supervisé

Cette section présente les résultats dans l'ordre où ils ont été obtenus : un premier benchmark groupé avec la configuration initiale (13 entrées, imputation itérative), puis les résultats de la configuration de travail (16 entrées, imputation médiane) sous les deux scénarios de validation.

7.1 Premier benchmark : 13 entrées, imputation itérative, validation groupée

Le notebook 03 a exécuté les 100 évaluations externes (5 familles × 4 cibles × 5 plis) en six minutes environ. Les 80 ajustements de prétraitement ont convergé (3 à 20 itérations selon la cible et le pli). Le tableau 18 donne les scores.

Tableau 18. Premier benchmark, schéma 13/itérative, validation groupée : moyenne ± écart-type sur les cinq plis externes. En gras : plus faible MAE par cible.

Cible	Modèle	MAE	RMSE	R^2
YS (MPa)	Médiane de y	70,45 ± 10,68	92,50	−0,073
	Ridge	69,92 ± 5,17	90,88	−0,054
	SVR RBF	69,28 ± 12,81	89,26	0,004
	Forêt aléatoire	**65,88 ± 10,61**	85,65	0,079
	kNN	76,87 ± 15,75	98,68	−0,208
UTS (MPa)	Médiane de y	72,66 ± 15,24	93,73	−0,180
	Ridge	65,88 ± 15,14	82,99	0,054
	SVR RBF	63,40 ± 12,70	83,43	0,039
	Forêt aléatoire	**57,65 ± 10,78**	76,25	0,194
	kNN	66,65 ± 16,00	88,66	−0,089
Allongement (points de %)	Médiane de y	4,09 ± 0,31	4,96	−0,062
	Ridge	3,73 ± 0,31	4,57	0,094
	SVR RBF	3,88 ± 0,39	4,82	−0,007
	Forêt aléatoire	**3,56 ± 0,18**	4,49	0,125
	kNN	3,91 ± 0,25	5,02	−0,093
Charpy* (J)	Médiane de y	36,04 ± 16,91	50,60	−0,149
	Ridge	35,74 ± 12,87	45,84	0,072
	SVR RBF	36,14 ± 8,51	46,12	0,035
	Forêt aléatoire	**34,71 ± 12,36**	46,53	0,017
	kNN	34,92 ± 13,12	49,36	−0,139

Analyse. La forêt aléatoire obtient la plus faible MAE pour les quatre cibles, mais les gains sur la référence restent modestes : 4,6 MPa pour YS et 15,0 MPa pour UTS, avec des R^2 entre 0,02 et 0,19. Pour Charpy, le gain est d'à peine 1,3 J. Les écarts-types entre plis (jusqu'à 16 MPa) sont du même ordre que les écarts entre familles : les performances dépendent fortement des séries placées en validation. Ces résultats insuffisants ont déclenché une investigation dédiée (section 8), dont deux conclusions ont modifié la configuration : ajouter Ni, Cr et Mo et passer à l'imputation médiane.

7.2 Configuration de travail : 16 entrées, imputation médiane

Avec 16 entrées numériques, le procédé et une imputation médiane, chaque scénario est évalué par validation imbriquée où **la famille et ses hyperparamètres sont choisis dans la boucle interne** (« sélection interne »). La figure 13 et le tableau 19 présentent le résultat principal du projet.

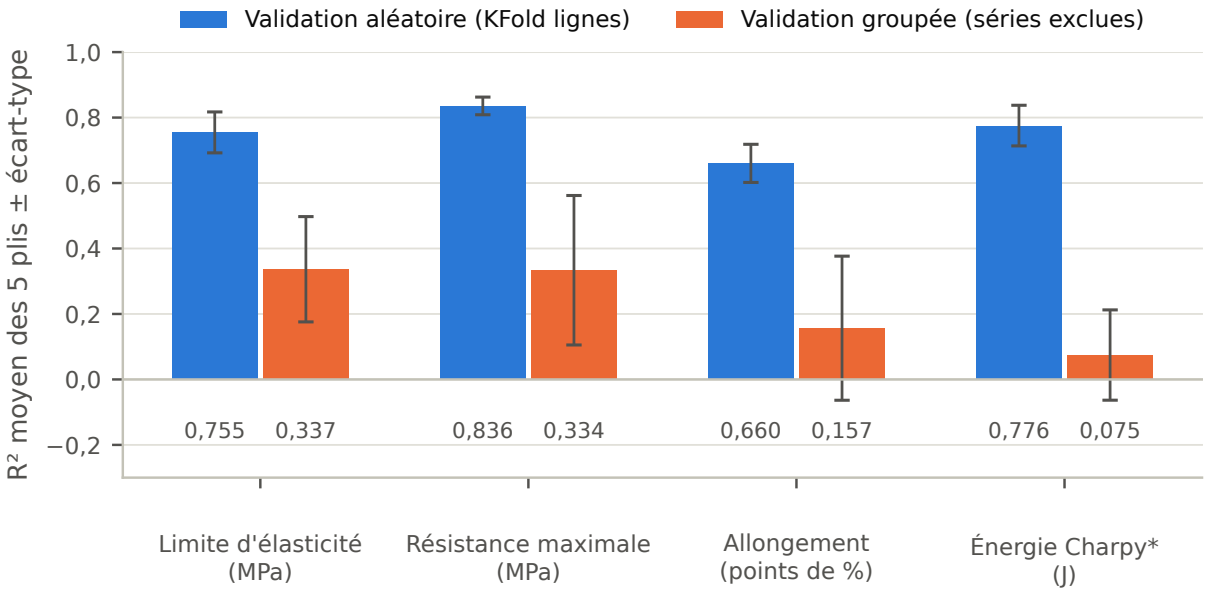


Figure 13. Résultat principal : R^2 moyen (± écart-type sur 5 plis) de la procédure supervisée avec sélection interne de la famille, configuration 16/médiane. Bleu : validation aléatoire ; orange : validation groupée.

Tableau 19. Procédure supervisée avec sélection interne, configuration 16/médiane : moyennes ± écart-type sur 5 plis externes, et MAE relative à la médiane de la cible.

	Validation aléatoire			Validation groupée		
Cible	MAE	MAE rel.	R^2	MAE	MAE rel.	R^2
YS (MPa)	31,630 ± 4,114	6,4 %	0,755 ± 0,063	56,757 ± 12,398	11,4 %	0,337 ± 0,161
UTS (MPa)	23,861 ± 0,906	4,1 %	0,836 ± 0,027	54,344 ± 13,181	9,4 %	0,334 ± 0,228
Allongement (pts de %)	2,054 ± 0,239	7,7 %	0,660 ± 0,058	3,517 ± 0,516	13,2 %	0,157 ± 0,220
Charpy* (J)	16,461 ± 1,161	16,5 %	0,776 ± 0,062	35,752 ± 11,863	35,8 %	0,075 ± 0,138

Lecture. En validation aléatoire, l'erreur typique est de **32 MPa sur YS et 24 MPa sur UTS**, soit 4 à 6 % de la valeur médiane, et les R^2 dépassent 0,75 pour YS, UTS et Charpy. Par rapport à la référence médiane, la MAE baisse de 55 % (YS), 65 % (UTS), 49 % (allongement) et 55 % (Charpy). En validation groupée, les mêmes procédures perdent une grande partie de leur pouvoir prédictif : la MAE ne baisse plus que de 19 % (YS), 25 % (UTS), 14 % (allongement) et 1 % (Charpy) par rapport à la référence. L'écart entre les deux scénarios est le résultat le plus important du projet ; la section 8 en analyse les causes.

7.3 Comparaison des familles de modèles

Pour comprendre d'où viennent ces scores, chaque famille est aussi évaluée séparément, avec ses hyperparamètres réglés en interne (figure 14, tableau 20).

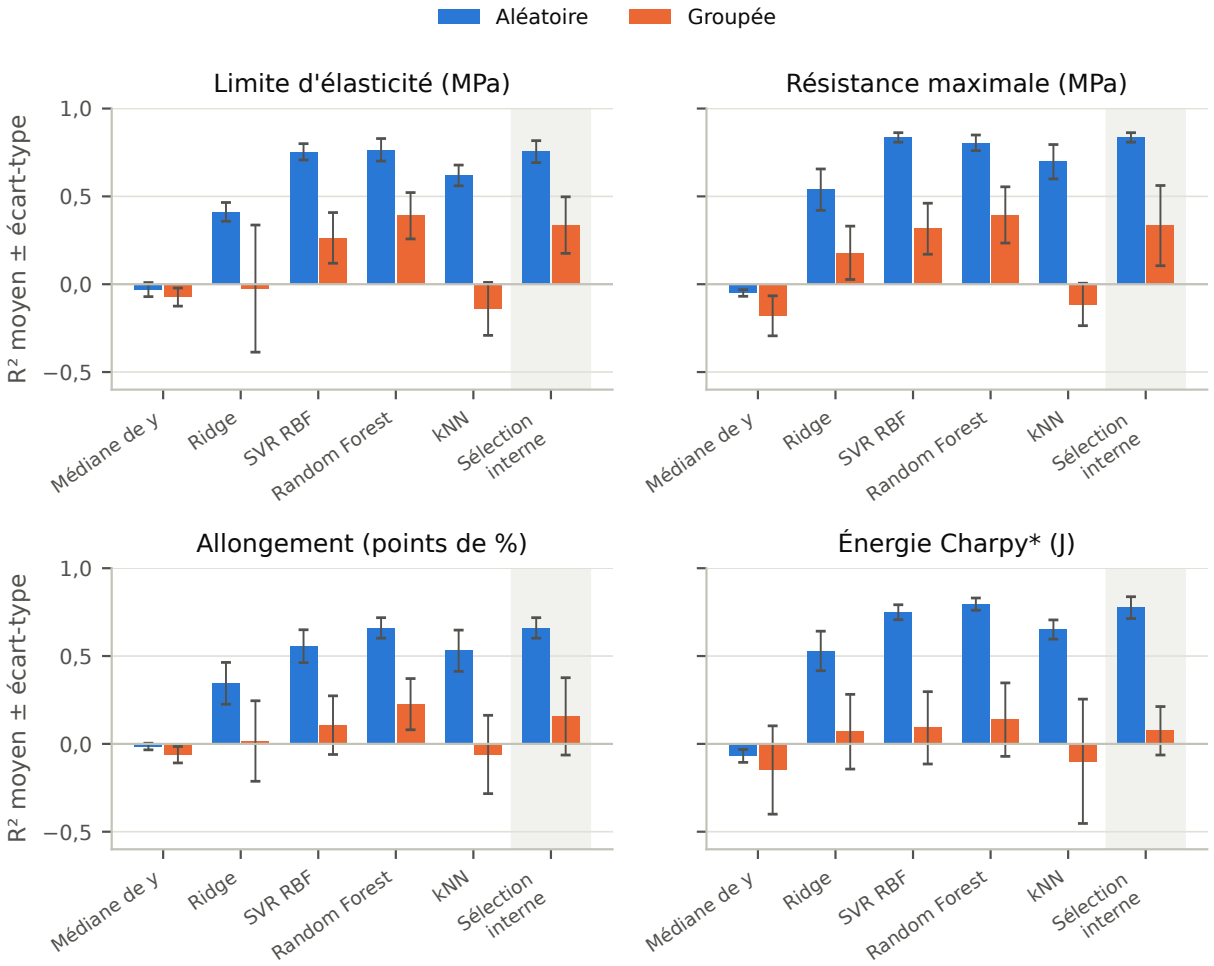


Figure 14. R^2 moyen (± écart-type) de chaque famille, configuration 16/médiane, validations aléatoire et groupée. La dernière colonne (fond gris) est la procédure de sélection interne de la famille.

Analyse par famille.

— **Référence médiane.** Son R^2 est légèrement négatif, comme attendu : prédire la médiane du train est un peu moins bon que prédire la moyenne de la validation. Elle fixe le plancher.

— **Ridge.** Elle capte une partie du signal en aléatoire (R^2 de 0,35 à 0,54), mais presque rien en groupé. Une relation *linéaire* globale ne suffit pas à décrire les propriétés.

— **SVR RBF et forêt aléatoire.** Ce sont les deux meilleures familles. La SVR est la meilleure pour UTS en aléatoire ; la forêt est la meilleure partout ailleurs et la plus robuste en validation groupée. Les non-linéarités et interactions sont donc importantes.

Tableau 20. MAE moyenne et R^2 moyen par famille, configuration 16/médiane (A : validation aléatoire ; G : validation groupée). En gras : meilleure famille par colonne.

	YS (MPa)		UTS (MPa)		Allong. (pts)		Charpy* (J)	
Famille	A	G	A	G	A	G	A	G
MAE								
Médiane de y	70,03	70,45	68,88	72,66	4,02	4,09	36,76	36,04
Ridge	54,05	69,39	44,32	61,90	3,01	3,66	26,91	34,75
SVR RBF	31,75	59,35	**23,86**	52,86	2,27	3,67	17,39	35,96
Forêt aléatoire	**31,24**	**54,14**	26,91	**48,91**	**2,05**	**3,34**	**16,10**	**33,03**
kNN	38,14	73,50	33,45	68,54	2,42	3,98	19,25	35,73
R^2								
Médiane de y	−0,031	−0,073	−0,050	−0,180	−0,015	−0,062	−0,069	−0,149
Ridge	0,412	−0,025	0,538	0,179	0,345	0,016	0,529	0,069
SVR RBF	0,754	0,264	**0,836**	0,316	0,556	0,106	0,749	0,091
Forêt aléatoire	**0,765**	**0,390**	0,805	**0,394**	**0,660**	**0,226**	**0,795**	**0,138**
kNN	0,619	−0,140	0,697	−0,115	0,530	−0,060	0,651	−0,099

— **kNN.** Très correct en aléatoire (R^2 de 0,53 à 0,70) mais *négatif* en groupé. C'est un signal clair : une méthode purement locale prédit bien lorsqu'un voisin de la même série est présent dans le train, et échoue lorsque ce n'est plus le cas.

Précaution d'interprétation

La forêt aléatoire isolée peut afficher un meilleur score externe que la procédure de sélection interne (par exemple 0,390 contre 0,337 pour YS en groupé). Choisir la forêt *après* avoir lu ce tableau reviendrait à sélectionner sur la validation : seul le score de la sélection interne est une estimation honnête de la procédure complète.

7.4 Familles et hyperparamètres sélectionnés

La sélection interne peut choisir une famille différente selon le pli. Les tableaux 21 et 22 détaillent ces choix.

Plusieurs enseignements ressortent. En aléatoire, les choix sont **stables** : SVR ($C = 10$, $\varepsilon = 0{,}05$) pour UTS dans les cinq plis, forêt à feuilles de taille 1 pour l'allongement. Les modèles peu régularisés sont préférés, ce qui est cohérent avec un contexte où des voisins très proches existent dans le train. En groupé, les choix sont **instables** — Ridge, SVR ou forêt pour UTS selon le pli — et la boucle interne retient même la **référence médiane** dans deux plis Charpy : en l'absence de séries connues, aucun modèle ne bat de façon fiable la constante pour cette cible. Cette instabilité illustre l'incertitude du transfert entre séries.

7.5 Prédictions et observations

La figure 15 compare les prédictions hors pli aux valeurs observées.

En validation aléatoire, les points suivent la diagonale. En validation groupée, le nuage est **aplati** :

Tableau 21. Validation aléatoire : famille et hyperparamètres choisis par la MAE interne dans chaque pli externe, et scores externes obtenus.

Cible	Pli	Famille	Hyperparamètres	MAE	R^2
YS	0	SVR RBF	$C = 10$, $\varepsilon = 0{,}05$, $\gamma = 0{,}05$	28,27	0,769
	1	Forêt	feuille 1, prof. libre, `mf` 0,5	29,26	0,817
	2	Forêt	feuille 1, prof. libre, `mf` 0,5	35,67	0,671
	3	SVR RBF	$C = 10$, $\varepsilon = 0{,}05$, γ=scale	28,42	0,807
	4	SVR RBF	$C = 10$, $\varepsilon = 0{,}05$, γ=scale	36,54	0,710
UTS	0–4	SVR RBF	$C = 10$, $\varepsilon = 0{,}05$, $\gamma \in \{0{,}05; \text{scale}\}$	23,1–25,4	0,814–0,871
Allong.	0–4	Forêt	feuille 1, prof. libre, `mf` $\in \{0{,}5; 1\}$	1,84–2,42	0,569–0,728
Charpy	0, 1, 3, 4	Forêt	feuille 1, prof. libre, `mf` $\in \{0{,}5; 1\}$	14,9–17,5	0,756–0,849
	2	SVR RBF	$C = 100$, $\varepsilon = 0{,}05$, $\gamma = 0{,}05$	17,51	0,683

Tableau 22. Validation groupée : famille et hyperparamètres choisis par la MAE interne dans chaque pli externe, et scores externes obtenus.

Cible	Pli	Famille	Hyperparamètres	MAE	R^2
YS	0	Forêt	feuille 2, prof. libre, `mf` 0,5	43,62	0,472
	1	Forêt	feuille 1, prof. libre, `mf` 0,5	68,48	0,204
	2	SVR RBF	$C = 10$, $\varepsilon = 0{,}05$, $\gamma = 0{,}05$	49,94	0,273
	3	Forêt	feuille 1, prof. 10, `mf` 0,5	50,28	0,543
	4	SVR RBF	$C = 10$, $\varepsilon = 0{,}2$, $\gamma = 0{,}05$	71,46	0,191
UTS	0	Ridge	$\alpha = 100$	74,90	0,038
	1	Forêt	feuille 1, prof. libre, `mf` 0,5	49,49	0,155
	2	SVR RBF	$C = 10$, $\varepsilon = 0{,}05$, $\gamma = 0{,}05$	38,76	0,399
	3	Forêt	feuille 2, prof. 10, `mf` 0,5	52,60	0,555
	4	Forêt	feuille 2, prof. libre, `mf` 0,5	55,98	0,523
Allong.	0, 1, 3	Forêt	`mf` 0,5, feuille 5/2/5	2,86–3,63	0,166–0,468
	2, 4	SVR RBF	$\varepsilon = 0{,}2$, $\gamma = 0{,}05$, $C = 1/10$	3,61–4,25	−0,080–−0,022
Charpy	0, 1	SVR RBF	$C = 1$, $\varepsilon = 0{,}2$, $\gamma = 0{,}05$	31,00 / 27,33	−0,038 / 0,222
	2, 4	Médiane de y	–	24,24 / 44,12	−0,034 / −0,006
	3	Forêt	feuille 1, prof. libre, `mf` 1	52,09	0,228

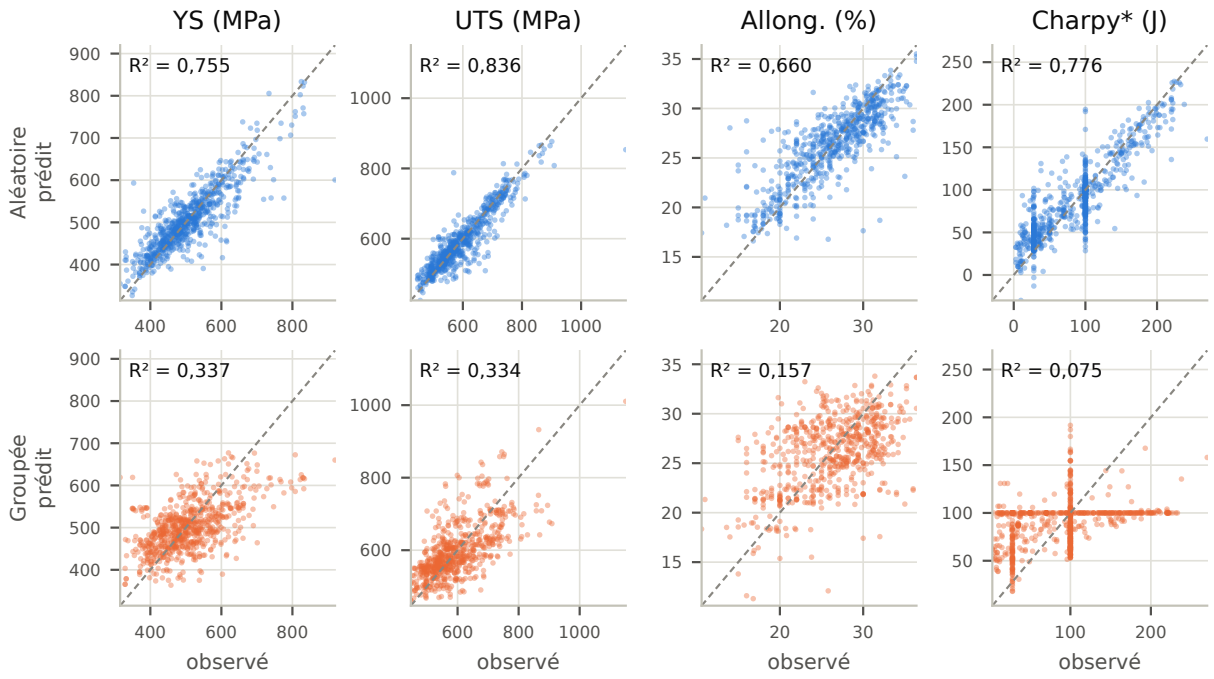


Figure 15. Valeurs observées et prédites hors pli (OOF) par la procédure de sélection interne, configuration 16/médiane. Haut : validation aléatoire ; bas : validation groupée. La diagonale pointillée correspond à une prédiction parfaite.

les prédictions restent proches de la moyenne et les fortes valeurs de YS et UTS sont sous-estimées. Pour Charpy, on distingue des bandes verticales à 28 et 100 J : pour ces couples, le modèle prédit des énergies très variées alors que l'énergie observée est fixée par le protocole, ce qui est cohérent avec l'hypothèse de températures de transition.

7.6 Modèles réentraînés pour l'inférence

Une fois l'évaluation terminée, chaque famille est réglée par une nouvelle CV5 sur *tous* les labels (aléatoire, graine 1042, ou par groupes), puis réentraînée. La famille de plus faible MAE de sélection est retenue par cible (tableau 23). Ces MAE de sélection sont optimistes et **ne remplacent pas** les scores imbriqués ; ces modèles ont vu tous les labels et ne servent jamais à scorer les plis.

Au total, **80 pipelines supervisées** sont exportées (40 par protocole : 20 modèles de plis externes et 20 réapprentissages complets), avec leur prétraitement, leurs métadonnées (entrées, unités, identifiants du train, paramètres, versions) et leur empreinte SHA-256. Toutes ont été rechargées dans un processus Python neuf et les modèles de plis reproduisent exactement leurs prédictions hors pli.

À retenir

- Configuration initiale 13/itérative : gains modestes, $R^2 \leq 0{,}19$ en validation groupée.
- Configuration 16/médiane : R^2 de **0,66 à 0,84 en aléatoire**, mais **0,08 à 0,34 en groupé**.
- **Forêt aléatoire et SVR RBF** sont les meilleures familles ; le kNN s'effondre dès que la série est absente.

Tableau 23. Modèles supervisés réentraînés sur tous les labels, retenus pour l'inférence.

CV de choix	Cible	Famille	MAE de sélection	Hyperparamètres
Aléatoire	YS	SVR RBF	31,228	$C = 10$, $\varepsilon = 0{,}05$, γ=scale
	UTS	SVR RBF	24,060	$C = 10$, $\varepsilon = 0{,}05$, $\gamma = 0{,}05$
	Allong.	Forêt	1,940	feuille 1, prof. libre, `mf` 0,5
	Charpy	Forêt	15,387	feuille 1, prof. libre, `mf` 1
Groupée	YS	Forêt	58,695	feuille 2, prof. libre, `mf` 0,5
	UTS	SVR RBF	46,555	$C = 10$, $\varepsilon = 0{,}05$, $\gamma = 0{,}05$
	Allong.	Forêt	3,282	feuille 1, prof. libre, `mf` 0,5
	Charpy	Forêt	32,375	feuille 1, prof. 10, `mf` 0,5

— Les choix internes sont stables en aléatoire, instables en groupé.

8 Diagnostics des performances et explicabilité

Le premier benchmark (tableau 18) a produit des R^2 faibles en validation groupée. Plutôt que d'essayer des modèles au hasard, le notebook `notebooks/04_diagnostics.ipynb` a cherché à *comprendre* ces scores. Le protocole des diagnostics a été fixé avant leur calcul ; il réutilise les mêmes labels, la même cohorte et les mêmes plis. Ces analyses sont **rétrospectives** : elles ne constituent pas une validation indépendante des choix qu'elles ont motivés.

8.1 Les modèles apprennent, mais transfèrent mal

Le tableau 24 compare les scores sur le train et en validation groupée pour le benchmark 13/itérative.

Tableau 24. Écart entre entraînement et validation groupée, forêt aléatoire du benchmark 13/itérative.

Cible	MAE train	MAE validation	R^2 train	R^2 validation
YS (MPa)	30,08	65,88	0,795	0,079
UTS (MPa)	23,79	57,65	0,842	0,194
Allongement (pts de %)	1,33	3,56	0,859	0,125
Charpy* (J)	8,40	34,71	0,941	0,017

La forêt reproduit bien le train (R^2 de 0,80 à 0,94) mais généralise mal aux séries absentes. Les modèles linéaires ont aussi un faible R^2 d'entraînement (0,18 à 0,27 pour Ridge) : ajouter de la capacité non linéaire ne suffit pas. De plus, les prédictions sont **comprimées** : l'écart-type des prédictions vaut environ 0,53 fois celui des observations pour YS et Charpy, 0,68 pour UTS et 0,64 pour l'allongement ; les soudures très résistantes ou très tenaces sont sous-estimées.

8.2 Une grande part de l'erreur vient des séries

L'erreur quadratique totale peut se décomposer exactement en une part due au **biais moyen de chaque série** et une part due aux variations à l'intérieur des séries :

$$\mathrm{SSE} = \sum_{g}\sum_{i\in g} e_i^2 = \underbrace{\sum_{g} n_g\, b_g^2}_{\text{décalage des séries}} + \underbrace{\sum_{g}\sum_{i\in g} \left(e_i - b_g\right)^2}_{\text{dispersion interne}}, \tag{13}$$

où $e_i = \hat{y}_i - y_i$ est l'erreur de la ligne i, n_g l'effectif de la série g et $b_g = \frac{1}{n_g}\sum_{i\in g} e_i$ son biais moyen.

Le tableau 25 montre que **la moitié environ de l'erreur quadratique** provient de décalages de niveau entre séries : le modèle se trompe de façon systématique sur une série entière. La figure 16 donne les séries qui concentrent le plus d'erreur. Les biais sont majoritairement négatifs pour la résistance : les séries très résistantes (par exemple `SurianEtAl-C-1991`, `Birmingham`, `Sw&Rog-1973`) sont sous-estimées de 170 à 240 MPa.

L'examen de cas concrets éclaire ces décalages. La ligne 722 (`Evans-AlEl9Cr1Mo-1994`) contient 3,01 % de Ni et 9,17 % de Cr ; son UTS observée vaut 1 151 MPa contre 729 MPa prédits. La ligne 1 209 (`PantK-1990`) contient 8,7 % de Cr ; son énergie Charpy observée est de 8 J contre 159 J prédits.

Tableau 25. Décomposition de l'erreur de la forêt du benchmark 13/itérative (prédictions OOF réunies).

Cible	Variance entre séries (% de SST)	Part de SSE due au biais des séries	R^2 OOF	RMSE OOF	RMSE requise pour $R^2 = 0{,}5$
YS (MPa)	48,0 %	56,4 %	0,091	87,7	65,0
UTS (MPa)	54,9 %	50,6 %	0,280	75,9	63,3
Allongement (pts)	54,4 %	50,0 %	0,156	4,48	3,45
Charpy* (J)	29,1 %	36,5 %	0,116	47,5	35,7

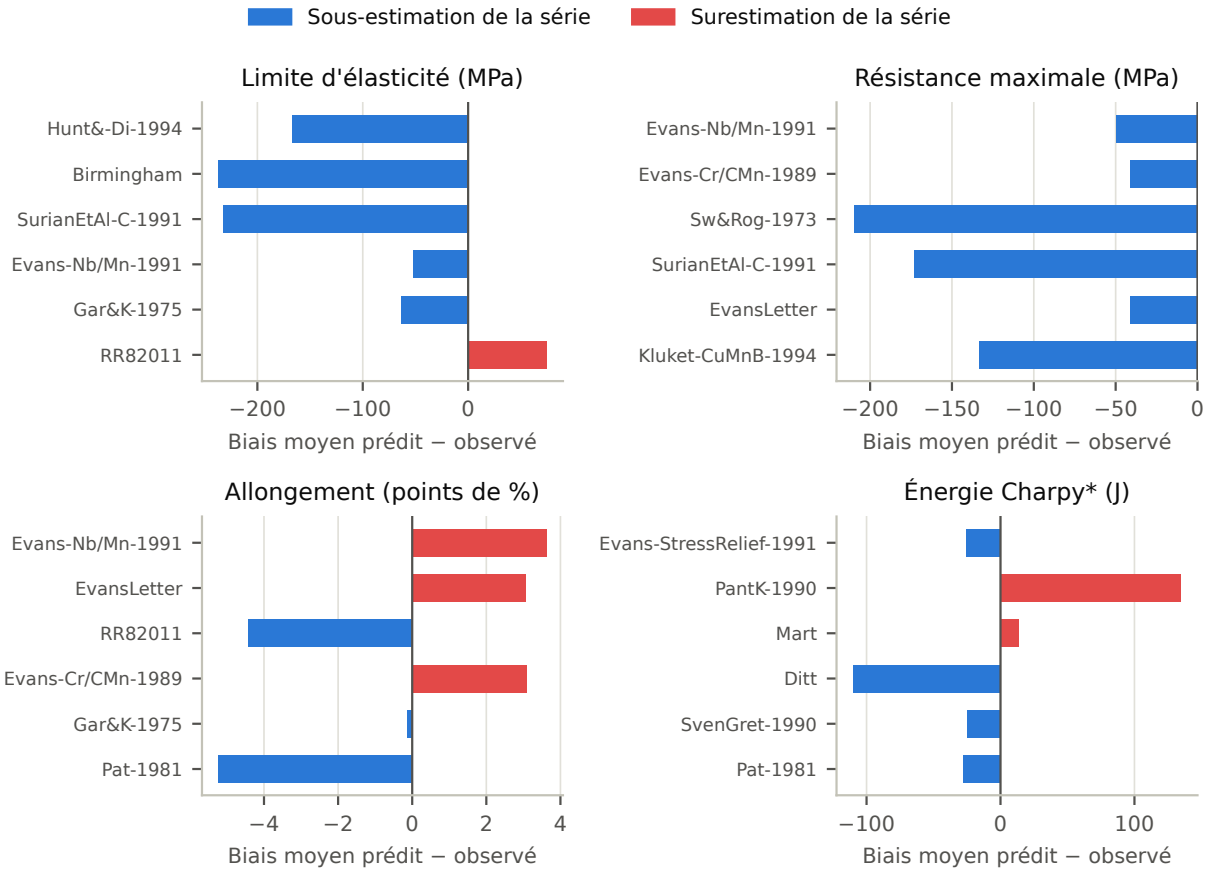


Figure 16. Biais moyen (prédit − observé) des six séries qui contribuent le plus à l'erreur quadratique, forêt du benchmark 13/itérative, validation groupée.

Or Ni, Cr et Mo *ne faisaient pas partie* des 13 entrées. Ces exemples suggèrent une information omise, que l'extension à 16 entrées teste directement (section 8.4).

8.3 Domaine des entrées et rôle de l'imputation

Le tableau 26 compare la MAE selon trois indicateurs : présence d'une entrée imputée, entrée hors des plages observées dans le train, procédé absent du train.

Tableau 26. MAE de la forêt (benchmark 13/itérative) selon l'appartenance au domaine du train.

	Entrée imputée		Hors plages du train		Procédé inconnu	
Cible	non	oui	non	oui	non	oui
YS (MPa)	72,5	57,4	65,0	73,2	64,4	102,4
UTS (MPa)	58,5	53,5	54,9	64,0	54,6	95,3
Allongement (pts)	3,64	3,44	3,67	2,99	3,50	4,29
Charpy* (J)	33,5	37,1	28,2	52,8	32,9	45,2

Deux constats en ressortent. D'abord, les lignes avec une entrée imputée **ne sont pas systématiquement moins bien prédites** ; pour YS elles le sont même mieux. L'hypothèse « l'imputation explique tout » est donc contredite. Ensuite, sortir du domaine du train dégrade nettement Charpy (MAE de 52,8 J contre 28,2 J, corrélation de rang erreur/distance 0,41), et un procédé inconnu du train dégrade fortement YS et UTS (MAE d'environ 100 MPa). Ces comparaisons sont descriptives et confondues par les séries.

8.4 Sensibilités : entrées et méthode d'imputation

Pour isoler les deux facteurs (nombre d'entrées et imputation), les six combinaisons {11, 13, 16 entrées} × {médiane, itérative} ont été évaluées avec les quatre familles, les grilles du notebook 03 et les mêmes plis groupés : 480 évaluations prévues. **436 ont abouti** ; l'imputation itérative à 16 entrées **n'a pas convergé** dans 11 contextes cible/pli (YS pli 4 ; UTS plis 3–4 ; allongement plis 2–4 ; Charpy tous les plis), rendant 44 évaluations indisponibles. Conformément au protocole, aucun repli silencieux n'a été appliqué.

Tableau 27. Forêt aléatoire en validation groupée : MAE et R^2 moyens selon le schéma et l'imputation (plis aboutis sur 5 entre parenthèses lorsque incomplets).

		YS (MPa)		UTS (MPa)		Allong. (pts)		Charpy* (J)	
Entrées	Imputation	MAE	R^2	MAE	R^2	MAE	R^2	MAE	R^2
11	médiane	68,98	0,000	57,31	0,179	3,69	0,076	35,14	0,018
11	itérative	69,14	−0,001	58,38	0,151	3,68	0,063	34,71	0,002
13	médiane	64,98	0,102	57,84	0,185	3,74	0,060	33,70	0,084
13	itérative	65,88	0,079	57,65	0,194	3,56	0,125	34,71	0,017
16	médiane	**54,14**	**0,390**	**48,91**	**0,394**	**3,34**	**0,226**	**33,03**	**0,138**
16	itérative	60,80 (4)	0,156	57,32 (3)	−0,069	3,97 (2)	−0,099	– (0)	–

Le passage de 13 à 16 entrées à imputation médiane identique produit un **gain apparié de MAE**

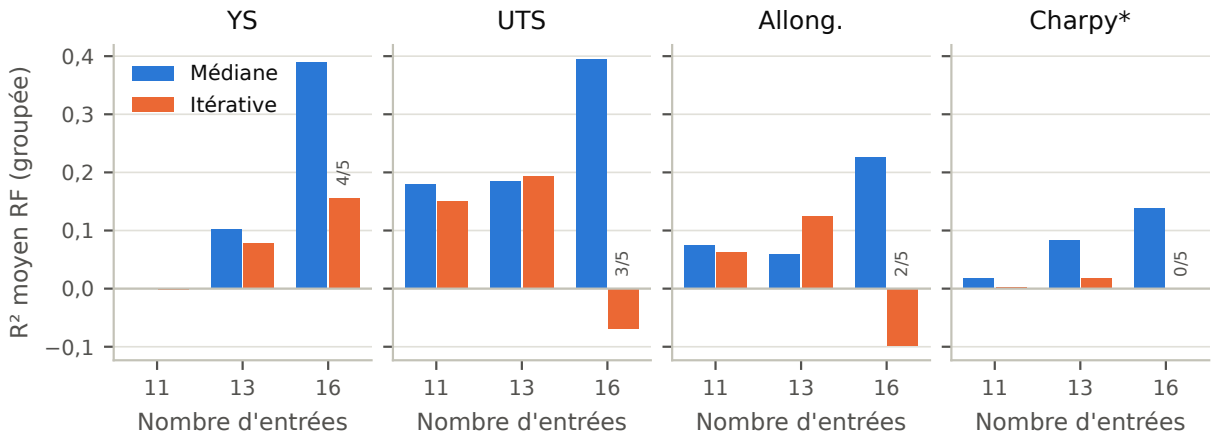


Figure 17. R^2 moyen de la forêt aléatoire en validation groupée selon le nombre d'entrées et l'imputation. Les mentions « $k/5$ » signalent les scénarios où seuls k plis sur 5 ont abouti (non comparables aux scénarios complets).

OOF de la forêt (bootstrap par groupes, 2 000 tirages) :

- YS : **11,06 MPa**, intervalle [3,09 ; 20,19] ;
- UTS : **8,80 MPa**, intervalle [2,38 ; 15,40] ;
- allongement : 0,39 point, intervalle [−0,05 ; 0,87] ;
- Charpy : 0,65 J, intervalle [−0,21 ; 1,64].

Les intervalles de YS et UTS excluent zéro : Ni, Cr et Mo apportent une information prédictive réelle sur la résistance. Pour l'allongement et Charpy, le gain n'est pas établi.

Un contrôle complémentaire a masqué 20 % des valeurs *observées* de Ni, Cr et Mo en validation, puis comparé leur reconstruction. L'itérative ne domine pas : pour Charpy, l'erreur absolue moyenne sur Cr vaut 4,79 % massique avec l'itérative contre 1,50 % avec la médiane, sur les mêmes cellules. Une imputation plus sophistiquée ne garantit donc pas une meilleure reconstruction hors série.

Décision et justification

La configuration de travail devient **16 entrées + médiane** : gain établi pour YS et UTS, convergence garantie, aucune perte de lignes. Elle reste un *candidat* à valider sur des séries indépendantes, car elle a été choisie après observation des scores.

Sélection conjointe interne. Pour mesurer ce que coûterait un choix automatique, une procédure a aussi choisi *dans la boucle interne* le schéma, l'imputation, la famille et les hyperparamètres. Ses R^2 externes sont 0,337 (YS), 0,334 (UTS), 0,164 (allongement) et −0,100 (Charpy), inférieurs à ceux de la forêt 16/médiane fixée : la sélection fluctue d'un pli à l'autre, signe de la fragilité du transfert. Enfin, régler les hyperparamètres par MSE plutôt que par MAE ne change presque rien (par exemple R^2 de la forêt pour UTS : 0,206 contre 0,194).

8.5 Effet du mode de découpage

Si la difficulté vient des séries, le même modèle devrait obtenir des scores très différents selon ce qui est séparé. Une forêt *identique*, sans réglage (300 arbres, feuille 2, profondeur libre, toutes les variables, graine 42), a été évaluée avec trois découpages (figure 18) : lignes aléatoires, conditions de soudage séparées (même signature des 16 entrées et du procédé), et séries séparées.

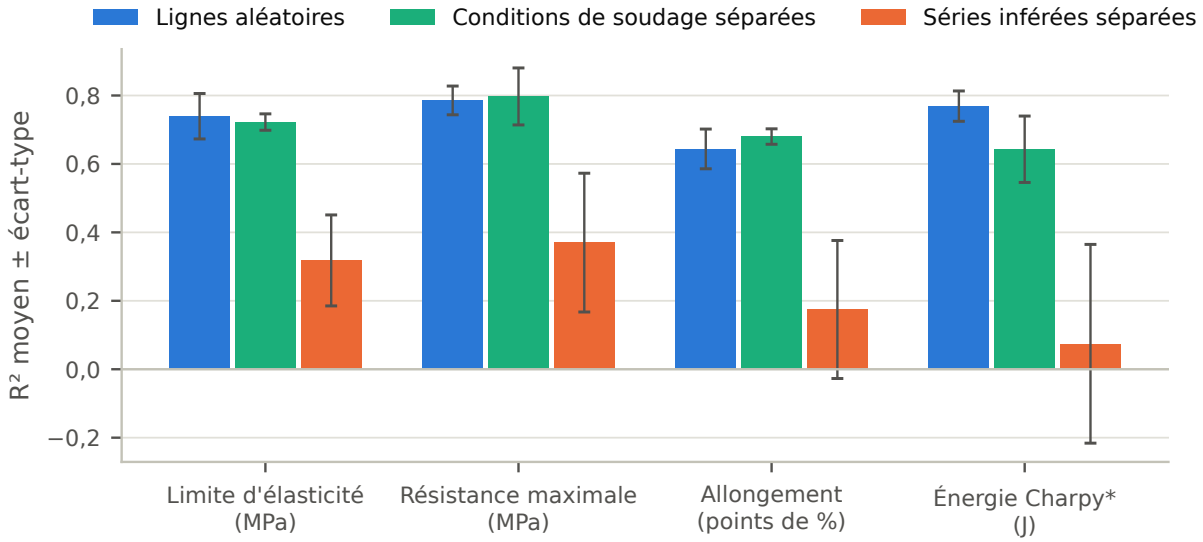


Figure 18. Même forêt aléatoire, sans réglage, configuration 16/médiane, sous trois découpages. Séparer des conditions de soudage répétées change peu le score ; séparer des séries entières le fait chuter.

Tableau 28. R^2 moyen de la forêt fixe selon le découpage, et structure des séries.

	R^2 moyen selon le découpage			Structure des séries	
Cible	Lignes	Conditions	Séries	Séries multi-conditions	Variance entre séries
YS	0,739	0,722	0,318	37 / 40	48,0 %
UTS	0,786	0,797	0,370	36 / 39	54,9 %
Allong.	0,644	0,680	0,175	33 / 34	54,4 %
Charpy	0,769	0,643	0,074	23 / 24	29,1 %

Pour la traction, séparer les conditions répétées ne fait presque pas baisser le score : le problème n'est pas une simple répétition de mesures identiques. En revanche, séparer des séries divise le R^2 par deux à quatre. Presque toutes les séries contiennent plusieurs conditions de soudage (37 sur 40 pour YS) : ce ne sont pas des doublons, mais des études cohérentes dont le « niveau » est propre. Un test de permutation (999 permutations) confirme que la part de variance des cibles portée par les séries (29 à 55 %) est très supérieure à ce qu'on obtiendrait par hasard (4 à 8 % au 95e centile ; $p = 0{,}001$). Ce test reste exploratoire : les répétitions limitent l'échangeabilité des lignes. Pour Charpy, 65 % des points de validation aléatoire partagent la condition de soudage d'un point du train (à une autre température), ce qui explique son R^2 aléatoire élevé.

8.6 Quantité de données : courbes d'apprentissage

La figure 19 fait varier la fraction des groupes du train (50, 75 et 100 %) sans toucher à la validation, avec deux graines.

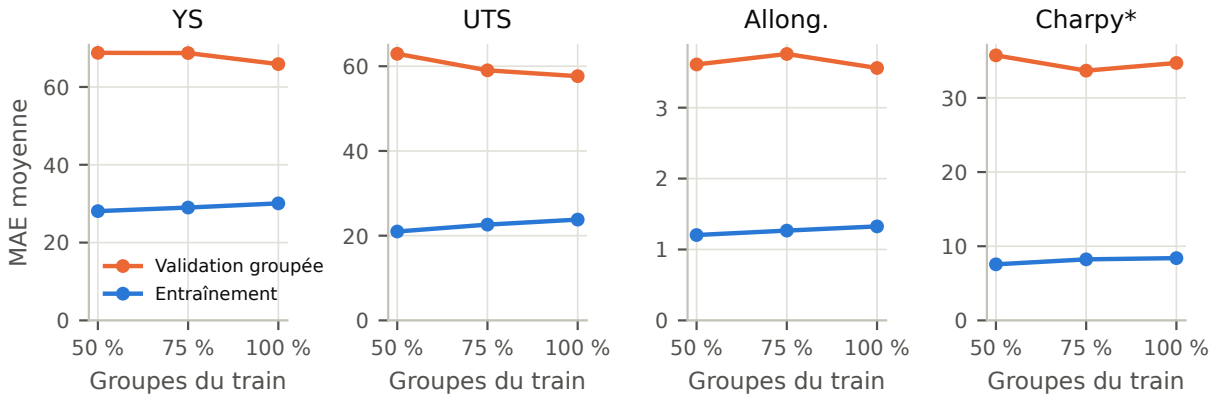


Figure 19. MAE d'entraînement et de validation groupée de la forêt (benchmark 13/itérative) en fonction de la fraction de groupes d'entraînement utilisée.

YS et UTS profitent de groupes supplémentaires (MAE UTS de 62,9 à 57,7 MPa), tandis que l'allongement et Charpy ne s'améliorent pas de façon monotone. Le large écart entre train et validation persiste : davantage de *séries diverses* semble plus utile que davantage de lignes d'une même série.

8.7 Explicabilité : quelles informations le modèle utilise-t-il ?

L'importance par permutation [12, 24] mesure la hausse de MAE lorsque l'on mélange aléatoirement une entrée (ou un bloc d'entrées corrélées) dans la validation, sans réentraîner le modèle. Les blocs sont : composition, paramètres de soudage, PWHT, procédé et, pour Charpy, température d'essai.

La figure 20 indique que la **composition** et le **PWHT** portent l'essentiel de l'information utilisée pour la résistance (hausse de MAE de 9,1 et 3,9 MPa pour YS ; 10,7 et 10,4 MPa pour UTS), que la composition domine pour l'allongement, et que la **température d'essai** domine pour Charpy (+7,5 J). Des contributions locales exactes, calculées le long des chemins des arbres, reconstruisent chaque prédiction et ont servi à analyser les plus grosses erreurs ; elles dépendent de l'ordre des coupures et ne sont pas des valeurs SHAP.

Précaution d'interprétation

Ces importances décrivent *le comportement du modèle*, pas des effets physiques causaux. Des entrées corrélées peuvent se substituer l'une à l'autre, et l'importance d'une variable dans un modèle faible n'établit pas une hiérarchie métallurgique.

8.8 Audit des protocoles Charpy

Pour Charpy, les séries ont été confrontées à leurs publications originales, par correspondance de compositions et de conditions (tableau 29).

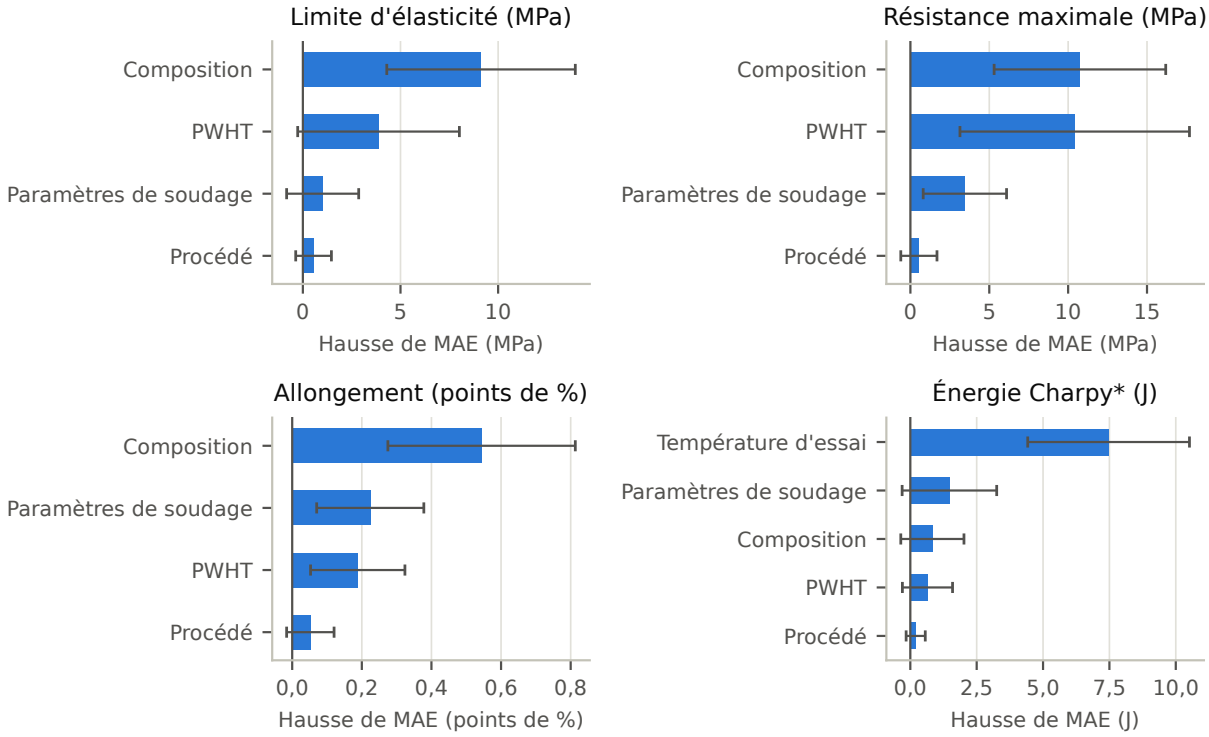


Figure 20. Importance par permutation de blocs d'entrées (forêt du benchmark 13/itérative, validation groupée, dix permutations par pli). Barres : hausse moyenne de MAE ; traits : écart-type entre répétitions et plis.

Tableau 29. Correspondance des séries Charpy avec leurs publications originales.

Série	Lignes	Constat
`SvenGret-1990` [25]	80	16 compositions et conditions concordantes ; énergies mesurées à cinq températures présélectionnées, cinq éprouvettes par température : **courbes $E(T)$ confirmées**
`Evans-StressRelief-1991` [26]	94	16 compositions et six conditions concordantes avec une publication de 1986 (malgré l'année 1991 de l'identifiant) : **famille de courbes de transition confirmée**
`Evans-Cr/CMn-1989` [5]	31	20 compositions concordantes ; la publication présente des températures à 100 J et les 31 couples valent 100 J : **extraction de températures de transition probable**
21 autres séries	656	Non résolues par leur publication originale

Dans la cohorte, 457 des 861 énergies (53,1 %) valent exactement 28 ou 100 J. Un point à 100 J appartient bien à la courbe $E(T)$, mais sa température a été choisie en fonction de l'énergie : il renseigne la position de la transition, pas toute la courbe. Mélanger ces règles d'échantillonnage peut modifier la distribution évaluée. Deux familles confirmées (174 points) ne suffisent pas à construire une nouvelle validation imbriquée par sources : **Charpy reste exploratoire**. L'audit a par ailleurs confirmé que la publication Svensson–Gretoft exprime Ti/Al/Sn/As/Sb en % massique, ce qui conforte la quarantaine des unités.

8.9 Bilan des diagnostics

À retenir

Établi : grand écart train/validation ; environ la moitié de l'erreur due à des décalages de niveau entre séries ; prédictions comprimées ; apport réel de Ni/Cr/Mo pour YS et UTS ; instabilité de l'imputation itérative à 16 entrées ; difficulté accrue hors du domaine du train pour Charpy ; règles d'échantillonnage Charpy hétérogènes.
Plausible mais non isolé : compositions ou états métallurgiques omis (Nb, V, Cu, Ti, B…), différences de protocoles entre séries, précision de transcription des labels.
Non démontré : que l'imputation explique les faibles scores ; qu'un bruit expérimental plafonne le R^2 sous 0,5 ; qu'une ACP ou un modèle multi-sorties résoudrait le problème ; que retirer les séries difficiles améliorerait la généralisation.

9 Résultats semi-supervisés : COREG

COREG (section 5.3) a été entraîné dans le notebook `notebooks/07_coreg.ipynb` pour les trois cibles de traction, avec la configuration 16/médiane, sous les deux protocoles de validation imbriquée et selon le protocole inductif de la section 6.4. Tous les vrais labels du train sont utilisés ; aucun label n'est masqué artificiellement. Charpy n'est pas concerné, son pool naturel étant vide. Au total : 180 évaluations externes et 576 ajustements COREG (choix internes, réapprentissages complets et sensibilité aux graines compris).

9.1 Méthodes comparées

Pour attribuer correctement un éventuel gain aux pseudo-labels, COREG est comparé à plusieurs contrôles évalués sur exactement les mêmes observations :

— **moyenne kNN L1/L2 au même k, sans pseudo-labels** : le contrôle *apparié*, qui ne diffère de COREG que par l'ajout de pseudo-labels ;
— **moyenne kNN L1/L2 réglée** : même architecture, k choisi indépendamment ;
— **kNN L1 seul** et **kNN L2 seul** ;
— **sélection supervisée** : la procédure de référence de la section 7.2, qui ne sert jamais à initialiser COREG.

9.2 Déroulement de la boucle

Le tableau 30 résume ce qui se passe dans les cinq ajustements externes de chaque cible et protocole.

Tableau 30. Déroulement de COREG dans les cinq plis externes (min–max sur les plis). « Pool distinct » : après déduplication et retrait des représentations déjà présentes parmi les vrais labels.

Protocole	Cible	Pool brut	Pool distinct	Pseudo-labels	Tours	Arrêts
Aléatoire	YS	679–680	224–234	118–170	61–91	5 sans gain positif
	UTS	702–703	249–258	70–158	38–82	5 sans gain positif
	Allong.	739–740	275–290	52–197	29–100	4 sans gain, 1 au maximum
Groupé	YS	651–696	143–240	80–200	42–100	2 sans gain, 2 max., 1 pool épuisé
	UTS	682–742	149–270	122–200	66–100	3 sans gain, 2 au maximum
	Allong.	725–763	189–293	80–200	42–100	2 sans gain, 3 au maximum

La déduplication réduit fortement le pool : sur environ 700 lignes sans label par pli, seules 140 à 290 représentations sont réellement nouvelles. Beaucoup de lignes non étiquetées décrivent des conditions déjà présentes parmi les labels. La figure 21 montre que chaque tour ajoute presque toujours deux pseudo-labels (un par régresseur) jusqu'à l'arrêt.

9.3 Performances

9.4 Gain apparié et robustesse

Le gain apparié compare COREG et le contrôle au même k sur les mêmes prédictions hors pli (gain positif = COREG réduit la MAE). L'intervalle est un bootstrap descriptif par séries (2 000 tirages).

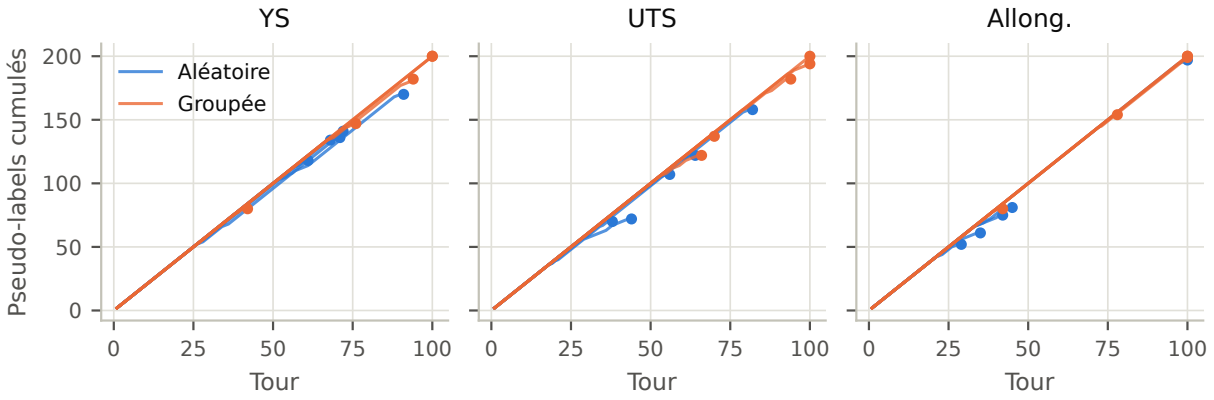


Figure 21. Nombre cumulé de pseudo-labels acceptés au fil des tours, pour chacun des cinq plis externes (un trait par pli ; point : arrêt). La croissance est quasi linéaire (deux ajouts par tour) jusqu'à l'absence de gain positif ou au plafond de 100 tours.

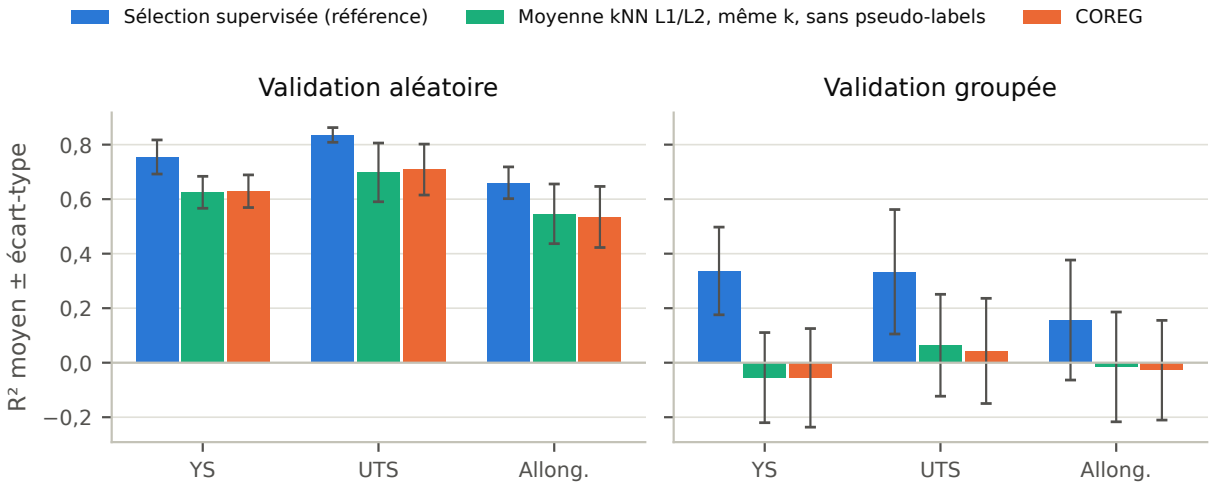


Figure 22. R^2 moyen (± écart-type) de COREG, de son contrôle apparié sans pseudo-labels et de la sélection supervisée de référence.

Tableau 31. COREG et contrôles : MAE moyenne et R^2 moyen sur les cinq plis externes.

		COREG		kNN même k		kNN réglés		Supervisé (réf.)	
Protocole	Cible	MAE	R^2	MAE	R^2	MAE	R^2	MAE	R^2
Aléatoire	YS (MPa)	37,919	0,629	38,241	0,625	38,241	0,625	**31,630**	**0,755**
	UTS (MPa)	33,037	0,709	33,319	0,698	33,319	0,698	**23,861**	**0,836**
	Allong. (pts)	2,402	0,535	2,392	0,546	2,392	0,546	**2,054**	**0,660**
Groupé	YS (MPa)	71,074	−0,056	70,817	−0,055	71,717	−0,080	**56,757**	**0,337**
	UTS (MPa)	63,060	0,043	62,081	0,064	62,081	0,064	**54,344**	**0,334**
	Allong. (pts)	3,904	−0,028	3,879	−0,015	3,879	−0,015	**3,517**	**0,157**

Tableau 32. Gain de MAE OOF de COREG par rapport au contrôle apparié (même k, sans pseudo-labels) et par rapport à la sélection supervisée.

		vs kNN même k		vs supervisé	
Protocole	Cible	Gain	Intervalle 95 %	Gain	Intervalle 95 %
Aléatoire	YS	0,322	[−0,060 ; 0,782]	−6,287	[−11,367 ; −2,070]
	UTS	0,283	[−0,154 ; 0,886]	−9,175	[−15,279 ; −3,679]
	Allong.	−0,011	[−0,035 ; 0,013]	−0,349	[−0,637 ; −0,011]
Groupé	YS	−0,272	[−1,144 ; 0,523]	−14,245	[−21,023 ; −6,827]
	UTS	−0,920	[−1,939 ; −0,275]	−7,721	[−18,425 ; 3,331]
	Allong.	−0,024	[−0,106 ; 0,029]	−0,382	[−0,780 ; −0,023]

Lecture des résultats.

— **Effet propre des pseudo-labels.** En aléatoire, COREG améliore très légèrement la MAE pour YS (0,32 MPa) et UTS (0,28 MPa), mais les intervalles couvrent zéro. En groupé, les trois gains sont négatifs, et celui d'UTS est entièrement négatif ([−1,94 ; −0,28] MPa).

— **Comparaison à la référence.** COREG est moins bon que la sélection supervisée dans **les six cas**, de 6 à 14 MPa sur la résistance.

— **Graines.** Avec les graines de base 43 et 44 et le même k, les MAE varient de moins de 0,5 MPa (par exemple UTS aléatoire : 33,04 ; 32,98 ; 33,31) : la conclusion ne dépend pas du tirage des candidats.

9.5 Pourquoi COREG n'apporte-t-il pas de gain ici ?

Plusieurs explications sont cohérentes avec les mesures, sans qu'aucune ne soit isolée comme cause unique :

1. **Le régresseur de base est faible hors série.** Les kNN sans pseudo-labels ont déjà un R^2 proche de zéro en groupé. COREG ne peut que *propager* leurs estimations ; il ne crée pas l'information physique manquante qui permettrait de corriger un décalage entre séries.
2. **Le pool apporte peu de diversité.** Après déduplication, seule une fraction du pool est nouvelle, et ces lignes proviennent des mêmes séries que les labels.
3. **La confiance est locale.** Le gain Δ_u mesure la cohérence d'une estimation avec ses voisins étiquetés, pas son exactitude ; les deux kNN partagent les mêmes entrées et peuvent renforcer une erreur commune.
4. **Le budget de labels est complet.** Le semi-supervisé est surtout utile lorsque les labels sont rares ; ici tous les labels disponibles sont utilisés. Un scénario à 25 ou 50 % de labels serait une expérience distincte.

9.6 Modèles exportés

Une nouvelle CV5 sur tous les labels (aléatoire graine 1042, ou par groupes) a choisi k pour les réapprentissages complets : $k = 3$ pour les trois cibles en aléatoire (82, 44 et 41 pseudo-labels

ajoutés), $k = 15$, 5 et 3 en groupé pour YS, UTS et l'allongement (200, 186 et 14 pseudo-labels). Au total **108 pipelines** sont exportées (90 de plis externes et 18 complètes, contrôles inclus). Un audit indépendant a recalculé les 180 scores, vérifié l'isolement des données pour les 576 ajustements et leurs 81 931 pseudo-labels, et recalculé explicitement 1 410 gains.

À retenir

COREG a été mis en œuvre selon un protocole inductif rigoureux et comparé à son exact pendant supervisé. Il **n'apporte pas de gain significatif** : gains de l'ordre de 0,3 MPa non significatifs en aléatoire, gains négatifs en groupé, et il reste nettement en dessous de la sélection supervisée dans tous les cas. Les modèles supervisés restent la référence pour cette base.

10 Analyse comparative et discussion

10.1 Vue d'ensemble des approches

Le tableau 33 rassemble, pour la limite d'élasticité, les principales approches évaluées au cours du projet. Les autres cibles suivent le même schéma (sections 7 et 9).

Tableau 33. Récapitulatif des approches pour YS : R^2 moyen sur cinq plis externes.

Approche	Entrées / imputation	R^2 aléatoire	R^2 groupé
Référence médiane de y	–	−0,031	−0,073
Forêt aléatoire, premier benchmark	13 / itérative	–	0,079
Forêt aléatoire	13 / médiane	–	0,102
Forêt aléatoire	16 / médiane	0,765	0,390
Sélection conjointe interne (schéma, imputation, famille)	11–16 / les deux	–	0,337
Sélection interne de la famille (référence)	**16 / médiane**	**0,755**	**0,337**
kNN réglé	16 / médiane	0,619	−0,140
COREG (semi-supervisé)	16 / médiane	0,629	−0,056

Trois enseignements en découlent :

1. **Les entrées comptent davantage que l'algorithme.** Passer de 13 à 16 entrées fait passer le R^2 groupé de la forêt de 0,10 à 0,39, alors que changer de famille à entrées fixées modifie beaucoup moins le score.
2. **Le protocole change la conclusion.** Toutes les familles apprises perdent entre 0,3 et 0,8 point de R^2 entre validation aléatoire et groupée ; les méthodes locales (kNN, COREG) deviennent même pires que la constante.
3. **Le semi-supervisé n'aide pas ici.** Exploiter les entrées sans label n'apporte pas l'information qui manque pour transférer entre séries.

10.2 Quelle approche est la plus appropriée ?

Décision et justification

L'approche recommandée est la **procédure supervisée 16 entrées + procédé, imputation médiane apprise dans le train, avec choix de la famille et des hyperparamètres par validation interne**. En pratique, cette procédure retient une **SVR RBF** ou une **forêt aléatoire** selon la cible (tableau 23) ; la forêt est la plus robuste lorsque la série est inconnue. COREG est conservé comme expérience semi-supervisée documentée, pas comme modèle de référence.

Le niveau de confiance à accorder dépend toutefois de l'usage :

— **Soudure proche d'une série déjà documentée** (même procédé, mêmes familles de composition) : l'erreur typique attendue est d'environ 30 MPa sur YS, 25 MPa sur UTS et 2 points d'allongement — un ordre de grandeur utile pour pré-sélectionner des recettes avant essais.

— **Soudure d'une nouvelle étude, procédé ou famille d'alliage** : l'erreur double (environ 55 MPa sur YS et UTS) et le R^2 chute sous 0,35. Le modèle ne remplace pas l'essai mécanique ; il peut au mieux orienter.

— **Énergie Charpy** : les prédictions restent exploratoires tant que les protocoles ne sont pas harmonisés ; elles ne doivent pas servir à une décision de ténacité.

10.3 Limites de l'étude

— **Sélection rétrospective.** Le passage à 16/médiane a été décidé après observation des scores groupés sur ces mêmes données. Même avec une validation imbriquée ensuite, l'ensemble de la démarche n'a pas été validé sur un jeu indépendant.

— **Groupes imparfaits.** Les séries sont inférées des identifiants : elles peuvent fusionner ou séparer des publications. Elles restent des approximations des vraies unités d'indépendance.

— **Données hétérogènes.** Compositions incomplètes, unités douteuses en quarantaine, protocoles Charpy non harmonisés, précision de transcription inconnue.

— **Entrées omises.** Des éléments exclus pour leur faible couverture (Nb, V, Ti, B, Cu…) peuvent expliquer une partie des décalages entre séries.

— **Incertitude.** Les intervalles rapportés sont descriptifs ; aucune prédiction n'est accompagnée d'un intervalle de prédiction calibré.

— **Semi-supervisé.** Une seule méthode, un seul budget de labels (complet) ; d'autres variantes (régresseurs différents, labels rares) restent à explorer.

10.4 Recommandations

L'énoncé demande nos recommandations pour obtenir une bonne qualité de soudure. Les modèles mettent en évidence des *associations*, pas des causes : nous séparons donc ce que les données permettent d'affirmer de ce qui demanderait des essais dédiés.

Ce que l'étude permet de recommander.

1. **Mesurer et enregistrer la composition complète**, y compris Ni, Cr et Mo : leur ajout réduit l'erreur de 9 à 11 MPa sur la résistance, alors qu'ils manquent dans plus de la moitié des lignes. Une valeur mesurée vaut mieux qu'une valeur imputée.
2. **Documenter le traitement thermique après soudage** (température, durée) : avec la composition, c'est le bloc d'information le plus utilisé par les modèles pour prédire la résistance.
3. **Enregistrer les protocoles d'essai**, en particulier pour Charpy : distinguer une énergie mesurée à température imposée d'une température de transition, et conserver des courbes $E(T)$ complètes.
4. **Identifier les séries, éprouvettes et publications** dans les bases, afin de pouvoir valider honnêtement le transfert à de nouvelles études.
5. **Valider tout modèle sur de nouvelles séries** avec de vraies mesures avant un usage opérationnel, et signaler les soudures hors du domaine du train (procédé inconnu, compositions

extrêmes), où l'erreur augmente nettement.

6. **Privilégier la diversité des études** plutôt que le nombre de lignes : les courbes d'apprentissage suggèrent que de nouvelles séries sont plus informatives que de nouvelles répétitions.

Ce que l'étude ne permet pas d'affirmer. Aucun réglage de soudage « optimal », aucun seuil universel de bonne soudure et aucun effet causal d'un élément ou d'un paramètre n'est démontré. Les importances indiquent *quelles* informations le modèle utilise, pas *dans quel sens* modifier une recette. Pour formuler des recommandations de procédé (composition cible, apport thermique, PWHT), il faudrait des plans d'expériences contrôlés et l'expertise de métallurgistes du soudage.

À retenir

La procédure supervisée 16/médiane (SVR ou forêt aléatoire selon la cible) est l'approche la plus appropriée. Elle est fiable pour interpoler dans des séries connues, nettement moins pour de nouvelles études. Les leviers d'amélioration sont avant tout la **qualité et la complétude des données** : composition complète, PWHT, protocoles d'essai et identification des séries.

11 Conclusion et perspectives

Ce projet a traité la prédiction de la qualité de soudures d'acier comme un ensemble de **régressions supervisées** sur des propriétés mécaniques mesurées. L'analyse exploratoire a révélé une base compilée à partir de séries expérimentales, avec des absences dépendant du procédé, des valeurs censurées, des unités douteuses et des protocoles Charpy hétérogènes. Une préparation entièrement traçable, un prétraitement appris dans chaque pli et une validation croisée imbriquée selon deux scénarios ont permis une comparaison rigoureuse de cinq familles supervisées et d'une méthode semi-supervisée.

Les résultats tiennent en trois phrases. **(1)** Avec 16 entrées et une imputation médiane, la forêt aléatoire et la SVR RBF prédisent bien les soudures de séries connues (R^2 de 0,66 à 0,84). **(2)** Le transfert à des séries absentes reste difficile (R^2 de 0,08 à 0,34), principalement à cause de décalages de niveau entre études que les entrées disponibles n'expliquent pas. **(3)** COREG n'améliore pas la référence supervisée, car les entrées sans label n'apportent pas l'information manquante.

Perspectives.

— **Validation indépendante** : évaluer la procédure retenue sur de nouvelles séries jamais utilisées pour la concevoir.

— **Enrichir les entrées** : réintégrer Nb, V, Ti, B ou Cu après vérification des unités par source, et tester leur apport par validation groupée.

— **Harmoniser Charpy** : poursuivre l'audit des 21 séries non résolues, séparer courbes $E(T)$ et températures de transition, puis construire une tâche homogène.

— **Quantifier l'incertitude** : intervalles de prédiction (forêts quantiles, prédiction conforme) et détection des entrées hors domaine.

— **Modèles hiérarchiques** : modéliser explicitement un effet aléatoire de série pour séparer variabilité intra- et inter-études.
— **Semi-supervisé** : tester COREG et d'autres méthodes dans un régime à labels rares (25 ou 50 %), où leur intérêt théorique est le plus grand.

12 Organisation du projet et diagramme de Gantt

12.1 Méthode de travail

Le travail a été organisé autour d'un dépôt Git commun (tableau 1) : une branche par tâche, des modèles d'*issue* et de *pull request*, une spécification vivante (`specs/spec.md`) consignant chaque décision scientifique, des rapports intermédiaires datés et une suite de tests ciblés. Le fichier `specs/time_log.csv` est prévu pour enregistrer le temps passé par membre et par séance.

12.2 Chronologie et diagramme de Gantt

La figure 23 retrace les grandes phases du projet. Les dates proviennent de l'historique Git et des dates portées par les rapports intermédiaires : elles indiquent *quand* chaque livrable a été produit ou versionné, pas la durée de travail effective.

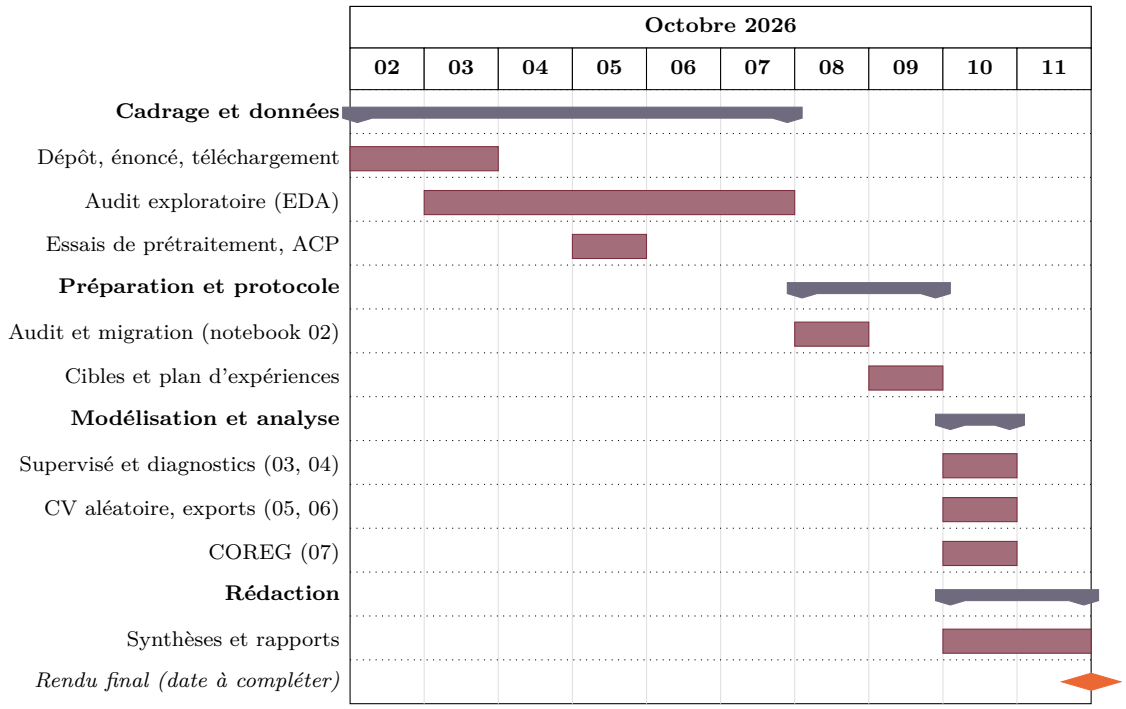


Figure 23. Diagramme de Gantt des phases du projet, d'après l'historique Git et les dates des rapports intermédiaires. Les responsables et les heures réelles sont à renseigner dans le tableau 34 ; la date de rendu est indicative.

12.3 Répartition des tâches et temps passé

L'énoncé demande d'indiquer, pour chaque tâche, le temps qu'elle a pris et le membre de l'équipe qui s'en est chargé. Ces informations ne sont pas déductibles des fichiers du dépôt (le journal de temps est vide) : elles sont laissées *à compléter par l'équipe*, sans être inventées. Les durées de calcul des notebooks (quelques minutes chacun) ne sont pas des durées de travail humain.

Tableau 34. Répartition des tâches. Colonnes « Membre(s) » et « Heures » à compléter par l'équipe à partir de `specs/time_log.csv`.

Tâche	Livrables	Membre(s)	Heures
Cadrage, dépôt, téléchargement des données	`scripts/`, `specs/`	**[À compléter]**	**[À compléter]**
Analyse exploratoire et audit des mesures	notebook 01, rapport 01	**[À compléter]**	**[À compléter]**
Prétraitement, groupes, cohorte, plis	notebook 02, rapports 02–08	**[À compléter]**	**[À compléter]**
Plan d'expériences, choix des cibles	rapport 09, `spec.md`	**[À compléter]**	**[À compléter]**
Entraînement supervisé	notebooks 03, 05, 06	**[À compléter]**	**[À compléter]**
Diagnostics et explicabilité	notebook 04, rapport 11	**[À compléter]**	**[À compléter]**
Bibliographie et COREG	notebook 07, rapport 14	**[À compléter]**	**[À compléter]**
Tests et reproductibilité	`tests/`, manifestes	**[À compléter]**	**[À compléter]**
Rédaction et relecture croisée	rapports 15, 16, présent rapport	**[À compléter]**	**[À compléter]**
Total			**[À compléter]**

À retenir

Le projet s'est déroulé du 2 au 10 octobre 2026 pour sa partie technique, en quatre phases : cadrage et données, préparation et protocole, modélisation et analyse, rédaction. La répartition des tâches et les heures réelles restent à renseigner par l'équipe.

Références bibliographiques

[1] T. Cool and H. K. D. H. Bhadeshia. MAP_DATA_WELD : base de données de dépôts de soudure d'acier. Université de Cambridge, Materials Algorithms Project, s.d. URL https://www.phase-trans.msm.cam.ac.uk/map/data/materials/welddb-b.html. Documentation des colonnes et des unités, consultée le 10 octobre 2026.

[2] Z.-H. Zhou and M. Li. Semi-supervised regression with co-training. In *Proceedings of the 19th International Joint Conference on Artificial Intelligence (IJCAI)*, pages 908–913, 2005. URL https://www.ijcai.org/Proceedings/05/Papers/0689.pdf.

[3] T. Cool. *Design of Steel Weld Deposits*. PhD thesis, University of Cambridge, 1996. URL https://www.phase-trans.msm.cam.ac.uk/2012/Cool_Thesis.pdf. Section 6.4 : modèle de ténacité Charpy.

[4] R. J. A. Little and D. B. Rubin. *Statistical Analysis with Missing Data*. Wiley, 3 edition, 2019.

[5] G. M. Evans. Effect of chromium on the microstructure and properties of C-Mn all-weld metal deposits. Publication accessible via ResearchGate, 1989. URL https://www.researchgate.net/publication/326989878.

[6] I. T. Jolliffe and J. Cadima. Principal component analysis : a review and recent developments. *Philosophical Transactions of the Royal Society A*, 374(2065) :20150202, 2016.

[7] H. K. D. H. Bhadeshia, D. J. C. MacKay, and L.-E. Svensson. Impact toughness of C-Mn steel arc welds – Bayesian neural network analysis. *Materials Science and Technology*, 11(10) : 1046–1051, 1995. URL https://www.phase-trans.msm.cam.ac.uk/abstracts/toughness.pdf.

[8] S. van Buuren and K. Groothuis-Oudshoorn. mice : Multivariate imputation by chained equations in R. *Journal of Statistical Software*, 45(3) :1–67, 2011.

[9] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn : Machine learning in Python. *Journal of Machine Learning Research*, 12 :2825–2830, 2011.

[10] A. E. Hoerl and R. W. Kennard. Ridge regression : biased estimation for nonorthogonal problems. *Technometrics*, 12(1) :55–67, 1970.

[11] A. J. Smola and B. Schölkopf. A tutorial on support vector regression. *Statistics and Computing*, 14(3) :199–222, 2004.

[12] L. Breiman. Random forests. *Machine Learning*, 45(1) :5–32, 2001.

[13] T. M. Cover and P. E. Hart. Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1) :21–27, 1967.

[14] O. Chapelle, B. Schölkopf, and A. Zien, editors. *Semi-Supervised Learning*. MIT Press, 2006.

[15] J. E. van Engelen and H. H. Hoos. A survey on semi-supervised learning. *Machine Learning*, 109(2) :373–440, 2020.

[16] D. Yarowsky. Unsupervised word sense disambiguation rivaling supervised methods. In *Pro-*

ceedings of the 33rd Annual Meeting of the Association for Computational Linguistics, pages 189–196, 1995.

[17] A. Blum and T. Mitchell. Combining labeled and unlabeled data with co-training. In *Proceedings of the 11th Annual Conference on Computational Learning Theory (COLT)*, pages 92–100, 1998.

[18] X. Zhu and Z. Ghahramani. Learning from labeled and unlabeled data with label propagation. Technical Report CMU-CALD-02-107, Carnegie Mellon University, 2002.

[19] Scikit-learn developers. Cross-validation : evaluating estimator performance. Guide utilisateur de scikit-learn, s.d. URL https://scikit-learn.org/stable/modules/cross_validation.html. Consulté le 10 octobre 2026.

[20] S. Varma and R. Simon. Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics*, 7 :91, 2006.

[21] G. C. Cawley and N. L. C. Talbot. On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, 11 :2079–2107, 2010.

[22] D. R. Roberts, V. Bahn, S. Ciuti, M. S. Boyce, J. Elith, G. Guillera-Arroita, S. Hauenstein, J. J. Lahoz-Monfort, B. Schröder, W. Thuiller, D. I. Warton, B. A. Wintle, F. Hartig, and C. F. Dormann. Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8) :913–929, 2017.

[23] B. Efron and R. J. Tibshirani. *An Introduction to the Bootstrap*. Chapman & Hall, 1993.

[24] A. Fisher, C. Rudin, and F. Dominici. All models are wrong, but many are useful : learning a variable's importance by studying an entire class of prediction models simultaneously. *Journal of Machine Learning Research*, 20(177) :1–81, 2019.

[25] L.-E. Svensson and B. Gretoft. Microstructure and impact toughness of C-Mn weld metals. *Welding Journal*, 69(12), 1990. URL https://canteach.candu.org/content%20library/20053409.pdf. Supplément de recherche, p. 454-s et suivantes.

[26] G. M. Evans. The effect of stress relieving on the microstructure and properties of C-Mn all-weld metal deposits. *Welding Journal*, 65, 1986. URL https://www.researchgate.net/publication/277011176. Supplément de recherche, p. 326-s et suivantes.

A Dictionnaire des variables

Positions et unités d'après la documentation de la base [1] ; noms utilisés dans les notebooks. Colonne « Usage » : E11/E13/E16 = entrée des schémas 11, 13 ou 16 (tableau 10) ; C = cible ; X = non utilisée.

Tableau 35. Les 44 champs de la Cambridge Weld Database.

Pos.	Nom (notebooks)	Signification	Unité	Usage
1	`C`	Carbone	% massique	E11
2	`Si`	Silicium	% massique	E11
3	`Mn`	Manganèse	% massique	E11
4	`S`	Soufre	% massique	E11
5	`P`	Phosphore	% massique	E11
6	`Ni`	Nickel	% massique	E16
7	`Cr`	Chrome	% massique	E16
8	`Mo`	Molybdène	% massique	E16
9	`V`	Vanadium	% massique	X
10	`Cu`	Cuivre	% massique	X
11	`Co`	Cobalt	% massique	X
12	`W`	Tungstène	% massique	X
13	`O_ppm`	Oxygène	ppm	E13
14	`Ti_ppm`	Titane	ppm (unité à revoir)	X
15	`N_ppm`	Azote	ppm	E13
16	`Al_ppm`	Aluminium	ppm (unité à revoir)	X
17	`B_ppm`	Bore	ppm	X
18	`Nb_ppm`	Niobium	ppm	X
19	`Sn_ppm`	Étain	ppm (unité à revoir)	X
20	`As_ppm`	Arsenic	ppm (unité à revoir)	X
21	`Sb_ppm`	Antimoine	ppm (unité à revoir)	X
22	`current_A`	Courant de soudage	A	E11
23	`voltage_V`	Tension	V	E11
24	`ac_dc`	Type de courant (AC/DC)	catégoriel	X
25	`polarity`	Polarité de l'électrode	catégoriel	X
26	`heat_input_kJmm`	Apport thermique	kJ/mm	E11
27	`interpass_C`	Température entre passes	°C	E11
28	`weld_type`	Procédé de soudage	catégoriel	tous schémas
29	`pwht_temp_C`	Température du traitement après soudage	°C	E11
30	`pwht_time_h`	Durée du traitement après soudage	h	E11
31	`yield_strength`	Limite d'élasticité	MPa	C

Pos.	Nom (notebooks)	Signification	Unité	Usage
32	`uts`	Résistance maximale à la traction	MPa	C
33	`elongation`	Allongement	%	C
34	`reduction_area`	Réduction de section	%	X (complémentaire)
35	`charpy_temp_C`	Température d'essai Charpy	°C	entrée Charpy
36	`charpy_J`	Énergie Charpy	J	C (exploratoire)
37	`hardness`	Dureté (protocole Vickers séparé)	kg/mm^2	X
38	`fatt50`	Température de transition à 50 % de rupture ductile	non documentée	X
39	`prim_ferrite`	Ferrite primaire	%	X
40	`ferrite_2nd_phase`	Ferrite à seconde phase	%	X
41	`acicular_ferrite`	Ferrite aciculaire	%	X
42	`martensite`	Martensite	%	X
43	`ferrite_carbide`	Agrégat ferrite-carbure	%	X
44	`weld_id`	Identifiant de la soudure et de sa source	texte	X (sert aux groupes)

Dans la table maître, le procédé est stocké en `weld_type_raw` (brut) et `weld_process` (synonymes regroupés) ; la dureté en `hardness_value` et `hardness_protocol`. Les colonnes `n_unavail_A1_13`, `in_strict13` et `has_<cible>` définissent la cohorte et l'éligibilité de chaque cible.

B Reproductibilité

B.1 Environnement

Les expériences ont été exécutées avec Python 3.14.8, scikit-learn 1.9.1, NumPy 2.5.3, pandas 3.0.6, joblib 1.6.0 et cloudpickle 3.1.2 ; les versions exactes sont enregistrées dans chaque manifeste d'expérience. Le fichier brut `welddb.data` a pour empreinte SHA-256 :

`eb46df81a454c8e549187d87c67a6e72b88676f760e8688a782c832737676ac1`

B.2 Commandes

Depuis la racine du dépôt :

```
python -m venv .venv && source .venv/bin/activate
python -m pip install -r requirements.txt
python scripts/download_data.py           # archive vérifiée par SHA-256
python -m jupyterlab                      # exécuter 01 -> 07 de haut en bas
python -m unittest discover -s tests -v   # 37 tests ciblés hors ligne
python rapport_latex/scripts/generer_figures.py
cd rapport_latex && latexmk -pdf main.tex
```

B.3 Notebooks, durées et exports

Tableau 36. Notebooks, durée de calcul rapportée dans les rapports d'exécution et exports produits (ignorés par Git).

Notebook	Rôle et exports	Durée
01_eda	Statuts, distributions, ACP descriptive ; aucun export d'entraînement	non mesurée
02_data_preparation	Table maître, provenance, alias, groupes, plis, cellules en quarantaine, manifeste (`data/processed/modeling/`)	non mesurée
03_modeling	Benchmark 13/itérative groupé : 100 évaluations, 2 440 ajustements (`salh_supervised_v1/`)	≈ 6 min
04_diagnostics	Erreurs par série, sensibilités 11/13/16, permutations, audit Charpy (`salh_diagnostics_v1/`)	non mesurée
05_random_kfold	CV aléatoire 16/médiane, 40 pipelines (`salh_random_kfold_v1/`)	≈ 7 min
06_grouped_exports	CV groupée 16/médiane, 40 pipelines (`salh_group_kfold_v1/`)	≈ 2 min
07_coreg	COREG, contrôles, 108 pipelines (`salh_coreg_v1/`)	≈ 10 min

Les modèles sont sérialisés sous `models/` avec un fichier JSON compagnon (entrées, unités, identifiants du train, paramètres, graines, versions, SHA-256) : 40 pipelines pour la CV aléatoire, 40 pour la CV groupée et 108 pour COREG, soit **188 pipelines**. Chaque dossier possède un index `selected_models.json`. Les modèles réentraînés sur tous les labels servent à l'inférence uniquement.

B.4 Contrôles automatiques

La suite de 37 tests hors ligne vérifie notamment : l'intégrité des archives, la classification des statuts de mesure, les doublons et les groupes, l'apprentissage des statistiques dans le seul train, la préservation des valeurs observées, les erreurs explicites (PWHT, non-convergence), l'étanchéité des recherches imbriquées, l'échelle des cibles de la SVR, les frontières des pools inductifs, et, pour COREG, l'égalité du gain local calculé avec un réapprentissage explicite. Des audits indépendants recalculent les métriques à partir des prédictions exportées et rechargent tous les modèles dans un processus Python neuf.

B.5 Figures de ce rapport

Les figures du dossier `rapport_latex/figures/` sont produites par le script `rapport_latex/scripts/generer_figures.py`, qui relit le fichier brut et les exports des notebooks sans réentraîner aucun modèle. Le script affiche les valeurs clés recalculées (effectifs, variance expliquée par l'ACP) afin de vérifier leur cohérence avec le texte.

C Tableaux complémentaires

C.1 Familles supervisées, configuration 16/médiane

C.2 COREG : dispersion et scores OOF

C.3 Reconstruction de valeurs Ni/Cr/Mo masquées

Tableau 37. Validation aléatoire : chaque famille réglée en interne (moyenne ± écart-type sur 5 plis ; RMSE moyenne).

Cible	Modèle	MAE	RMSE	R^2
YS (MPa)	Médiane de y	70,032 ± 4,087	92,774	−0,031 ± 0,040
	Ridge	54,047 ± 3,440	70,005	0,412 ± 0,053
	SVR RBF	31,747 ± 3,900	45,403	0,754 ± 0,046
	Forêt aléatoire	31,242 ± 4,038	44,172	0,765 ± 0,064
	kNN	38,144 ± 2,497	56,273	0,619 ± 0,059
UTS (MPa)	Médiane de y	68,879 ± 4,438	91,419	−0,050 ± 0,019
	Ridge	44,319 ± 3,535	60,137	0,538 ± 0,118
	SVR RBF	23,861 ± 0,906	35,989	0,836 ± 0,027
	Forêt aléatoire	26,906 ± 1,907	39,165	0,805 ± 0,045
	kNN	33,452 ± 4,870	48,626	0,697 ± 0,098
Allong. (pts)	Médiane de y	4,019 ± 0,149	4,903	−0,015 ± 0,019
	Ridge	3,011 ± 0,152	3,923	0,345 ± 0,119
	SVR RBF	2,268 ± 0,198	3,227	0,556 ± 0,094
	Forêt aléatoire	2,054 ± 0,239	2,835	0,660 ± 0,058
	kNN	2,423 ± 0,260	3,305	0,530 ± 0,117
Charpy* (J)	Médiane de y	36,756 ± 2,813	51,989	−0,069 ± 0,037
	Ridge	26,913 ± 0,587	34,170	0,529 ± 0,113
	SVR RBF	17,393 ± 0,988	25,068	0,749 ± 0,043
	Forêt aléatoire	16,099 ± 1,027	22,636	0,795 ± 0,035
	kNN	19,253 ± 1,518	29,586	0,651 ± 0,055

Tableau 38. Validation groupée : chaque famille réglée en interne (moyenne ± écart-type sur 5 plis ; RMSE moyenne).

Cible	Modèle	MAE	RMSE	R^2
YS (MPa)	Médiane de y	70,449 ± 10,682	92,501	−0,073 ± 0,052
	Ridge	69,387 ± 6,953	88,202	−0,025 ± 0,362
	SVR RBF	59,350 ± 9,755	76,275	0,264 ± 0,144
	Forêt aléatoire	54,139 ± 10,658	69,570	0,390 ± 0,132
	kNN	73,496 ± 9,189	94,956	−0,140 ± 0,151
UTS (MPa)	Médiane de y	72,664 ± 15,237	93,729	−0,180 ± 0,114
	Ridge	61,898 ± 13,272	77,232	0,179 ± 0,152
	SVR RBF	52,861 ± 11,679	70,542	0,316 ± 0,145
	Forêt aléatoire	48,905 ± 7,269	65,236	0,394 ± 0,160
	kNN	68,538 ± 14,821	90,258	−0,115 ± 0,121
Allong. (pts)	Médiane de y	4,086 ± 0,309	4,962	−0,062 ± 0,047
	Ridge	3,658 ± 0,362	4,735	0,016 ± 0,229
	SVR RBF	3,670 ± 0,345	4,534	0,106 ± 0,167
	Forêt aléatoire	3,339 ± 0,342	4,218	0,226 ± 0,146
	kNN	3,983 ± 0,328	4,908	−0,060 ± 0,223
Charpy* (J)	Médiane de y	36,035 ± 16,909	50,603	−0,149 ± 0,251
	Ridge	34,752 ± 10,268	45,433	0,069 ± 0,213
	SVR RBF	35,963 ± 8,404	44,879	0,091 ± 0,206
	Forêt aléatoire	33,033 ± 10,974	43,560	0,138 ± 0,209
	kNN	35,725 ± 12,222	48,624	−0,099 ± 0,354

Tableau 39. COREG : moyenne ± écart-type sur les plis et scores OOF réunis.

Protocole	Cible	MAE moyenne	R^2 moyen	MAE OOF	R^2 OOF
Aléatoire	YS (MPa)	37,919 ± 3,151	0,629 ± 0,060	37,913	0,631
	UTS (MPa)	33,037 ± 4,905	0,709 ± 0,093	33,038	0,707
	Allong. (pts)	2,402 ± 0,258	0,535 ± 0,112	2,403	0,538
Groupé	YS (MPa)	71,074 ± 14,263	−0,056 ± 0,181	71,780	−0,051
	UTS (MPa)	63,060 ± 15,175	0,043 ± 0,193	61,470	0,146
	Allong. (pts)	3,904 ± 0,311	−0,028 ± 0,183	3,883	0,018

Tableau 40. Sensibilité de COREG à la graine de tirage des candidats (k fixé par la sélection interne du calcul principal) : MAE moyenne et R^2 moyen.

		Graine 42		Graine 43		Graine 44	
Protocole	Cible	MAE	R^2	MAE	R^2	MAE	R^2
Aléatoire	YS	37,919	0,629	37,990	0,628	38,203	0,627
	UTS	33,037	0,709	32,976	0,709	33,314	0,703
	Allong.	2,402	0,535	2,397	0,535	2,396	0,538
Groupé	YS	71,074	−0,056	70,873	−0,054	70,868	−0,051
	UTS	63,060	0,043	62,707	0,049	63,083	0,040
	Allong.	3,904	−0,028	3,887	−0,018	3,888	−0,023

Tableau 41. Erreur absolue moyenne (% massique) de reconstruction de 20 % des valeurs observées de Ni, Cr et Mo masquées en validation, imputeur ajusté sur le train ; mêmes cellules pour les deux méthodes.

		Ni		Cr		Mo	
Contexte	Imputation	n	MAE	n	MAE	n	MAE
YS	médiane	71	0,388	71	1,612	70	0,388
	itérative	71	0,419	71	1,419	70	0,313
UTS	médiane	45	0,439	52	1,556	43	0,370
	itérative	45	0,537	52	1,705	43	0,399
Allong.	médiane	58	0,325	64	1,098	58	0,407
	itérative	58	0,723	64	1,945	58	0,362
Charpy	médiane	33	0,782	40	1,504	30	0,696
	itérative	33	1,035	40	4,792	30	1,060

D Glossaire

Apport thermique Énergie électrique fournie par unité de longueur de soudure (kJ/mm) ; dépend du courant, de la tension et de la vitesse de soudage.

Biais d'une série Erreur moyenne (prédit − observé) des observations d'une même série ; un biais non nul signifie que le modèle se trompe de niveau pour toute la série.

Bootstrap par groupes Rééchantillonnage avec remise des séries (et non des lignes) pour estimer la variabilité d'un indicateur lorsque les lignes d'une série sont dépendantes.

Censure Valeur rapportée seulement comme inférieure à une limite de détection (`<L`).

Charpy (essai) Essai de choc sur éprouvette entaillée mesurant l'énergie absorbée à la rupture (J) à une température donnée ; renseigne sur la ténacité.

Cohorte Population de lignes retenue pour la modélisation (ici : au plus deux entrées manquantes sur 13, sans doublon).

COREG Méthode de co-apprentissage pour la régression : deux kNN s'échangent des pseudo-labels choisis par réduction locale d'erreur.

Fuite d'information Utilisation, pendant l'apprentissage, d'une information issue des données de validation ; elle rend les scores optimistes.

GroupKFold Validation croisée qui place toutes les observations d'un même groupe dans le même pli.

Imputation Remplacement d'une entrée manquante par une valeur estimée (médiane, régression itérative…) ; ce n'est pas une mesure.

Inductif / transductif Un protocole semi-supervisé est inductif s'il n'utilise jamais les entrées de validation pendant l'apprentissage, transductif s'il les exploite sans leurs labels.

MAE, RMSE, R^2 Erreur absolue moyenne, racine de l'erreur quadratique moyenne, coefficient de détermination (section 6.3).

OOF (*out-of-fold*) Prédiction faite pour une observation par le modèle du pli où elle était en validation ; l'ensemble des OOF couvre chaque label une fois.

Pipeline Enchaînement d'étapes de prétraitement et d'un estimateur, ajusté en bloc sur le train puis appliqué tel quel à de nouvelles données.

Pli (*fold*) Partie des données tenue à l'écart pour l'évaluation pendant une itération de validation croisée.

Pool non étiqueté Lignes qui ne renseignent pas la cible, utilisables par une méthode semi-supervisée.

Pseudo-label Valeur de cible estimée par un modèle et ajoutée comme label ; ce n'est pas une mesure.

PWHT Traitement thermique après soudage (*post-weld heat treatment*), caractérisé par une température et une durée.

Série inférée Groupe d'observations issues d'une même étude, déduit des identifiants ; utilisé pour la validation groupée.

Standardisation Transformation $z = (x - \mu)/\sigma$ qui met les variables à la même échelle.

Validation croisée imbriquée Validation à deux niveaux : la boucle interne règle le modèle, la boucle externe l'évalue sur des données jamais utilisées pour le régler.

YS, UTS Limite d'élasticité et résistance maximale à la traction (MPa).