Prédiction des propriétés mécaniques de soudures d’acier

Rapport du projet - première version pour relecture - 10 octobre 2026

Auteurs : Mohamed SALH, Mohamed CHEBLI et Idriss BEN LETAIFA.

E-mails : mohamed.salh@student-cs.fr ; mohamed.chebli@student-cs.fr ; idriss.benletaifa@student-cs.fr.
Numéro d’équipe : à renseigner.

Résumé

Nous étudions la Cambridge Weld DB pour prédire trois propriétés de traction et, de façon exploratoire, l’énergie Charpy à température connue. La préparation conserve 1 555 observations ; cinq familles supervisées et COREG sont évaluées avec des validations imbriquées aléatoire et par séries. La configuration retenue utilise 16 entrées numériques, le procédé et une imputation médiane locale au train. Les R^2 aléatoires vont de 0,660 à 0,836 pour la procédure supervisée ; les R^2 groupés de 0,075 à 0,337. COREG ne l’améliore pas. Le transfert entre séries et l’hétérogénéité des essais limitent les conclusions opérationnelles.

Plan : 1. Problématique ; 2. Données et cibles ; 3. Préparation et ACP ; 4. Méthodes ; 5. Validation ; 6. Résultats ; 7. Semi-supervisé ; 8. Diagnostics ; 9. Discussion ; 10. Conclusion ; 11. Organisation ; 12. Références.

1. Problématique et traduction en tâche de ML

L’énoncé vise à exploiter les données de soudage pour mieux caractériser la qualité et compléter les connaissances expertes. Nous la représentons par plusieurs propriétés mesurées, plutôt que par une classe arbitraire « bonne » ou « mauvaise ». La tâche est une régression par cible à partir de compositions, conditions de soudage et traitement thermique. Une sortie n’est jamais utilisée pour prédire une autre. Les modèles séparés conservent les labels disponibles pour chaque tâche, sans exiger toutes les sorties complètes.

2. Base de données et définition des cibles

La base issue de la littérature comporte 1 652 lignes et 44 champs [1]. Quatre répétitions exactes hors identifiant sont écartées des expériences. La cohorte principale retient 1 555 lignes et 44 séries inférées des identifiants et liens de doublons, avec au plus deux entrées manquantes sur le noyau initial de 13. Chaque groupe peut réunir plusieurs conditions : il n’est pas une éprouvette unique certifiée. Le master conserve les NaN et la provenance du nettoyage.

Tableau 1 - Cibles et labels éligibles dans la cohorte.

Cible	Information représentée	Unité	Labels
YS	Limite d’élasticité	MPa	706
UTS	Résistance maximale à la traction	MPa	677
Allongement	Déformation à rupture	%	631
Charpy*	Énergie à température d’essai connue	J	861

YS et UTS sont corrélées (r=0,915 sur les paires exactes dédupliquées), mais décrivent deux niveaux mécaniques distincts. L’allongement apporte une dimension de déformation (corrélation avec UTS=-0,738). Cette matrice de corrélation n’est pas une ACP. Dureté, FATT50 et réduction de section ne sont pas des sorties retenues ; les autres propriétés et la microstructure restent hors des entrées.

Charpy est exploratoire : température et énergie sont deux colonnes séparées ; le modèle prédit E(T), pas T à énergie fixée. Certaines séries contiennent des courbes apparentées, d’autres des points sélectionnés à une énergie de transition. Toutes les sources ne sont pas harmonisées.

3. Préparation, variables et ACP descriptive

N signifie non rapporté, jamais zéro [1]. Les limites <L utilisent L/2 et les intervalles leur milieu, avec statut conservé. Les 322 cellules à unité douteuse et les annotations d'azote restent indisponibles dans la représentation principale. Les vrais zéros PWHT et les observations connues sont préservés. Seuls des synonymes de procédés documentés sont fusionnés ; le brut reste intact.

Les 16 variables numériques sont C, Si, Mn, S, P, Ni, Cr, Mo (% massique), O/N (ppm), courant (A), tension (V), apport thermique (kJ/mm), température entre passes et PWHT (°C), durée PWHT (h). Le procédé est catégoriel ; Charpy ajoute sa température connue. Ni/Cr/Mo manquent sur 58,8/53,2/53,0 % des lignes. Leur ajout accroît l'information potentielle, sans ajouter d'observations.

Chaque train ajuste ses moyennes/écarts-types sur les nombres observés, son encodage one-hot et ses médianes. Les transformations restent figées pour la validation et le pool. Une catégorie inconnue devient un vecteur nul. Les PWHT imputés doivent respecter des couples compatibles du train ; les couples sont complets dans la cohorte actuelle. Ni les cibles ni la température Charpy ne sont imputées. Une colonne totalement absente du train est refusée.

L'ACP est descriptive, sur 1 339 lignes dont onze entrées sont exactes et complètes, après standardisation sans imputation. PC1 et PC2 expliquent 27,02 % et 19,03 % de variance, soit 46,05 % cumulés ; trois axes expliquent 61,26 % (figure 1). Ce sous-ensemble n'est pas toute la cohorte. Aucune de ces transformations apprises globalement n'est réutilisée dans la CV prédictive.

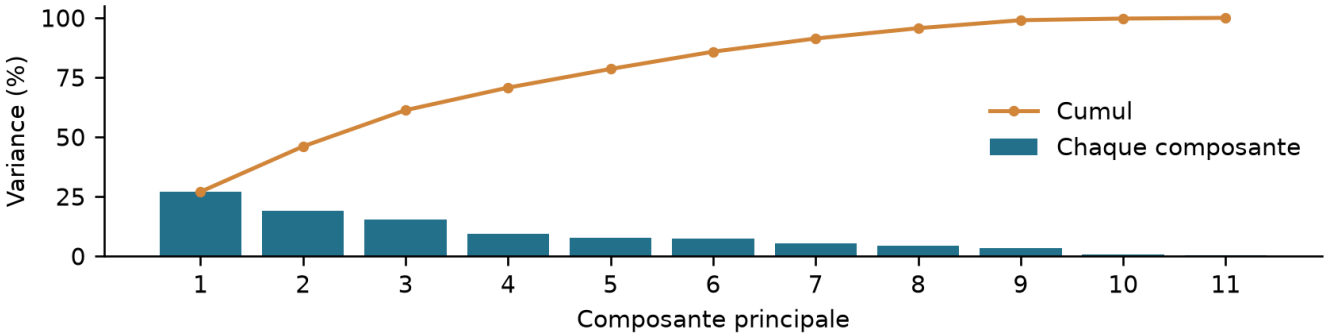


Figure 1 - Variance expliquée de l'ACP descriptive, onze entrées complètes.

4. Méthodes supervisées et choix du preprocessing

Tableau 2 - Modèles, rôle et réglages internes.

Modèle	Rôle et choix internes
Médiane de y	Référence constante, aucun fit de X
Ridge	Régression linéaire L2 ; alpha=0,01 à 1 000 (six valeurs)
SVR RBF	Non-linéarité ; C=1/10/100, gamma=scale/0,05, epsilon=0,05/0,2
RF	300 arbres ; feuille=1/2/5, profondeur libre/10, max_features=0,5/1
kNN	Régression locale ; k=3/5/9/15, distances L1/L2, poids uniformes

La SVR standardise aussi y dans son train puis restitue son unité. Les 39 configurations, baseline incluse, sont choisies par MAE interne. La RF est un contrôle non linéaire polyvalent, Ridge un contrôle linéaire et kNN le pendant supervisé de COREG. Aucun algorithme n'est supposé optimal avant comparaison. Les sensibilités 11/13/16 × médiane/itérative motivent 16/médiane : gains YS/UTS et convergence robuste. L'itérative a 11 échecs, entraînant 44 évaluations indisponibles sur 480. Ce choix est rétrospectif sur ces mêmes données.

5. Validation croisée et métriques

Les deux protocoles sont imbriqués : cinq validations externes, trois internes pour sélectionner famille et paramètres ; tout preprocessing est appris dans le train courant [3]. La CV aléatoire mélange les lignes (seed42 ; internes seed43+pli). La groupée garde les séries séparées. Les estimateurs utilisent seed42. La première mesure la prédiction dans une population représentée, la seconde le transfert vers des séries absentes. Les groupes inférés restent imparfaits ; une performance aléatoire élevée ne démontre pas IID.

Pour n labels y_i, prédictions $\hat{y}_i$ et moyenne $\bar{y}$ de validation :

$MAE = (1/n)\ \Sigma\ |y_i - \hat{y}_i|$; $RMSE = \sqrt{[(1/n)\ \Sigma\ (y_i - \hat{y}_i)^2]}$; $R^2 = 1 - \Sigma(y_i - \hat{y}_i)^2 / \Sigma(y_i - \bar{y})^2$.

MAE règle les modèles ; RMSE pénalise davantage les grandes erreurs. R^2 peut être négatif et n'a aucun minimum garanti de 0,5. Les tableaux donnent les moyennes non pondérées des cinq plis. Les R^2 OOF réunis sont distincts ; la dispersion entre plis n'est pas un intervalle de confiance.

6. Résultats supervisés, configuration 16/médiane

Tableau 3 - Procédure de sélection interne, mêmes labels pour les deux CV. *Les MAE sont en MPa, points de % ou J selon la cible ; Charpy* est exploratoire.*

Cible (unité)	MAE aléatoire	R^2 aléatoire	MAE groupée	R^2 groupé
YS (MPa)	31,630	0,755	56,757	0,337
UTS (MPa)	23,861	0,836	54,344	0,334
Allongement (points de %)	2,054	0,660	3,517	0,157
Charpy* (J)	16,461	0,776	35,752	0,075

Tableau 4 - R^2 moyens par famille : A=aléatoire, G=groupé. *Le classement externe décrit les performances ; il ne décide pas des exports.*

Famille	YS : A / G	UTS : A / G	Allong. : A / G	Charpy* : A / G
Médiane de y	-0,031 / -0,073	-0,050 / -0,180	-0,015 / -0,062	-0,069 / -0,149
Ridge	0,412 / -0,025	0,538 / 0,179	0,345 / 0,016	0,529 / 0,069
SVR RBF	0,754 / 0,264	0,836 / 0,316	0,556 / 0,106	0,749 / 0,091
Random Forest	0,765 / 0,390	0,805 / 0,394	0,660 / 0,226	0,795 / 0,138
kNN	0,619 / -0,140	0,697 / -0,115	0,530 / -0,060	0,651 / -0,099

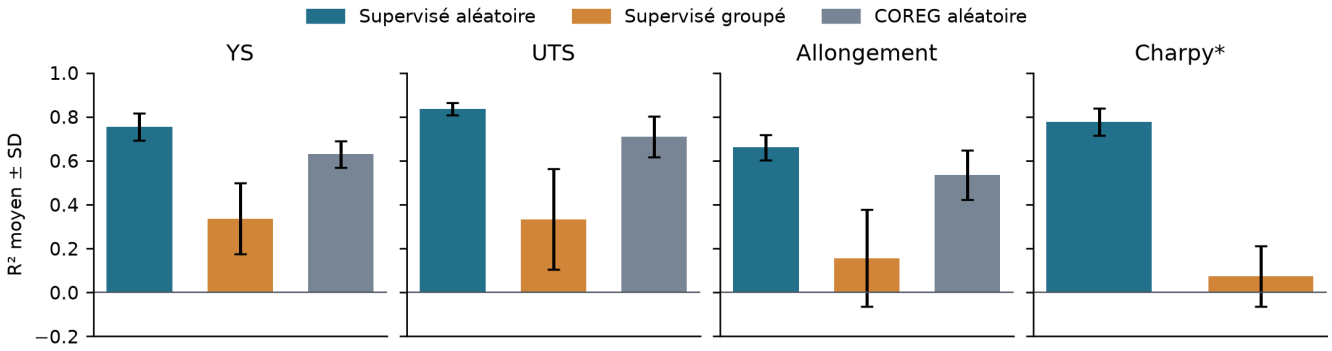


Figure 2 - R^2 moyens ± SD des cinq plis ; sélection supervisée et COREG aléatoire.

La figure 2 montre la chute lors du transfert entre séries. En aléatoire, les familles RF/SVR sont compétitives ; la sélection interne atteint 0,755/0,836/ 0,660 pour la traction. En groupé, ses R^2 restent 0,337/0,334/0,157. La RF isolée peut avoir un meilleur score externe que la sélection interne : cette observation ne permet pas de sélectionner sur la validation. Les refits complets sont réglés par une nouvelle CV5, et ne servent jamais à scorer les plis.

7. Semi-supervisé : COREG inductif

COREG utilise deux kNN échangeant des estimations jugées cohérentes localement [2]. Notre variante a deux distances L1/L2 sur les mêmes entrées, k choisi dans 3/5/9/15 en interne et une sortie moyenne. Le gain local de SSE est mesuré après insertion temporaire de la propre estimation du régresseur source, puis le candidat est transmis à l'autre régresseur. Son voisinage courant comprend les pseudo-labels précédents. Ces estimations ne sont pas des mesures mécaniques.

Le pool naturel global comprend 849/878/924 lignes sans YS/UTS/allongement. Dans chaque pli, seuls les X du train sont accessibles ; les X et labels de validation sont exclus, ainsi que leurs séries en groupé : protocole inductif. Le preprocessing est appris sur les vrais labels et figé. Le pool transformé est dédupliqué et les X déjà représentés parmi les vrais labels sont retirés ; les vrais labels répétés restent conservés. Cette politique est une variante du projet. Elle ne certifie pas l'identité physique de représentations égales.

Au plus 100 candidats actifs, 100 tours, un ajout par régresseur/tour et aucun ID ajouté deux fois. Gain > 1e-12 × max(1,var(y_train)) × k ; arrêt si pool épuisé, aucun gain positif dans le pool actif ou budget atteint. Aucun label de validation ne sert à accepter ou arrêter. Le contrôle principal est la moyenne des mêmes kNN au même k, sans pseudo-labels, avec mêmes vrais labels.

Tableau 5 - COREG, A=aléatoire / G=groupé ; gain positif=amélioration de MAE. *Les MAE sont moyennes des plis ; les gains sont appariés sur les OOF.*

Cible	MAE COREG A / G	R^2 COREG A / G	Gain OOF même k A / G
YS	37,919 / 71,074	0,629 / -0,056	0,322 / -0,272
UTS	33,037 / 63,060	0,709 / 0,043	0,283 / -0,920
Allongement	2,402 / 3,904	0,535 / -0,028	-0,011 / -0,024

Les petits gains aléatoires YS/UTS ont des intervalles descriptifs couvrant zéro (bootstrap par séries, 2 000 tirages). L'allongement ne progresse pas ; les trois gains groupés sont négatifs. Pour UTS groupé, intervalle [-1,939 ; -0,275] MPa. Les seeds de bases 43/44, avec k fixé, donnent la même lecture. COREG reste moins bon que la sélection supervisée dans les six cas. Aucun entraînement COREG Charpy n'est possible avec le pool naturel actuel à température connue.

8. Diagnostics et explicabilité

Le RF initial 13/itérative apprend le train mais transfère mal : R^2 train YS/UTS=0,795/0,842 contre 0,079/0,194 groupés. Environ 56/51 % de sa SSE proviennent des biais moyens de séries. Ce diagnostic vise le benchmark initial, pas automatiquement les modèles 16/médiane. À médiane identique, ajouter Ni/Cr/Mo donne des gains MAE OOF RF de 11,06 MPa YS et 8,80 MPa UTS, avec intervalles descriptifs positifs ; allongement/Charpy sont moins établis.

La permutation de blocs du RF initial indique une information utilisée dans la composition et PWHT ; la température d'essai est utile pour Charpy (+7,47 J de MAE lorsqu'elle est permutée). Corrélations, permutations et contributions des chemins d'arbres ne prouvent aucun effet causal. Un gain local COREG peut renforcer une erreur commune sans corriger le décalage entre séries.

9. Discussion et recommandations

Le partage de séries explique un contexte plus favorable en aléatoire : 99 à 100 % des validations partagent une série avec le train. Pour Charpy, 65 % partagent une condition, parfois à une autre température. Un contrôle RF à paramètres fixes confirme que séparer des séries est plus difficile que séparer les seules signatures répétées. Le protocole principal doit suivre l'usage, plutôt que maximiser le R^2 affiché. Les validations externes ont déjà informé le choix 16/médiane : une étude indépendante reste nécessaire.

Charpy conserve une réserve spécifique : deux familles de courbes E(T) apparentées sont confirmées (174 points), une famille à 100 J semble issue de températures de transition (31 points), et 21 groupes restent non résolus. La thèse de Cool [4] emploie également des entrées différentes ; ses résultats ne sont pas directement comparables. Il faut harmoniser les protocoles.

Les recommandations étayées sont de mieux mesurer les compositions manquantes, enregistrer conditions et protocoles, identifier les éprouvettes/séries et valider sur de nouvelles séries avec vrais labels. Aucun réglage de soudage optimal, seuil universel de qualité ou substitution aux essais mécaniques n'est démontré par ces associations. Leur validation demanderait des essais contrôlés et l'avis de spécialistes du domaine.

10. Conclusion

La référence retenue est supervisée, avec 16 variables et médiane locale au train ; la famille dépend de la cible et de la CV interne. COREG satisfait l'étude semi-supervisée demandée mais n'améliore pas ce benchmark à budget complet de labels. La priorité est le transfert entre séries et la qualité des mesures. Les 188 pipelines sont exportées ; 37 tests et les audits OOF valident le calcul. Ces contrôles ne constituent pas une validation industrielle.

11. Organisation et trame Gantt à compléter

Le journal de travail est vide : aucune heure ou responsabilité n'est inventée. Le tableau 6 prépare le Gantt final. Il faut renseigner les dates, le membre et les heures, puis tracer les barres sur ces dates. Les durées de calcul ne sont pas des durées de travail humain. La revue croisée par l'équipe reste à documenter.

Tableau 6 - Trame de saisie du Gantt ; temps et partage réels à renseigner.

Tâche réalisée / prévue	Membre	Dates début / fin	Heures réelles
EDA et lecture des sources	À compléter	À compléter	À compléter
Préparation et protocole	À compléter	À compléter	À compléter
Modèles supervisés	À compléter	À compléter	À compléter
Diagnostics et explicabilité	À compléter	À compléter	À compléter
COREG et contrôles	À compléter	À compléter	À compléter
Rédaction et revue croisée	À compléter	À compléter	À compléter

12. Références bibliographiques

[1] Cool, T. et Bhadeshia, H. K. D. H. Documentation Cambridge MAP_DATA_WELD, colonnes et unités, consultée le 10 octobre 2026.

[2] Zhou, Z.-H. et Li, M. (2005). Semi-Supervised Regression with Co-Training. IJCAI, p. 908-913.

[3] Scikit-learn. Cross-validation: evaluating estimator performance, consultée le 10 octobre 2026.

[4] Cool, T. (1996). Design of Steel Weld Deposits, thèse, Cambridge, section 6.4 ; contexte Charpy et variables supplémentaires.

[5] Projet, notebooks 01 à 07 et rapports 10 à 14 : protocoles, résultats locaux et audits reproductibles, 10 octobre 2026.

La synthèse globale contient les dispersions, RMSE, sensibilités, paramètres complets et preuves des rapports 10 à 14.