Projet de Machine Learning — CentraleSupélec

Prédiction de la qualité des soudures d'acier à partir de la Cambridge Weld Database

Rapport de synthèse

Mohamed SALH mohamed.salh@student-cs.fr
Mohamed CHEBLI mohamed.chebli@student-cs.fr
Idriss BEN LETAIFA idriss.benletaifa@student-cs.fr

12 octobre 2026

Résumé. Nous prédisons quatre propriétés mécaniques de dépôts de soudure d'acier — limite d'élasticité (YS), résistance à la traction (UTS), allongement et énergie Charpy — à partir de leur composition et de leurs paramètres de soudage, sur la *Cambridge Weld Database* (1 652 lignes, 44 champs) [1]. Six familles supervisées et la méthode semi-supervisée COREG sont comparées par validation croisée imbriquée, selon un découpage aléatoire et un découpage par séries expérimentales. Sur des séries connues, la meilleure procédure (dominée par XGBoost) atteint un R^2 de 0,65 à 0,85 ; sur des séries nouvelles, il chute à 0,06–0,37. Des seuils tirés de la norme ISO 2560-A montrent enfin que le modèle peut trier des soudures, mais pas en valider une sans essai.

Table des matières

1 Problématique et traduction en tâche d'apprentissage **1**

2 Base de données et analyse exploratoire **2**

3 Cibles, préparation et protocole **3**

4 Méthodes d'apprentissage **4**
4.1 Méthodes supervisées 4
4.2 Méthode semi-supervisée : COREG 4

5 Résultats et analyse comparative **5**
5.1 Procédure supervisée de référence 5
5.2 Comparaison des familles 5
5.3 Pourquoi le transfert entre séries échoue 6
5.4 Apport du semi-supervisé 7

6 Des prédictions à une décision : seuils normatifs **7**

7 Discussion, recommandations et conclusion **8**

1 Problématique et traduction en tâche d'apprentissage

La qualité d'une soudure d'acier conditionne la tenue d'ouvrages comme les monopieux d'éoliennes. Elle s'évalue aujourd'hui par des essais mécaniques et par l'expérience de soudeurs experts. L'enjeu est d'extraire de données publiées une connaissance plus homogène, et si possible d'estimer les

propriétés d'une soudure *avant* de la tester.

La « qualité » n'est pas une colonne de la base : nous la représentons par des propriétés mesurées sur le métal fondu, que les normes utilisent pour qualifier un consommable (section 6). Le problème devient **quatre régressions supervisées indépendantes** : YS (MPa), UTS (MPa), allongement (%) et, à titre exploratoire, énergie Charpy $E(T)$ (J) à température d'essai T connue. Les entrées sont uniquement celles connues avant l'essai : composition, procédé, paramètres électriques, apport thermique, température entre passes et traitement thermique après soudage (PWHT). Une autre propriété mécanique, la microstructure ou l'identifiant de la publication ne sont pas des entrées.

Chaque cible n'est mesurée que pour 42 à 53 % des lignes : on dispose d'un ensemble étiqueté et d'un ensemble non étiqueté, ce qui motive l'étude d'une méthode **semi-supervisée**. Enfin, les lignes proviennent de dizaines de séries expérimentales : la question « le modèle prédit-il une série qu'il n'a jamais vue ? » est centrale et structure tout le protocole.

2 Base de données et analyse exploratoire

Contenu. Les 44 colonnes regroupent 21 teneurs chimiques (% massique, ou ppm pour les éléments traces), les paramètres de soudage (courant en A, tension en V, apport thermique en kJ/mm, température entre passes en °C, type de courant, polarité, procédé), le PWHT (température en °C, durée en h), sept propriétés mécaniques avec la température de l'essai Charpy, et cinq fractions de microstructure. La valeur `N` signifie « non rapporté » et est traitée comme manquante, jamais comme zéro.

Constats. L'analyse exploratoire montre une base *hétérogène*, compilée à partir de nombreuses publications :

- **absences massives et structurées** : aucune ligne n'est complète, et les absences dépendent du procédé (Ni et Cr manquent dans 91 % des lignes TSA, l'énergie Charpy dans 77 % des lignes SA) ;
- **valeurs censurées** (`<0,01`), intervalles et annotations : 44,5 % des valeurs d'aluminium rapportées sont censurées ;
- **quelques unités douteuses**, mises en quarantaine sans conversion conjecturale ;
- **distributions multimodales** (Mn, Cr) et procédés déséquilibrés (soudage manuel MMA majoritaire) : un mélange de familles d'aciers et de séries ;
- **Charpy hétérogène** : 54 % des couples (T, E) ont $E = 28$ ou 100 J exactement, signature probable de températures de transition plutôt que d'énergies mesurées à T imposée.

Analyse en composantes principales. Une ACP standardisée sur les onze entrées complètes (1 339 lignes) sert à développer l'intuition (figure 1) [2]. Les deux premiers axes expliquent 27,0 et 19,0 % de la variance ; il faut huit axes pour dépasser 95 %. Le premier axe est un axe « énergie du procédé » (apport thermique, courant, tension) qui sépare le soudage manuel du soudage sous flux ; le second oppose impuretés (P, S) et PWHT au silicium et au manganèse. La projection forme des amas liés aux séries et aux procédés plutôt qu'un nuage continu. Comme l'information est répartie sur de nombreux axes, aucune ACP n'est utilisée dans les modèles.

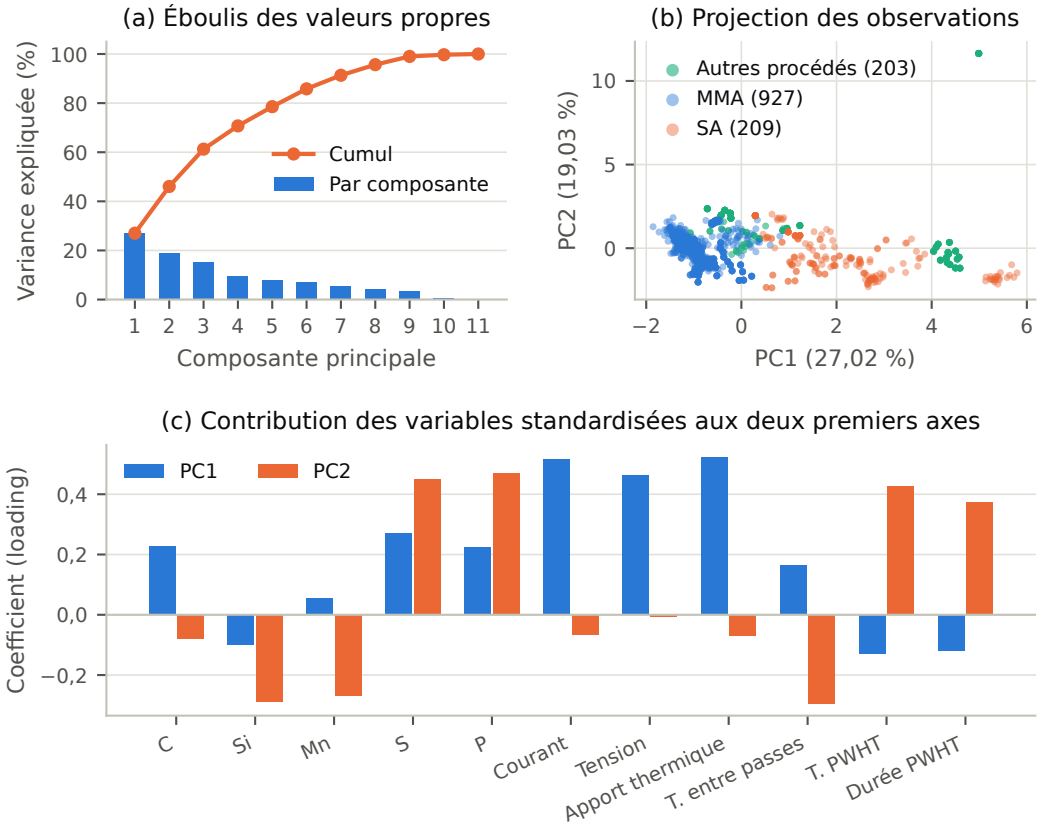


Figure 1. ACP standardisée des onze entrées complètes. (a) Variance expliquée ; (b) projection sur les deux premiers axes, colorée par procédé ; (c) coefficients des variables sur les deux premiers axes.

3 Cibles, préparation et protocole

Cibles. YS, UTS et allongement sont les cibles principales (706, 677 et 631 labels dans la cohorte). L'énergie Charpy (861 couples $E(T)$) est exploratoire : ses protocoles ne sont pas harmonisés entre séries. Aucune cible n'est imputée.

Préparation. Le nettoyage est déterministe et traçable : 66 080 cellules gardent leur valeur brute, leur statut et leur provenance ; `<L` est remplacé par $L/2$ et un intervalle par son milieu ; quatre doublons exacts sont retirés. Les identifiants permettent d'inférer des **séries expérimentales**. La cohorte principale retient les lignes qui ont au plus deux entrées manquantes sur un noyau de 13 variables : **1 555 lignes, 44 séries**. Le modèle utilise 16 entrées numériques (C, Si, Mn, S, P, Ni, Cr, Mo, O, N, courant, tension, apport thermique, température entre passes, température et durée du PWHT), le procédé et, pour Charpy, la température d'essai.

Prétraitement sans fuite. Standardisation, encodage one-hot du procédé et imputation par la médiane sont **appris dans le seul ensemble d'entraînement de chaque pli**, au sein d'une pipeline unique. Une première configuration (13 entrées, imputation itérative) a donné des R^2 groupés de 0,02 à 0,19 ; son diagnostic a conduit à ajouter Ni, Cr et Mo (gain de 11 et 9 MPa de MAE sur YS et UTS) et à passer à la médiane, l'imputation itérative ne convergeant pas dans 11

contextes.

Validation croisée imbriquée. Cinq plis externes estiment la performance ; dans chaque train externe, trois plis internes choisissent la famille et ses hyperparamètres par MAE [3, 4]. Deux scénarios répondent à deux questions :

— **validation aléatoire** (KFold sur les lignes, graine 42) : prédire une soudure d'une série déjà représentée — 99 % des lignes de validation partagent leur série avec le train ;
— **validation groupée** (GroupKFold sur les séries) : prédire une série entièrement nouvelle, le cas d'usage d'une nouvelle étude [5].

Métriques. Sur n prédictions $\hat{y}_i$ de valeurs y_i de moyenne $\bar{y}$:

$$\mathrm{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|, \qquad \mathrm{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}, \qquad R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}. \tag{1}$$

La MAE, dans l'unité de la cible et robuste aux valeurs extrêmes, sert à la sélection ; la RMSE pénalise les grosses erreurs ; le R^2, sans unité, compare les cibles ($R^2 < 0$: pire que prédire la moyenne). Les scores sont des moyennes ± écarts-types sur les cinq plis externes.

4 Méthodes d'apprentissage

4.1 Méthodes supervisées

Six familles couvrent des hypothèses différentes sur la relation entre recette et propriétés (51 configurations réglées par cible et par pli) :

— **médiane de** y : référence constante, gain minimal à dépasser ;
— **Ridge** [6] : régression linéaire pénalisée par $\alpha\|\beta\|_2^2$, contrôle linéaire (α de 0,01 à 1 000) ;
— **SVR à noyau RBF** [7] : perte ε-insensible et noyau gaussien pour des relations non linéaires lisses (C, γ, ε réglés ; cible standardisée dans le train) ;
— **forêt aléatoire** [8] : moyenne de 300 arbres sur échantillons bootstrap, qui capte interactions et effets de seuil (taille des feuilles, profondeur, fraction de variables réglées) ;
— k **plus proches voisins** [9] : méthode locale ($k \in \{3, 5, 9, 15\}$, distances L1 ou L2), contrôle supervisé de COREG ;
— **XGBoost** [10] : *boosting* d'arbres, chaque arbre corrigeant les résidus des précédents avec un pas η et une pénalité de complexité (profondeur 2 à 6, $\eta \in \{0{,}03; 0{,}1\}$, 150 ou 300 arbres, sans arrêt précoce).

Toutes sont implémentées avec scikit-learn [11] et XGBoost dans des notebooks autonomes ; les choix de famille se font uniquement sur la MAE interne.

4.2 Méthode semi-supervisée : COREG

Bibliographie. Les méthodes semi-supervisées exploitent des entrées sans label en plus des données étiquetées [12, 13]. L'auto-apprentissage (*self-training*) ajoute itérativement les prédictions

les plus sûres d'un modèle comme pseudo-labels [14] ; le co-apprentissage fait échanger ces pseudo-labels entre deux modèles complémentaires [15] ; les méthodes de graphe propagent les labels entre voisins [16]. La plupart ont été conçues pour la classification, où la confiance d'une prédiction est une probabilité.

Choix et justification. Nous retenons **COREG** [17], un co-apprentissage conçu pour la *régression* : deux kNN de distances différentes (L1 et L2) s'échangent des pseudo-labels, et un candidat n'est accepté que s'il réduit l'erreur locale du modèle sur ses voisins étiquetés. Ce critère remplace la probabilité, absente en régression. COREG est simple, inductif (il prédit de nouvelles soudures sans réentraînement) et directement comparable à son pendant supervisé : la moyenne des deux mêmes kNN sans pseudo-labels isole l'effet des pseudo-labels.

Protocole inductif. Le pool non étiqueté ne contient que des lignes de la cohorte sans la cible, prises dans le train du pli (849 à 924 lignes selon la cible) ; aucune entrée ni aucun label de validation n'est utilisé. COREG est évalué sur les trois cibles de traction, Charpy n'ayant pas de pool avec température d'essai connue.

5 Résultats et analyse comparative

5.1 Procédure supervisée de référence

Le tableau 1 donne le résultat principal : la procédure qui choisit la famille parmi les six dans la boucle interne.

Tableau 1. Sélection interne parmi six familles, 16 entrées + procédé, imputation médiane : moyenne ± écart-type sur 5 plis externes, et MAE de la référence médiane.

Cible	Validation	MAE	RMSE	R^2	MAE médiane
YS (MPa)	aléatoire	26,3 ± 2,7	39,1	0,82 ± 0,04	70,0
	groupée	54,4 ± 9,8	70,3	0,37 ± 0,17	70,4
UTS (MPa)	aléatoire	23,6 ± 0,8	36,5	0,83 ± 0,03	68,9
	groupée	55,7 ± 12,9	70,3	0,31 ± 0,22	72,7
Allongement (%)	aléatoire	2,06 ± 0,22	2,89	0,65 ± 0,05	4,02
	groupée	3,28 ± 0,37	4,14	0,26 ± 0,14	4,09
Charpy* (J)	aléatoire	14,2 ± 0,7	19,7	0,84 ± 0,03	36,8
	groupée	36,3 ± 12,8	46,4	0,06 ± 0,12	36,0

Sur des séries connues, l'erreur typique est de 26 MPa sur YS et 24 MPa sur UTS (4 à 5 % de la médiane), soit une MAE réduite de 49 à 66 % par rapport à la référence. Sur des séries nouvelles, l'erreur double et la réduction tombe à 20–23 % pour la traction ; pour Charpy, la procédure ne fait pas mieux que la médiane. **L'écart entre les deux scénarios est le résultat principal du projet.**

5.2 Comparaison des familles

La figure 2 montre que :

— **XGBoost** est la meilleure famille sur des séries connues pour les quatre cibles (MAE de

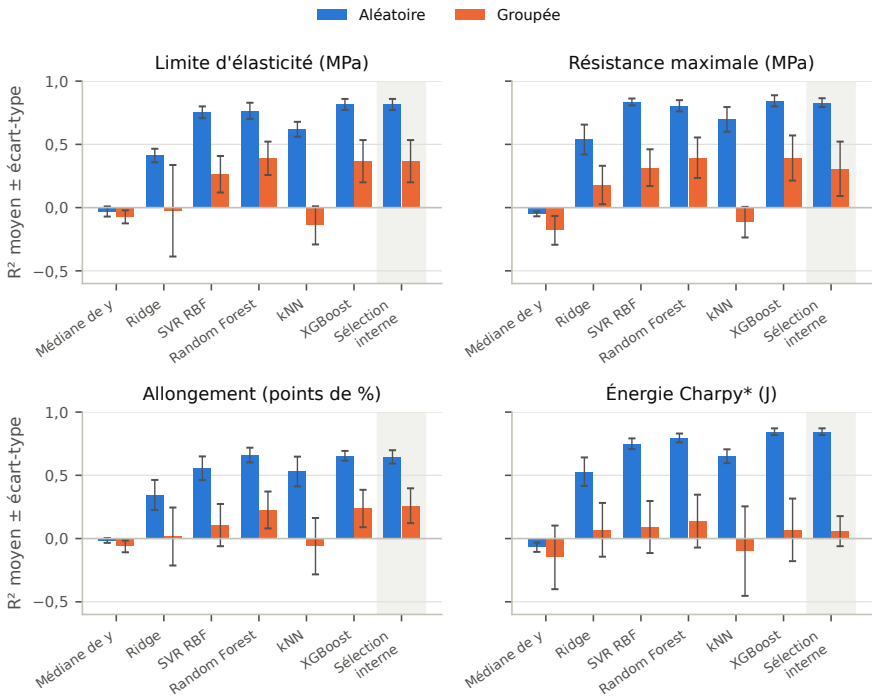


Figure 2. R^2 moyen (± écart-type) de chaque famille réglée en interne et de la procédure de sélection (fond gris), validations aléatoire (bleu) et groupée (orange).

26,3 MPa sur YS contre 31,2 pour la forêt) ; la sélection interne le retient dans 17 plis aléatoires sur 20, avec des arbres profonds ;

- la **forêt aléatoire** reste la plus robuste sur des séries nouvelles (R^2 de 0,39 sur YS et UTS) ; en groupé, la boucle interne préfère des XGBoost peu profonds (profondeur 2) et choisit même la médiane dans deux plis Charpy ;
- **Ridge** capte peu de signal : la relation n'est pas linéaire ;
- le ***k*NN** est correct en aléatoire mais *négatif* en groupé : une méthode locale réussit quand un voisin de la même série est dans le train, et échoue sinon.

L'ajout de XGBoost réduit la MAE de la sélection dans cinq comparaisons sur huit (YS aléatoire : 31,6 → 26,3 MPa) mais ne change pas la conclusion groupée. Choisir une famille *après* lecture de ces scores externes serait une sélection sur la validation : seule la sélection interne est une estimation honnête.

5.3 Pourquoi le transfert entre séries échoue

Une décomposition de l'erreur quadratique de la forêt (premier benchmark groupé) montre qu'environ **la moitié de l'erreur** (36 à 56 % selon la cible) vient d'un biais moyen constant sur toute une série : le modèle prédit correctement les variations à l'intérieur d'une série mais se trompe sur son niveau. Les prédictions groupées sont « aplaties » vers la moyenne. Les entrées disponibles n'expliquent pas ces décalages, probablement liés à des éléments non retenus (Nb, V, Ti, B, Cu), à des protocoles d'essai différents ou à des états métallurgiques non décrits.

5.4 Apport du semi-supervisé

Tableau 2. COREG, son contrôle sans pseudo-labels (deux kNN au même k) et la sélection supervisée : MAE moyenne sur 5 plis.

	Validation aléatoire			Validation groupée		
Cible	COREG	Contrôle	Supervisé	COREG	Contrôle	Supervisé
YS (MPa)	37,9	38,2	**26,3**	71,1	70,8	**54,4**
UTS (MPa)	33,0	33,3	**23,6**	63,1	62,1	**55,7**
Allongement (%)	2,40	2,39	**2,06**	3,90	3,88	**3,28**

COREG gagne au mieux 0,3 MPa sur son contrôle en aléatoire, gain non significatif (intervalles bootstrap par séries couvrant zéro), et perd en groupé (tableau 2). Il reste 7 à 17 MPa derrière la sélection supervisée. Trois raisons sont cohérentes avec ces mesures : les kNN de base sont faibles hors série et COREG ne fait que propager leurs estimations ; le pool provient des mêmes séries que les labels et apporte peu d'information nouvelle ; enfin tous les labels disponibles sont déjà utilisés, alors que le semi-supervisé est surtout utile quand ils sont rares.

6 Des prédictions à une décision : seuils normatifs

Pour juger la qualité d'une soudure, il faut décider si ses propriétés sont suffisantes. Nos données décrivant surtout du métal fondu, les références directes sont les normes de classification des consommables, qui imposent *simultanément* des minimums de traction et de résilience : ISO 2560-A [18, 19], ISO 18275-A au-delà de 500 MPa [20], AWS A5.1 (E7018 : 400 MPa, 490 MPa, 22 %, 27 J à −29 °C) [21] et, en offshore, les règles DNV [22]. Ces exigences s'accompagnent de compromis : l'allongement exigé baisse quand la classe de résistance monte (corrélation YS–allongement de −0,73 dans nos données), et un métal fondu plus résistant est plus difficile à rendre tenace [23, 24].

Profil et règle. Nous retenons la classe **ISO 2560-A E 42 2**, au centre de nos données : YS $\geq$ 420 MPa, UTS $\geq$ 500 MPa, allongement $\geq$ 20 % et énergie Charpy moyenne $\geq$ 47 J à −20 °C (critères critiques), UTS $\leq$ 640 MPa (informatif). Pour tenir compte de l'erreur du modèle, nous appliquons la *bande de garde* du JCGM 106 [25] : pour un seuil bas L, une prédiction $\hat{y}$ est conforme (C) si $\hat{y} - 2u \geq L$, non conforme (NC) si $\hat{y} + 2u < L$, indéterminée (I) sinon, où u est la RMSE hors pli. Avec $w = 2u$, le risque d'accepter une soudure non conforme est au plus de 2,3 % pour une erreur normale. Une soudure est **VALIDÉE** si tous ses critères sont C, **NON VALIDÉE** si un critère critique est NC, **PARTIELLE** sinon (essai nécessaire). Les mesures de la base sont jugées avec $w = 0$; chaque soudure est prédite par un modèle qui ne l'a jamais vue, et l'énergie Charpy à −20 °C.

Résultats. Les mesures donnent 51 soudures VALIDÉES et 230 NON VALIDÉES ; les autres sont PARTIELLES, surtout faute de cibles mesurées ensemble (141 lignes seulement ont les quatre). Le modèle, lui, **ne valide aucune soudure** (figure 3) : la plage d'UTS (140 MPa) est plus étroite que deux bandes de garde (2 × 73 MPa en aléatoire), si bien qu'aucune prédiction ne peut satisfaire à la fois UTS $\geq$ 500 et UTS $\leq$ 640. Ses décisions tranchées sont fiables : par critère, au plus 2,3 % de fausses acceptations dans les deux protocoles, et aucun rejet sur une borne basse contredit par la mesure. Mais elles sont rares pour une série nouvelle : le modèle groupé ne tranche que 7 à 27 %

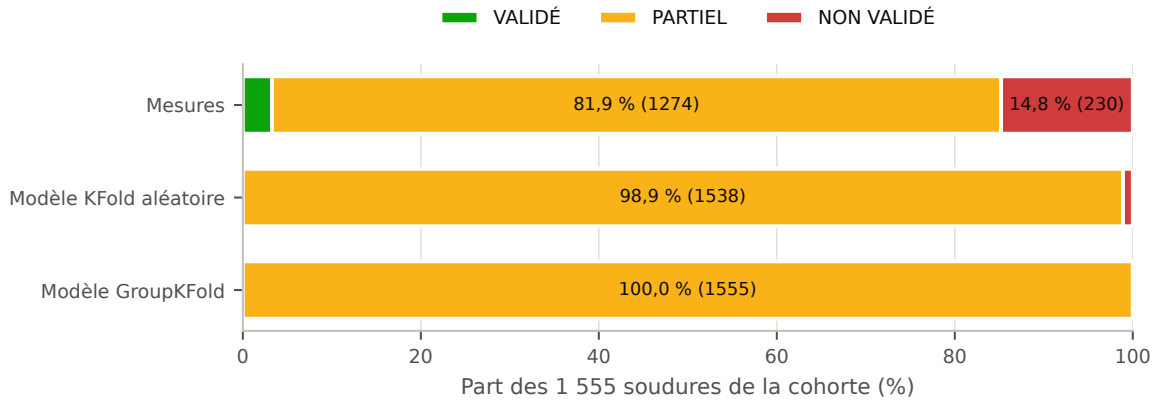


Figure 3. Décisions sur les 1 555 soudures de la cohorte, profil E 42 2, bande de garde $2u$: mesures et prédictions hors pli des deux protocoles.

des critères. En ignorant la borne haute d'UTS, le modèle aléatoire validerait 125 soudures, dont 2 contredites par la mesure (1,6 %) ; le modèle groupé n'en validerait toujours aucune.

7 Discussion, recommandations et conclusion

Approche la plus appropriée. La procédure supervisée — 16 entrées et procédé, imputation médiane apprise dans le train, choix de la famille parmi six par validation interne — est la plus appropriée ; elle retient surtout XGBoost. Elle est utile pour **interpoler dans des séries connues** (erreur de l'ordre de 25 MPa sur la résistance), beaucoup moins pour une nouvelle étude (environ 55 MPa, $R^2 < 0{,}4$). Les entrées comptent davantage que l'algorithme : ajouter Ni, Cr et Mo a plus amélioré le transfert que tout changement de famille, et le semi-supervisé n'apporte pas l'information manquante.

Limites. La configuration 16/médiane et l'ajout de XGBoost ont été décidés après les premiers résultats : malgré la validation imbriquée, aucun jeu indépendant ne confirme la démarche complète. Les séries sont inférées des identifiants ; Charpy mélange des protocoles ; la règle de validation utilise une erreur globale par cible plutôt qu'un intervalle propre à chaque soudure, qui pourrait être obtenu par prédiction conforme [26].

Recommandations pour une bonne qualité de soudure. Nos modèles révèlent des associations, pas des causes : nous ne recommandons aucun réglage « optimal » de composition ou de procédé, ce qui demanderait des plans d'expériences contrôlés. Les données permettent en revanche de recommander :

1. de **mesurer la composition complète**, dont Ni, Cr et Mo, et de documenter le PWHT : ce sont les informations les plus utiles aux modèles de résistance ;
2. d'**enregistrer les protocoles d'essai**, en particulier Charpy (courbes $E(T)$ complètes plutôt que températures de transition), et d'identifier séries et publications ;
3. de **qualifier chaque soudure par essai** : le modèle sert de filtre avant essai, pas de verdict — une soudure PARTIELLE vis-à-vis de la classe visée doit être testée ;

4. de **valider tout modèle sur de nouvelles séries** et de privilégier la diversité des études plutôt que le nombre de répétitions.

Conclusion. Prédire les propriétés d'une soudure proche d'une série connue est réaliste (R^2 de 0,65 à 0,85) ; prédire une nouvelle étude reste difficile (R^2 de 0,06 à 0,37), principalement à cause de décalages de niveau entre séries que les entrées n'expliquent pas. COREG n'améliore pas la référence supervisée. Face à une exigence normative avec une marge de sécurité, le modèle trie mais ne qualifie pas : les progrès viendront d'abord de données plus complètes et mieux documentées.

Reproductibilité. Code dans les notebooks 01 à 09 du dépôt, 47 tests ciblés ; le rapport complet détaille chaque étape, chaque choix et l'ensemble des résultats.

Références bibliographiques

[1] T. Cool and H. K. D. H. Bhadeshia. MAP_DATA_WELD : base de données de dépôts de soudure d'acier. Université de Cambridge, Materials Algorithms Project, s.d. URL https://www.phase-trans.msm.cam.ac.uk/map/data/materials/welddb-b.html. Documentation des colonnes et des unités, consultée le 10 octobre 2026.

[2] I. T. Jolliffe and J. Cadima. Principal component analysis : a review and recent developments. *Philosophical Transactions of the Royal Society A*, 374(2065) :20150202, 2016.

[3] S. Varma and R. Simon. Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics*, 7 :91, 2006.

[4] G. C. Cawley and N. L. C. Talbot. On over-fitting in model selection and subsequent selection bias in performance evaluation. *Journal of Machine Learning Research*, 11 :2079–2107, 2010.

[5] D. R. Roberts, V. Bahn, S. Ciuti, M. S. Boyce, J. Elith, G. Guillera-Arroita, S. Hauenstein, J. J. Lahoz-Monfort, B. Schröder, W. Thuiller, D. I. Warton, B. A. Wintle, F. Hartig, and C. F. Dormann. Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8) :913–929, 2017.

[6] A. E. Hoerl and R. W. Kennard. Ridge regression : biased estimation for nonorthogonal problems. *Technometrics*, 12(1) :55–67, 1970.

[7] A. J. Smola and B. Schölkopf. A tutorial on support vector regression. *Statistics and Computing*, 14(3) :199–222, 2004.

[8] L. Breiman. Random forests. *Machine Learning*, 45(1) :5–32, 2001.

[9] T. M. Cover and P. E. Hart. Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1) :21–27, 1967.

[10] T. Chen and C. Guestrin. XGBoost : A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016. doi : 10.1145/2939672.2939785.

[11] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn : Machine learning in Python. *Journal of Machine Learning Research*, 12 :2825–2830, 2011.

[12] O. Chapelle, B. Schölkopf, and A. Zien, editors. *Semi-Supervised Learning*. MIT Press, 2006.

[13] J. E. van Engelen and H. H. Hoos. A survey on semi-supervised learning. *Machine Learning*, 109(2) :373–440, 2020.

[14] D. Yarowsky. Unsupervised word sense disambiguation rivaling supervised methods. In *Proceedings of the 33rd Annual Meeting of the Association for Computational Linguistics*, pages 189–196, 1995.

[15] A. Blum and T. Mitchell. Combining labeled and unlabeled data with co-training. In *Proceedings of the 11th Annual Conference on Computational Learning Theory (COLT)*, pages 92–100, 1998.

[16] X. Zhu and Z. Ghahramani. Learning from labeled and unlabeled data with label propagation. Technical Report CMU-CALD-02-107, Carnegie Mellon University, 2002.

[17] Z.-H. Zhou and M. Li. Semi-supervised regression with co-training. In *Proceedings of the 19th International Joint Conference on Artificial Intelligence (IJCAI)*, pages 908–913, 2005. URL https://www.ijcai.org/Proceedings/05/Papers/0689.pdf.

[18] ISO. ISO 2560 – produits consommables pour le soudage – Électrodes enrobées pour le soudage manuel à l'arc des aciers non alliés et des aciers à grains fins – classification. Organisation internationale de normalisation, éditions

2002 et 2020, 2020. URL https://cdn.standards.iteh.ai/samples/35626/e216187634ce4fb68ef77afca2a42d40/ISO-2560-2002.pdf. Tableaux 1A et 2A lus sur l'aperçu officiel de l'édition 2002, identiques dans l'édition 2020 selon TWI ; consulté le 12 octobre 2026.

[19] TWI. Welding consumables – part 3 (job knowledge 84). The Welding Institute, s.d. URL https://www.twi-global.com/technical-knowledge/job-knowledge/welding-consumables-part-3-084. Tableaux de classification ISO 2560, consulté le 12 octobre 2026.

[20] ISO. ISO 18275 – produits consommables pour le soudage – Électrodes enrobées pour le soudage manuel à l'arc des aciers à haute résistance – classification. Organisation internationale de normalisation, 2005. URL https://www.sis.se/api/document/preview/905907/. Tableau 1A lu sur l'aperçu de l'édition 2005 ; consulté le 12 octobre 2026.

[21] American Welding Society. AWS A5.1/A5.1M – specification for carbon steel electrodes for shielded metal arc welding. Exigences E7018 reprises par la fiche Lincoln Electric 7018 AC ; tableaux 3 et 4 de l'édition 1981 (ASME SFA-5.1), 1981. URL https://canteach.candu.org/Content%20Library/20053402.pdf. Consulté le 12 octobre 2026.

[22] Det Norske Veritas. DNV-OS-C401 – fabrication and testing of offshore structures. Offshore Standard, avril 2004, amendé en avril 2005, 2004. URL https://rules.dnv.com/docs/pdf/dnvpm/codes/docs/2005-04/OS-C401.pdf. Ch. 2 Sec. 1, essais de qualification des modes opératoires ; consulté le 12 octobre 2026.

[23] E. Keehan, L. Karlsson, M. Marimuthu, H.-O. Andrén, and H. K. D. H. Bhadeshia. High strength steel weld metals : developments with Ni and Mn. In *Proceedings of the 7th International Welding Symposium*. Japan Welding Society, 2001. URL https://www.phase-trans.msm.cam.ac.uk/2002/kobe.html.

[24] A. Mehmanparast, J. Taylor, F. Brennan, and I. Tavares. Experimental investigation of mechanical and fracture properties of offshore wind monopile weldments : SLIC inter-laboratory test results. *Fatigue & Fracture of Engineering Materials & Structures*, 2018. URL https://strathprints.strath.ac.uk/64716/.

[25] JCGM. Evaluation of measurement data – the role of measurement uncertainty in conformity assessment. Technical Report JCGM 106 :2012, Joint Committee for Guides in Metrology, 2012. URL https://www.bipm.org/documents/20126/2071204/JCGM_106_2012_E.pdf.

[26] R. F. Barber, E. J. Candès, A. Ramdas, and R. J. Tibshirani. Predictive inference with the jackknife+. *The Annals of Statistics*, 49(1) :486–507, 2021. doi : 10.1214/20-AOS1965.